

Cops-Ref 論文詳細導讀 (繁體中文版)

寫給完全沒讀過的人，也希望能一篇看懂。本文整合 PDF 全文細節 + 後續 follow-up (FineCops-Ref 2024) + 與你 vault 內其他 REC 論文 (GREC、HieA2G、Modeling Relationships、True/False Verification) 的關聯。

0. 一句話總結

Cops-Ref 是一個 2020 年 CVPR 提出的「組合性指涉表達理解 (Compositional Referring Expression Comprehension, REC)」資料集與任務。它的核心觀察是：以前的 RefCOCO/RefCOCO+/RefCOCOg 用「最短的詞 + 一兩個物體」就能解出來，根本量不到模型的 reasoning 能力。Cops-Ref 用兩招逼模型必須真的讀懂整句話：

1. 表達式引擎 (expression engine)：六種邏輯型態 (chain, and, or, order, same, not) 任意組合，產生「華麗 (flowery)、長、組合性高」的 query，例如 The cat on the left that is sleeping and resting on the white towel.
2. 干擾圖像 (distracting images)：測試時除目標圖外，加入大量視覺上與 target 相似的其他圖像 (含相同物件類別、相同類別 + 屬性、相同物件但關係不同等四種干擾)，逼模型不能用 shortcut。

論文同時提出一個 baseline 改良：MattNet-Mine，用 modular hard mining 從 sub/loc/rel 三個模組各自找 hard negative。

1. 論文基本資訊

項目	內容
標題	Cops-Ref: A new Dataset and Task on Compositional Referring Expression Comprehension
作者	Zhenfang Chen ¹ , Peng Wang ² , Lin Ma ³ , Kwan-Yee K. Wong ¹ , Qi Wu ⁴
單位	¹ HKU、 ² University of Wollongong、 ³ Tencent AI Lab、 ⁴ University of Adelaide
會議/年份	CVPR 2020 (arXiv:2003.00403)
CVF 連結	https://openaccess.thecvf.com/content_CVPR_2020/html/Chen_Ref_..._paper.html
官方案式碼	https://github.com/zfchenUnique/Cops-Ref
延伸工作	FineCops-Ref (EMNLP 2024 · arXiv:2409.14750) ; TPAMI 2025 擴展版

2. 問題定義與動機

2.1 REC 任務本身

Referring Expression Comprehension (REC) = 給一張影像 + 一句自然語言描述，模型要在影像中定位出該描述所指的「特定物件」(output 是 bbox 或 region index)。是 visual grounding 的一支。

2.2 既有資料集的兩大缺陷

作者抨擊 RefCOCO / RefCOCO+ / RefCOCOg 等主流資料集：

缺陷 A：表達式太短、太淺 - 平均長度只有 3.5 (RefCOCO)、8.5 (RefCOCOg) 詞。 - 通常只描述「類別 + 一個屬性 + 一個簡單空間關係」，例如 the girl with glasses、the man sitting next to a table。 - 模型只要做「淺層 cross-domain alignment」就能答對，無法評估深度推理。

缺陷 B：圖像中干擾太少 + dataset bias 嚴重 - 每張圖通常只有 2-3 個同類物件，distractor 不足。 - Cirik et al. (NAACL 2018) 已指出：只看圖、不看 query 的「deaf model」，在 RefCOCOg 上 image-only 都能拿到 40.1% (vs 隨機)，證明 shortcut 嚴重。 - 即使把整句話的詞序打亂 (shuffle) 或只留名詞形容詞，效能只掉 4% / 3%——代表模型根本沒在用 reasoning。

對手選項 CLEVR-Ref+ (CVPR 2019) 雖然合成、有 clean diagnostic 性質，但只有 3 種物件類別、12 種屬性，太簡單也不夠真實。

2.3 Cops-Ref 的設計目標

要同時做到： - **真實圖像** (不像 CLEVR 合成)：建在 GQA 的 real-world image + scene graph 之上。 - **組合性強的長表達式**：用 expression engine 自動產生，可控、無歧義、語法正確。 - **強干擾測試環境**：每個 query 附帶 4 類 distracting images，逼模型必須讀懂整句、做到細粒度推理。

3. Cops-Ref 方法架構 (資料集構建細節)

整個資料集建構分四個模組：(A) Expression Engine → (B) Distractor Discovery → (C) Post-processing → (D) Statistics。

3.1 (A) Expression Engine (最關鍵的創新)

三步驟流程

1. 給定一個 target region，從預定義的 **logic form family** 抽一個邏輯型態 + 對應 textual template。
2. 從場景圖 (scene graph) 以 target object 為 root，展開出對應的 **reasoning tree**。
3. 用 reasoning tree 的內容填回 textual template，產生最終表達式。

六種 Logic Forms (論文 Table 1)

編號	Form	Reasoning tree 結構	Template 範例	表達式範例
1	chain	obj0(att0)— rel0→obj1(att1) — rel1→obj2(att2)	The <att0> <obj0> that is <rel0> <att1> <obj1> that is <rel1> <obj2>.	The young girl that is touching the glazed donut that is on the round table.
2	and	obj0 同時與 obj1、 obj2 有兩條關係	The <att0> <obj0> <rel0> the <att1> <obj1> and <rel1> the <att2> <obj2>.	The white fence near the building and behind the walking woman.

編號	Form	Reasoning tree 結構	Template 範例	表達式範例
3	or	obj0 與 obj1、obj2 至少滿足一條關係	...or...	The green suitcase behind the black suitcase or near the yellow suitcase.
4	order	obj0 帶 in-dex/direction/attribute	The <idx> obj0> from the <dir> that is <att0>.	The first glass from the left that is red.
5	same	obj0 與 obj1 共享某屬性類別 (顏色/形狀/材質/性別/紋路)	The <obj0> that has the same <cat> as the <obj1>.	The bag that has the same color as the sweater.
6	not	obj0 不具有某屬性	The <obj0> that is not <att0>.	The apple that is not red.

這六種可以再彼此巢狀組合，產生更複雜的句子。

Reasoning Tree 解析細節

- **chain/and/or**：直接從 GQA 的 scene graph 子圖切出。
- **order**：把同類物件依 bbox 中心座標由左到右排序；因為 order 的條件較弱 (“the left glass” 在干擾圖也可能成立)，再額外加 attribute/relation 來保唯一性。
- **not**：遍歷 scene graph，找出「同類別其他物件全部有、但 target 沒有」的 attribute/relation。
- **same**：找「只有 target 和 related object 共享」的屬性，把該屬性類別當作兩者間的「關係」。

3.2 (B) Distracting Images 的發現 (第二大創新)

測試階段對每個 expression 提供 4 類干擾圖 (每類 3 張，共最多 12 張干擾圖 + 1 張 target 圖)：

類型	定義	考驗什麼能力
DiffCat	圖中物件類別 $\neq$ target 類別	基本物件識別
Cat	含 target 同類別的物件	屬性/關係的進一步辨別
Cat&attr	含 target 同類別 + 同屬性的物件	必須讀關係
Cat&cat	含 reasoning tree 中所有物件，但關係不同	必須讀關係的「方向/語意」

→ 找不到足夠 distractor 的 region-expression pair 直接丟棄。

3.3 (C) Post-processing 與 Balancing

- 用 WordNet 的 synonym 增加表達式詞彙多樣性。
- 刪掉「無法用 bbox 框出」的類別 (如 sky, cloud)。
- 刪掉太小的 region ($< 1\%$ 影像面積)。
- 手動 check testing set，去除因 GQA scene graph 不完整而造成的「distractor 其實也符合 query」的雜訊樣本。
- 對 GQA 中過度頻繁的關係 (如 to the left of) 做反比例 downsampling，並丟掉「只含簡單空間關係」的 region-expression。

3.4 (D) Dataset Statistics (論文 Table 2)

Dataset	#ObjCat	#Att	#Rel	Avg Exp Length	Avg #Cand	Avg #Same-cat Cand
RefCOCO	801	—	—	3.5	10.6	4.9
RefCOCOg	80	—	—	8.5	8.2	2.6
CLEVR-Ref+	3	12	5	22.4	—	—
Cops-Ref	508	601	299	14.4	262.5	20.3

最終規模：- 148,712 expressions、1,307,885 regions、75,299 images - Vocabulary size: 1,596 - Train / Val / Test = 119,603 / 16,524 / 12,586 expressions - 採用 GQA 的 val 當 test (因 GQA test scene graph 未公開)，再從 GQA train 切出新 val

3.5 任務形式化

給定 N 張圖 (含 1 張 target + 多張 distractor) 和 query q，找：

$$r_{i,j}^* = \arg \max_{r_{i,j}, i \in [1, N], j \in [1, J_i]} s(r_{i,j} | q)$$

其中 $s(\cdot | q)$ 是 region-query 匹配分數。訓練時不提供 **distractor** 圖 (理由：真實世界難收集 distractor，且方便沿用既有 REF model 的訓練流程)，distractor 只在測試時加入。

4. 場景上下文 (Scene Context) 是如何被建模的？

論文沒有提一個新的 grounding model 去顯式建 scene context，而是透過資料設計把 scene context 的需求 push 到 model 端。具體機制：

4.1 資料層次：表達式內嵌 scene graph

- Reasoning tree 直接從 GQA dense scene graph 切出，所以一個 expression 不只是描述 target 本身，而是把 target 嵌入到一張 **sub-graph** (target + related objects + relations + attributes) 裡。
- 例如 The young girl that is touching the glazed donut that is on the round table 強迫模型同時定位 girl/donut/table 並驗證 touching、on 兩條關係。

4.2 測試環境層次：multi-image context

- 把 distracting images 加入候選池，將 scene context 從「單張圖內」擴展到「圖像集合間」。模型不能只看單張圖內的少數同類物，還必須把整個 image set 視為一個更大的 visual context 去 disambiguate。

4.3 模型層次：MattNet-Mine 透過 modular sampling 學 context

- 用 MattNet 的 sub/loc/rel 三個模組的 phrase embedding 相似度，從整個訓練集找「modular-level」的 hard negative。
- 等於把「context distinguishability」當成一個 learning signal 注入訓練：模型被迫學到 sub/loc/rel 三方面都和 target 接近的 negative 才難。

5. Baseline 模型與 MattNet-Mine

5.1 Baseline = MattNet (Yu et al., CVPR 2018)

MattNet 是當年最強 REF baseline · 把 query 拆三模組：subject (sub)、location (loc)、relationship (rel) · 總匹配分數：

$$s(r_j|q) = \sum_{md \in \{\text{sub, loc, rel}\}} w_{md} \cdot s(r_j|q_{md})$$

原始訓練用 **ranking loss** (hard negative 只在「同一張圖內」抽)：

$$L_{rank} = \sum_m \left([\Delta - s(r_m|q_m) + s(r_m|q_n)]_+ + [\Delta - s(r_m|q_m) + s(r_o|q_m)]_+ \right)$$

→ 在 Cops-Ref 上問題：沒辦法挑「跨圖」的 **hard negative** · 所以 distractor 圖一加入立刻崩盤。

5.2 MattNet-Mine (本文新增 baseline)

Modular Hard Mining 策略 對第 m 個 region-expression pair · 用 modular phrase embedding q_m^{md} 算出與第 n 個 pair 的 cosine 相似度 $s_{m,n}^{md}$ · 再 softmax 得到取樣機率：

$$p_{m,n}^{md} = \frac{\exp(s_{m,n}^{md})}{\sum_{n'=1, n' \neq m}^{N_C} \exp(s_{m,n'}^{md})}$$

其中 N_C = 訓練集中與 m-th sample 同類別的所有 sample 數。

Mining Loss

$$L_{mine} = \sum_m \sum_{md} \left([\Delta - s(r_m|q_m) + s(r_m|q_n^{md})]_+ + [\Delta - s(r_m|q_m) + s(r_n^{md}|q_m)]_+ \right)$$

總 Loss

$$L = L_{rank} + L_{mine}$$

- L_{rank} 處理「同圖內」hard negative； L_{mine} 處理「跨圖」hard negative。
- 訓練流程：先用 L_{rank} pre-train · 再用 $L_{rank} + L_{mine}$ fine-tune；每 50 iteration 更新一次 sample 機率。
- 高效：只需 expression embedding · 不用 load 圖；29 秒就能掃完整個訓練集所有 expression。

6. 實驗結果

6.1 主表 (Table 3 · testing accuracy %)

Method	Full	DiffCat	Cat	Cat&attr	Cat&cat	WithoutDist
Chance	0.4	1.7	1.8	1.9	1.7	6.6
Grounder	19.1	60.2	38.5	35.7	38.9	75.7

Method	Full	DiffCat	Cat	Cat&attr	Cat&cat	WithoutDist
Deaf-Grounder (image-only)	2.2	7.7	7.9	8.0	8.0	27.1
Shuffle-Grounder	13.1	41.8	28.6	27.2	27.6	58.5
Obj-Attr-Grounder (只留名詞形容詞)	15.2	53.1	32.6	29.6	32.7	68.8
MattNet-refCOCO (transfer)	8.7	22.7	17.0	16.7	18.9	42.4
MattNet	26.3	69.1	45.2	42.5	45.8	77.9
CM-Att-Erase	28.0	71.3	47.1	43.4	48.4	80.4
SCAN+MattNet (re-trieve+REF)	18.8	—	—	—	—	—
MattNet-Mine (本文)	33.8	70.5	54.4	46.8	52.0	78.4

6.2 Bias Analysis (最有說服力的結果之一)

- **Deaf-Grounder** (看圖不看字) 在 Full 設定下只有 **2.2%**，而在 RefCOCOg 等其他資料集相同實驗能拿到 **40.1%**。→ Cops-Ref 的 dataset bias 顯著被壓抑。
- **Shuffle 詞序**：RefCOCOg 上只掉 4%，Cops-Ref 上掉 **31%**。
- **Obj-Attr only**：RefCOCOg 上只掉 3%，Cops-Ref 上掉 **20%**。
- → 證明 Cops-Ref 真的需要句法、關係、整體推理才能解。

6.3 Transfer Performance (兩個方向皆值得注意)

- MattNet trained on RefCOCO → Cops-Ref Full: **8.7%** (崩潰) → 證明 Cops-Ref 真的比較難。
- MattNet trained on Cops-Ref → RefCOCO testA/B: **56.5 / 64.5%** (約原始 65.7% / 76.4%) → 證明合成出來的 expression 仍有實用知識可 transfer 回 RefCOCO。

6.4 Logic Form 細分 (Fig. 3)

- **order > not > 其他四種**：因為 order 的 reasoning tree 較簡單，且本身就提供同類別物的相對空間位置。
- chain / and / or / same 表現接近。

6.5 Expression Length (Fig. 4)

- **middle (10–20 words) > short < long**：太短資訊不足，太長則語意太複雜難 reason。

6.6 Ablation —Mining Strategy (Table 4)

Strategy	Full	DiffCat	Cat	Cat&attr	Cat&cat
原 MattNet	26.3	69.1	45.2	42.5	45.8
Random	27.6	71.6	47.4	43.5	47.3
Class-aware	32.2	70.3	53.2	46.1	51.4
Sentence-sim	32.3	70.4	53.6	46.4	51.2
Module-specific (本文)	33.8	70.5	54.4	46.8	52.0

→ Module-specific (用 sub/loc/rel 各自的 embedding 相似度) 顯著勝過用整句平均的 sentence-sim。

6.7 Retrieve + REF 策略

「先用 SCAN 做 text-to-image retrieval 挑一張圖再 REF」反而只有 18.8% (遠低於 dense REF) · 原因是 retrieval 粗略，無法做 region-level fine-grained matching。

7. 關鍵洞見與貢獻

7.1 對社群的四大貢獻

1. 新任務 **Cops-Ref**：要求模型在 visually-similar 的 image set 中定位 target。
2. 新資料集：建在 GQA 真實圖像之上、保留視覺真實感與語意豐富性。
3. **Expression Engine**：6 種 logic form 可任意組合，產生可控的長/複雜 query。
4. **MattNet-Mine baseline**：modular hard mining 顯著優於既有 SOTA。

7.2 我認為更值得記住的洞見

- 資料集設計本身就是 **contribution**：把「scene context」這件事的負擔從 model design 推回 data design，比硬寫一個新 attention module 更有 lever。
- **distractor** 是 **reasoning** 評估的本質：沒有 distractor，shortcut model 就能假裝在 reason。Cops-Ref 用 4 種 distractor 把 shortcut 路徑一條條切掉。
- **Modular hard mining** 是 **cheap and effective**：不需要 load image，只用 phrase embedding 相似度，就能挑出強 hard negative。
- **Cross-dataset transfer** 是雙向不對稱的：RefCOCO → Cops-Ref 崩盤；Cops-Ref → RefCOCO 大致保留 → 證明 Cops-Ref 的訓練信號「包含」RefCOCO 但反之不然。

8. 與你 vault 中其他 REC 論文的關係

8.1 vs. Modeling Relationships in Referential Expressions with Compositional Modular Networks (Hu et al., CVPR 2017)

- Hu 的 CMN 是「模型側」的 compositional approach：把 query 拆成 subject-relation-object triplet，各自用 module 處理。Cops-Ref 是「資料側」的 compositional approach：用 expression engine 生 compositional query。
- 兩者互補：Cops-Ref 創造的測試環境，正好是 CMN/MattNet 這類 modular model 的試金石。論文也直接用 MattNet (CMN 的精神後裔) 作為主要 baseline。

8.2 vs. HieA2G (Hierarchical Attention-based Approach to Grounding)

- HieA2G 強調階層式 attention 處理多層級語意關係。
- Cops-Ref 的 chain/and/or 等 logic form 正好提供 multi-hop reasoning 的測試場景，**HieA2G 這類階層 attention model 可以在 Cops-Ref 上量到比 RefCOCO 更明顯的優勢**（如果它真的有 hierarchical reasoning 能力的話）。

8.3 vs. GREC (Generalized REC)

- GREC 把 REC 從「假設 query 必有對應物件」推廣到「query 可能對應 0 個、1 個或多個物件」，引入 no-target、multi-target 的 abstention 與多選能力。
- Cops-Ref 的 4 種 distractor 中，**Cat**、**Cat&attr**、**Cat&cat** 都已經帶有「**distractor 圖中也有同類物，但不是 target**」的設定，邏輯上接近 GREC 的「no-target rejection」前身——但 Cops-Ref 仍假設「全 image set 中至少有一個正解」，沒到 GREC 的徹底程度。
- 你做 CRS (Conformal Referring Set) 時，可以把 Cops-Ref 的 distractor 設定當「半個 no-target benchmark」用，但要小心它的訓練集不含 distractor，所以模型沒學過 abstention。

8.4 vs. Zero-Shot REC via Visual-Language True/False Verification (2509.09958)

- 該論文用 LLM/VLM 做 zero-shot REC，把問題 reframe 成「verify 一個 candidate-claim 對」的 True/False 判斷。
- Cops-Ref 的設計反而是讓 **fully-supervised model 都很難解**，所以是 True/False verification 框架的最硬考題之一：模型對長 reasoning chain + distractor 必須做多步 verification，不能用單一 contrastive score 一次比完。
- 你筆記提到這篇是新競品威脅 Ch5 ceiling —在 Cops-Ref 上對 True/False verification framework 的 evaluation，可能會比在 RefCOCO 上更能拉開差距、給你 Ch5 找回優勢空間。

9. 個人評價

9.1 優點

1. **問題抓得準**：當時 REC 領域已被 RefCOCO 主宰太久，shortcut 嚴重，Cops-Ref 直接從「能不能評到 reasoning」的根本動機切入。
2. **資料設計嚴謹**：bias analysis 用 deaf/shuffle/obj-only 三組 ablation 把「沒在 reason」的可能路徑全部 expose 出來，論證強。
3. **規模合理**：~15 萬 expression、~7.5 萬影像，足以訓練；又不像 CLEVR 一樣脫離真實。
4. **MattNet-Mine 是個好用的 baseline trick**：modular-level mining 比 sentence-level 顯著好，且實作便宜。
5. **可重現性高**：GitHub repo、CVPR open access、scene graph 來自公開 GQA。

9.2 缺點與限制

1. **Expression 還是「合成」出來的**：雖然建在真實圖像 + 真實 scene graph 上，但句子是 template + slot fill，不像人類自由表達自然。所以 Cops-Ref 對“自然語言的歧義性、口語性、metaphor”等問題覆蓋不足。
2. **scene graph 噪音傳播**：GQA scene graph 已知 incomplete/noisy，作者只手動清了 testing set，training set 依舊帶噪。
3. **訓練/測試 distractor 不對稱**：訓練時不放 distractor，造成 model 沒學過跨圖比較；MattNet-Mine 其實是在補這個 gap，但仍是後處理式的補救。
4. **6 種 logic form 仍是封閉集合**：不能涵蓋 negation 的多層 scope、quantifier (「所有的」「至少兩個」)、temporal/causal reasoning 等更複雜邏輯。
5. **不評估 no-target / multi-target**：所有 query 在 image set 中恰好有一個正解，無法測 GREC-style 拒答能力（這後來被 FineCops-Ref / GREC 補上）。

6. 缺乏 **generative / open-vocab** 設定：bbox 候選來自 GT，等於假設 detector 完美，與現代 open-set / VLM-based REC 的 setup 落差大。
7. 6 年後已被 **follow-up** 部分超越：FineCops-Ref (EMNLP 2024) 名字就是致敬 Cops-Ref，補強了 controllable difficulty、negative text、negative image，並把測試對象從專家 REC model 改到 MLLM。

9.3 適合什麼研究情境用 Cops-Ref？

- 想評估 **compositional reasoning** 而非 **grounding accuracy** 本身 → 強推。
 - 想測 **zero-shot VLM** 能不能讀懂長 **query** + 拒絕 **distractor** → 是不錯的 stress test。
 - 想做 **selective grounding / calibration** 研究（如你的 CRS 主線）→ 4 類 distractor 是現成的 controlled negative source，可以拿來做 conformal set 的 size/coverage 對比；但要小心 multi-image setup 與 RefCOCO/gRefCOCO 的 protocol 不同，bbox 候選池不一樣。
-

10. 對你（kuo）論文主線的可能用途

結合你的 CRS / selective grounding 主線：

1. **Cops-Ref 的 distractor 是天然的 conformal calibration set**：4 類干擾分得很乾淨，可以做「分類別 LTT bound」的 fine-grained study，比 gRefCOCO 的 no-target 更可控。
 2. **Cross-Base Conformal Composition (OWL gate + GD box) 在 Cops-Ref 上可能更顯優勢**：因為 distractor 多，gate 的價值會放大；可以把它當成第三個 base 或第三個資料集去佐證 cross-base transferability。
 3. **Risk**: Cops-Ref 的 ground-truth bbox protocol 與你 frozen detector 的 detection-from-scratch 設定不同，需要先決定要不要用 GT proposal。如果用 GT，那等於把 detector recall 設成 1，CRS 的可用 abstention 會少一個論述空間。
 4. **與 True/False Verification 競品的對比**：在 Cops-Ref 上跑你的 post-hoc reliability layer，若能在 Cat&attr / Cat&cat 兩個最硬 split 上贏 True/False baseline，能幫 Ch5 找回 ceiling。
-

11. 參考延伸閱讀

- 原論文：arXiv:2003.00403 / CVPR 2020 open access
- 程式碼：<https://github.com/zfchenUnique/Cops-Ref>
- 後繼工作 FineCops-Ref：arXiv:2409.14750 (EMNLP 2024 main + TPAMI 2025 擴展)
- 同類診斷資料集：CLEVR-Ref+ (CVPR 2019)
- Bias analysis 母題：Cirik et al., NAACL 2018, "Visual Referring Expression Recognition: What Do Systems Actually Learn?"
- MattNet (baseline)：Yu et al., CVPR 2018
- CM-Att-Erase (baseline)：Liu et al., CVPR 2019