

GREC: Generalized Referring Expression Comprehension —— 詳細導讀

讀書筆記（繁體中文版）

2026-06-18

GREC: Generalized Referring Expression Comprehension ——詳細導讀

0. 基本資訊

- 論文標題：GREC: Generalized Referring Expression Comprehension
- 作者：Shuting He†、Henghui Ding†（共同一作）、Chang Liu、Xudong Jiang
- 單位：Nanyang Technological University（南洋理工大學）
- 發表狀態：arXiv 技術報告（arXiv:2308.16182v2，2023 年 12 月 24 日 v2）。是 CVPR 2023 論文 GRES: Generalized Referring Expression Segmentation（Liu, Ding, Jiang, CVPR 2023）的姊妹/延伸技術報告，把 GRES 在 segmentation 端建立的「multi-target / no-target」泛化設定，平移到 detection / bounding box 端。
- 官方資源：
 - 專案頁：<https://henghuiding.github.io/GRES>
 - 程式碼與 gRefCOCO 標註：<https://github.com/henghuiding/gRefCOCO>
- 篇幅：正文 5 頁 + 1 頁參考文獻，總 6 頁。屬於 short technical report，定位是「定義新任務 + 開源 benchmark + 提供 baseline 改造方案 + 提出評估指標」。

1. 問題定義與動機

1.1 經典 REC 是什麼

Referring Expression Comprehension（REC，指代表達式理解）是視覺-語言領域的經典任務：

- 輸入：一張影像 + 一段自然語言描述（referring expression），例如「the kid in red」。
- 輸出：影像中該描述所指物件的單一 bounding box。
- 代表資料集：ReferIt（Kazemzadeh et al., EMNLP 2014）、RefCOCO / RefCOCO+ / RefCOCOg（Yu et al., ECCV 2016；Mao et al., CVPR 2016）。
- 應用場景：影片製作、人機互動、機器人。

過去十年的 REC 方法（MCN、VLT、MDETR、TransVG、UNINEXT、Grounding DINO 等）在 RefCOCO 系列上 top-1 accuracy 已普遍達 85% 以上，看似「solved」。

1.2 經典 REC 的兩個強假設（也是限制）

論文一針見血地指出，主流 REC 設定其實隱含兩個「過強的前置條件」（pre-defined constraints）：

1. 單目標假設（single-target）：每條表達式恰好對應到影像中一個物件。
 - 資料集裡每個 sample 只有一個 ground-truth box，模型也只輸出一個 box。
 - 但實際語言常出現「所有人」「左邊三隻羊」「除了穿白衣的那個小孩外的所有人」這種多目標表達式，現有 REC 完全無法處理——你必須把問題拆成多次單目標查詢，效率低且不自然。

2. 目標必存在假設 (target-must-exist)：表達式所指的物件一定在影像中存在。
 - 若使用者輸入一個畫面裡根本不存在的物件，例如畫面是兩個穿紅、白衣的小孩，使用者問「the kid in blue」，現行 REC 模型行為是「未定義的」——它一定會硬輸出某個 box（通常是隨便挑一個最像的），對使用者極度不友善。
 - 這在實務上等於把判斷「指代是否成立」的責任全推給使用者。

論文的核心論點：這兩個假設嚴重削弱 REC 的實用性，必須鬆綁。

1.3 GREC：把 REC 從「1」泛化到「0 ~ many」

作者提出 Generalized Referring Expression Comprehension (GREC)：

- 輸入：與經典 REC 相同（影像 + 表達式）。
- 輸出：bounding box 的集合 $B = \{b_i\}$ ， $|B|$ 可以是 0、1、2、 $\dots$ 、N。
- 支援三種樣本：
 1. single-target：經典 REC 的情況，向後相容。
 2. multi-target：一條表達式對應到多個物件（例如「all people」、「two players on left」、「everyone except the kid in white」）。
 3. no-target：表達式描述的物件不存在於影像中，模型應該輸出空集合 $\emptyset$ 。

GREC 不是發明全新的任務，而是鬆綁經典 REC 的人工約束，讓問題退回更自然的 set-valued grounding 問題。

1.4 為什麼這個泛化有意義（論文舉的四個應用）

1. 一次 forward 抓多物件：例如「all people」原本要跑四次模型才能框出四個人，GREC 一次搞定 (Fig. 2a)。
2. 使用者定義的 open-vocabulary perception：像「foreground」「kids」這種模糊但語意明確的詞，可以當作 query 直接抓符合條件的所有物件。
3. 以表達式做影像檢索：把同一條表達式套到一組影像上，可以快速篩出「含有該物件的影像」，比傳統 image retrieval 更精準 (Fig. 2b)。
4. 更高的 robustness：實務上使用者會打錯字、亂下指令，no-target 樣本的存在強迫模型有「拒答」能力，避免幻覺式錯誤輸出。

2. gRefCOCO 資料集

注意：GREC 論文本身對資料集只給出 1 個段落的概述（§ 2.2 只說「請參考 GREC 論文」），完整的標註流程與統計細節在姊妹論文 GREC (CVPR 2023) 裡。以下整合 GREC 論文的關鍵資訊。

2.1 與其它 REC 資料集的比較 (Tab. 1)

資料集	影像來源	Multi-target	No-target	表達式
ReferIt	CLEF	☒	☒	free
RefCOCO / RefCOCOg	COCO	☒	☒	free
PhraseCut	VG	✓ (fallback)	☒	templated
gRefCOCO	COCO	✓	✓	free

關鍵：- gRefCOCO 是第一個同時涵蓋 multi-target + no-target + free-form 表達式的大規模 REC 資料集。- 影像來自 COCO，與 RefCOCO 同源，所以可以直接做 cross-dataset 比較與相容。- PhraseCut 雖然支援 multi-target，但它的表達式是模板生成的 (templated)，語言多樣性遠遠不如 free-form。

2.2 樣本切分

延續 RefCOCO 的 train / val / testA / testB 切分，內含三種樣本 (single / multi / no-target) 並存。重點 caveat：作者特別強調，任何訓練／預訓練都必須排除 val/testA/testB 的影像，否則會 information leakage (這是 UNINEXT 原始版本踩過的坑，他們重新訓練了一份乾淨版來公平比較)。

3. 評估指標：為什麼經典 REC 的 Precision@0.5 不夠用

3.1 經典 REC 的指標

- 每個 sample 只有 1 個 GT box、1 個 predicted box，預測非 TP 即 FP。
- 用 Precision@0.5 (top-1 accuracy)：IoU > 0.5 算對。
- 這個指標在 GREC 下完全崩潰，因為：
 - multi-target 樣本：GT 有 N 個 box，預測也應該有 0~M 個 box，單靠一個 IoU 沒法評。
 - no-target 樣本：根本沒有 GT box，IoU 無從談起。

3.2 GREC 新指標 1：Precision@(F1=1, IoU ≥ 0.5) (論文推薦主指標)

對一個 sample：

1. 把每個 predicted box 與 GT box 用 $\text{IoU} \geq 0.5$ 做配對：
 - 配對到的 prediction 算 TP；若多個 prediction 配到同一個 GT，只保留 IoU 最高那一個為 TP，其餘 FP。
 - 配對不到 GT 的 prediction 算 FP。
 - 配對不到 prediction 的 GT 算 FN。
2. 計算 sample-level F1： $F1 = 2 \cdot TP / (2 \cdot TP + FN + FP)$ 。
3. 只有 F1=1 (完全配對、無冗餘) 才算這個 sample 預測成功。
4. 對 no-target 樣本：若預測 0 個 box $\rightarrow F1=1$ (成功)；否則 $\rightarrow F1=0$ (失敗)。
5. 整個資料集的指標 = 成功樣本數 ÷ 總樣本數。

為什麼設這麼嚴格的「F1 必須等於 1」？因為 REC/GREC 的下游使用情境是把 box 給使用者看，多框一個錯的或漏一個對的，使用者體驗都會崩，因此採 sample-level 全對才算分。

3.3 GREC 新指標 2：N-acc. (No-target accuracy)

專門評估「拒答能力」：

- 對 no-target 樣本：預測 0 個 box $\rightarrow TP$ ；只要預測任何 box $\rightarrow FN$ (不是 FP，因為這裡視為「沒有正確識別出 no-target」)。
- $N\text{-acc.} = TP / (TP + FN)$ 。

3.4 為什麼不推薦用 AP

論文特別說明，COCO 風格的 AP (IoU 0.5–0.95 平均) 在 REC/GREC 不合適，因為 AP 不會懲罰模型輸出大量低 confidence 的冗餘 box ——但 REC 場景下，使用者問一個物件你卻吐 100 個框絕對是 unacceptable。所以 AP 高未必好，作者明確說 AP 「does not fully capture the performance」。

4. 方法：把現有 REC 方法「適配」到 GREC

GREC 論文本身沒有提出新方法，定位是 benchmark 論文。它做的事情是：

1. 拿四個經典/SOTA REC 方法 (MCN、VLT、MDETR、UNINEXT)。
2. 把它們的 detection head 改造成可以輸出多個 bounding box (原本許多方法只輸出 top-1 或單一 box)。

3. 在「如何從多個候選 box 選出最終輸出集合」這一步做 ablation。

4.1 候選 box 選法的 ablation (Tab. 2, 以 MDETR 為 base)

MDETR 本身會輸出 100 個 box，問題是怎麼從中選：

策略	Pr@(F1=1, IoU $\geq$ 0.5)	AP	N-acc.
Top-1	0.0	26.2	0.0
Top-5	0.0	52.8	0.0
Top-10	0.0	53.3	0.0
Top-100	0.0	53.5	0.0
Threshold-0.5	37.0	52.6	32.2
Threshold-0.6	38.9	52.5	33.9
Threshold-0.7	41.5	52.3	36.1
Threshold-0.8	44.7	51.7	39.2
Threshold-0.9	51.2	50.8	45.7

關鍵洞察：

- Top-k 策略全軍覆沒 (Pr@F1=1 都是 0)：因為 top-k 強迫每個 sample 都吐 k 個 box，對 multi-target 樣本最多只能拿到 F1 = 0.67 (兩個目標只對一個 + 多了一個 FP)，對 no-target 樣本一定 FN (強迫輸出 ≥ 1 個 box，但 GT 是 0)，N-acc. = 0。
- 基於 confidence threshold 的動態策略才行得通：讓模型根據每個 sample 自己決定要輸出幾個 box。
- threshold 越高越好：從 0.5 提到 0.9，Pr@F1=1 從 37.0% $\rightarrow$ 51.2%，N-acc. 從 32.2% $\rightarrow$ 45.7%。高 threshold 等於更保守地輸出，減少 FP 與錯誤拒答失敗。
- AP 在不同 threshold 下變化很小 (50.8–53.5)，再次印證 AP 對 GREC 不敏感。

論文呼籲：未來研究應該設計更聰明的 output strategy (不只是 threshold cut-off)。

4.2 主表 baseline 結果 (Tab. 3)

四個方法被改造成「輸出多 box + threshold=0.7 篩選」(+ 標記)：

方法	Visual Enc.	Text Enc.	val Pr@F1=1	val N-acc.	testA Pr@F1=1	testA N-acc.	testB Pr@F1=1	testB N-acc.
MCN +	DarkNet-53	GRU	28.0	30.6	32.3	32.0	26.8	30.3
VLT +	DarkNet-53	GRU	36.6	35.2	40.2	34.1	30.2	32.5
MDETR +	ResNet-101	RoBERTa	42.7	36.3	50.0	34.5	36.5	31.0
UNINEXT +	ResNet-50	BERT	58.2	50.6	46.4	49.3	42.9	48.2

關鍵觀察：

- 同樣這些方法在 RefCOCO 單目標 setting 上 top-1 accuracy 普遍 85%+，在 GREC 上 Pr@F1=1 只剩 26–58%，掉了 30+ 點。明確證明「single-target 上 saturated」 $\neq$ 「真實場景上 ready」。
- UNINEXT 最強，但 N-acc. 也只有 ~50%，表示拒答能力遠未到位。
- testA (人物為主) 通常比 testB (物件為主) 容易，但 UNINEXT 在 val/testA/testB 上 Pr@F1=1 是 58.2 / 46.4 / 42.9，跟其它方法 testA > val > testB 的順序不同——這可能跟 UNINEXT 的訓練資料分布有關。

Information leakage caveat：原始 UNINEXT 預訓練包含 val/testA/testB 的影像，作者重新訓練了一份不含這些影像的版本 (嚴格 setup)，數字是這份乾淨版的。

4.3 質性結果 (Fig. 3)

- 成功案例 (最上排)：模型能抓 salient 線索如顏色 (橘色雨傘)、位置 (最邊兩個人)、數量 (三隻看狗的羊)。
- multi-target 失敗 (中排)：當表達式包含「共享屬性」「複雜組合」(如 “Orange and all sandwiches”，需要同時抓水果跟所有三明治)，模型會漏框或多框， $F1 = 0.27 \sim 0.5$ 。
- no-target 失敗 (下排)：模型仍會硬輸出 box， $F1 = 0$ 。論文舉了一個有趣的 deceptive 案例：「The right guy sitting on the bench wearing a hat」——畫面右邊確實有個人坐在 bench 上，但他沒戴帽子。理想模型應該識破這個 mismatch 輸出 $\emptyset$ ，但目前的方法做不到。這個案例特別點出 GREC 需要「細粒度語意一致性檢查」的能力。

5. GREC 與經典 REC 的核心差異總表

維度	經典 REC	GREC
輸入	影像 + 表達式	影像 + 表達式 (相同)
輸出	1 個 box	0 ~ N 個 box 的集合
樣本類型	只有 single-target	single + multi + no-target
假設前提	目標必存在且唯一	無假設
主指標	Precision@0.5 (top-1 acc)	$Pr@(F1=1, IoU \geq 0.5) + N\text{-acc.}$
輸出策略	argmax / top-1	需要動態決定輸出數量 (threshold / set prediction)
對 robustness 的要求	低 (默認 well-formed input)	高 (要能拒答與多框)
與下游應用契合度	受限 (要多次呼叫、無拒答)	更貼近真實使用情境

6. 與其他相關論文的關係

6.1 與 GRES (Liu, Ding, Jiang, CVPR 2023)

- 直系姊妹工作。GRES 把 referring segmentation (RES, 輸出 mask) 泛化到多目標 + no-target；GREC 是把同一個泛化哲學套到 referring comprehension (REC, 輸出 box)。
- 兩者共用 gRefCOCO 資料集的影像與表達式標註 (box 與 mask 都有)。
- GRES 用 ReLA (Region-Language Attention) model 提了一個專門的 method；GREC 沒提新方法，只做 benchmark 與既有方法 adaptation。
- GREC 論文裡資料集細節 (標註流程、表達式統計、annotator 設計) 全部 defer 到 GRES 論文，所以要完整理解 gRefCOCO 必須對讀兩篇。

6.2 與 COPS-Ref (Chen et al., ICCV 2020)

- COPS-Ref (Cops-Ref: A New Dataset and Task on Compositional Referring Expression Comprehension) 也是在批判經典 RefCOCO 系列「太簡單」，但走的是不同方向：
 - COPS-Ref 強調組合性推理 (compositional reasoning) 與 distractor 設計——讓表達式必須做多跳屬性/關係推理才能定位 (例：「the cup to the left of the plate that is on the red table」)。
 - COPS-Ref 仍是 single-target setting (每個表達式一個目標)，但表達式語意更複雜。
- GREC 走的方向是 set-valued generalization (0/1/many 目標)，不是推理複雜度的提升。
- 兩者互補：COPS-Ref 在「表達式有多難理解」這條軸往前推，GREC 在「答案空間多大」這條軸往前推。理想未來 benchmark 應該結合兩者。

6.3 與 HieA2G (Hierarchical Alignment for grounding, 相關 multi-target 後續工作)

- HieA2G 是 GREC/gRefCOCO 釋出後社群提出的後續方法之一，針對 multi-target 場景設計階層式語言-視覺對齊 (hierarchical alignment)，把表達式分解成子片段 (每個 sub-phrase 對應一個或一組物件) 後再做 attention 對齊。
- 對 GREC 的具體貢獻：解決 baseline 在 “shared clue” 與 “compositional multi-target” 上的失敗模式 (如 GREC 論文 Fig. 3 中 “Orange and all sandwiches” 這種需要分解的表達式)。
- 換言之 GREC 是「task + benchmark」，HieA2G 是「在這個 benchmark 上推進方法」的代表之一。

6.4 與 “Modeling Relationships in Referential Expressions” (Hu et al., CVPR 2017)

- Hu et al. 2017 提出 Compositional Modular Networks (CMN)，是早期把「關係」(relationships，如 left of、on top of) 顯式建模進 referring 任務的代表作。它把表達式分解成 subject、relationship、object 三個 module，分別處理後組合。
- 對 GREC 的意義：CMN 已經點出「關係建模」對 REC 不可少，但仍受限於 single-target。GREC 的 multi-target 場景大量需要關係推理 (“two players on left”、“everyone except the kid in white”)，CMN 那條 modular 路線在 GREC 上依然有參考價值。
- 兩者關係：CMN = 經典 REC 時代的方法論貢獻；GREC = 重新定義任務本身。CMN 是 GREC 的學術祖父輩，GREC 引用了它 (ref [13]) 作為 REC 文獻脈絡的一環。

7. 關鍵洞見與貢獻總結

1. 任務泛化 (最核心)：明確指出經典 REC 的兩個強假設 (single-target、target-must-exist)，並提出 set-valued 的 GREC 來取代。這是一個任務層面的概念性鬆綁，比方法層面的改良更具長期影響力。
2. 資料集 gRefCOCO：第一個大規模、free-form、同時涵蓋 single/multi/no-target 的 REC 資料集，與 RefCOCO 影像同源便於相容比較。
3. 新評估指標 $\text{Pr}@(\text{F1}=1, \text{IoU} \geq 0.5) + \text{N-acc.}$ ：sample-level $\text{F1} = 1$ 的嚴格標準確保「全對才算數」，N-acc. 專門評估拒答能力。這兩個指標已被後續 selective grounding、conformal grounding 等 reliability/calibration 方向採用為主指標。
4. Ablation 揭示 top-k 失效：實證證明 top-1/top-k 策略在 GREC 下全部得 0 分，必須改用 dynamic threshold 或 set prediction。這個結論看似簡單，但提醒社群「output strategy 本身是個 open problem」。
5. Baseline reality check：SOTA REC 方法在 RefCOCO 上 85%+，搬到 GREC 上只剩 30–58%，戳破「REC 已解決」的迷思，重新打開研究空間。

8. 個人評價：優點、缺點、限制、後續方向

8.1 優點

- 問題定義乾淨且直覺：把「 $N=1$ 」放寬到「 $N \in \{0,1,2,\dots\}$ 」是最自然的泛化方向，沒有人工痕跡。
- 與既有資料集相容：gRefCOCO 用 COCO 影像、延伸 RefCOCO 標註，舊方法只要小改 head 就能評，門檻低。
- 評估指標設計嚴謹： $\text{Pr}@(\text{F1}=1)$ 的嚴格性正好對應 REC 的下游需求；同時針對 no-target 給 N-acc. 補位。
- 開源完整：資料集、評估腳本、MDETR 改造版 baseline 全部開源，是負責任的 benchmark 論文。
- 論文短而精準：6 頁說清楚 task、dataset、metric、baseline、failure analysis，沒有冗餘。

8.2 缺點與限制

- 沒有提出新方法：定位純粹是 benchmark，貢獻集中在 task + data + metric 三點，方法層留給社群。對研究者來說這既是缺點（沒給 method 啟發）也是優點（不偏袒任何方法）。
- 資料集細節依賴 GRES 論文：§ 2.2 只有一句話「請見 GRES」，獨立讀 GREC 論文無法完整理解 gRefCOCO 的標註流程、表達式分布、潛在偏誤。
- N-acc. 與 $\text{Pr}@F1=1$ 的耦合：no-target 樣本在 $\text{Pr}@F1=1$ 裡也佔分母，與 N-acc. 不完全獨立，可能造成兩個指標互相 confound（例如模型「全部拒答」N-acc 滿分但 $\text{Pr}@F1=1$ 在 multi/single target 部分崩潰）。社群後續通常會分 single/multi/no-target 三個 split 各自報指標。
- Threshold-based 策略其實是 ad-hoc：threshold=0.7 / 0.9 在不同方法、不同 split 上最優值不同，缺少統一的、有理論依據的 abstention 機制。後續 selective prediction / conformal prediction 方向（如 CLIP-VG selective、CRS conformal referring set）就是針對這個缺口。
- 失敗案例「right guy with hat」暴露的是 hallucination 問題：GREC 給了測試平台但沒給解法。需要更強的視覺-語言對齊（如 grounded captioning、verifier、cross-modal entailment）才能解。
- 僅支援靜態影像：影片場景下「multi-target + no-target」的指代有時間動態（MeViS 已往這方向走），GREC 沒涵蓋。
- 缺乏「部分成功」的細粒度評分： $F1 = 1$ 才算對是 sample-level 全有全無；對 multi-target 中等規模 (N=5) 只漏一個的 sample，與完全亂預測拿同樣 0 分，可能讓方法層的小幅進步無法被指標反映。

8.3 後續方向（個人觀點）

1. 更聰明的 abstention / output strategy：跳脫 fixed threshold，改用 conformal prediction、selective head、或學一個 stopping module 來動態決定輸出多少 box（如 Cross-Base Conformal Referring Set 把 LTT 跨 detector 聯合校準）。
2. post-hoc reliability 路線：保持 frozen backbone（CLIP-VG、OWL-ViT、Grounding DINO 等）+ 加一層 calibration head，把 GREC 當「可靠性研究」的試金石（這正是我本身碩論主線在做的方向）。
3. 更困難的 compositional GREC：結合 COPS-Ref 風格的多跳推理與 GREC 的 set-valued 答案，建一個 next-gen benchmark。
4. 多 detector ensemble / cross-base transfer：在 gRefCOCO 上跑多個 base model（CLIP-VG、OWL-ViT、UNINEXT）並研究它們失敗模式的互補性，做集成或 routing。
5. 更精細的 metric：除了 $\text{Pr}@F1=1$ ，引入 mean F1、PR-curve over confidence、cost-sensitive metric（漏框 vs 多框的代價可調）。
6. 支援否定、量詞、排除：multi-target 表達式中「everyone except X」「at least 2 of the ...」對現有 vision-language model 仍是難關。
7. 延伸到 3D / 影片 / robot manipulation：把 set-valued grounding 套到具身智慧場景，這是 referring 任務真正能 deploy 的地方。

9. 三句話總結

1. GREC = 把「REC 只能輸出 1 個 box」這個過時的人工假設拿掉，允許 0/1/many 個 box，更貼近真實使用場景。
2. 作者沒提新方法，而是建了 gRefCOCO 資料集 + 設計了 $\text{Pr}@F1=1, \text{IoU} \geq 0.5$ 與 N-acc. 兩個新指標 + 把 4 個 SOTA REC 方法改造後跑 baseline，發現它們在 GREC 上掉了 30+ 點，戳破「REC 已 saturated」的錯覺。
3. 這篇論文最大的價值不在技術新意，而在重新定義任務邊界——之後 GREC 成為 selective grounding、conformal grounding、open-vocabulary REC 等 reliability/calibration 方向的標準 benchmark。

10. 對個人研究（selective grounding）的對接筆記

與我自己 thesis 主線（CRS: Cross-Base Conformal Referring Set）的對接。

- gRefCOCO 就是我主場資料集，三個 split (val/testA/testB) 也是我 M0/M1/M4 gate 用的。
- $\text{Pr}@(F1=1, \text{IoU} \geq 0.5)$ 與 N-acc. 在我的論文裡是直接拿來當官方指標 (M4 full-GREC 就是用這兩個 metric)。
- N-acc. $0.18 \rightarrow 0.94$ (forced-output $\rightarrow$ post-hoc policy) 這個對比就是 GREC 論文沒處理但我主結果在處理的核心問題：用 post-hoc selective policy 把 no-target 拒答能力從不到 20% 拉到 90+%。
- multi-target T-acc 天花板 $\sim 0.19\text{--}0.24$ 這個 frozen detector exact-match 硬上限，正好對應 GREC 論文 Fig. 3 中 multi-target 失敗案例的根因——bottleneck 在 false positive，不在 false negative，跟我 spark 上跑的數字一致。
- GREC 論文的「threshold-based output strategy」是最 naive 的 baseline，CRS 的 LTT 跨 detector 聯合校準正好是這個方向的「有理論保證」升級版。
- 本論文的 baseline 表 (MDETR 42.7、UNINEXT 58.2 在 val $\text{Pr}@F1=1$) 是我 CRS 主結果 ($\alpha=\beta=0.3$ 下 3.21 boxes、CI 上界 < 0.3) 對比的歷史參照點。

讀後一句評：GREC 是一篇「短小但有定義權」的論文——它沒給你方法，但給了一把尺，從此以後 referring 領域不能只報 RefCOCO 85% 就說 done。