

HieA2G 詳細導讀 (中文)

整理：Kuo

2026-06-18

HieA2G 詳細導讀：階層對齊增強的自適應 Grounding 網路

為 GREC (Generalized Referring Expression Comprehension) 而生

0. 書目資訊

- 論文標題：Hierarchical Alignment-enhanced Adaptive Grounding Network for Generalized Referring Expression Comprehension
- 縮寫：HieA2G (A2G = Alignment-enhanced Adaptive Grounding, 不是 Attribute-to-Group)
- 作者：Yaxian Wang¹², Henghui Ding³ (通訊), Shuting He⁴, Xudong Jiang[✉], Bifan Wei[✉], Jun Liu¹²
 - ¹² 西安交通大學 計算機學院 / 智能網絡與網絡安全教育部重點實驗室
 - ³ 復旦大學 大數據學院
 - ⁴ 上海財經大學
 - ✉ 南洋理工大學
 - ✉ 西安交通大學 繼續教育學院 / 陝西省大數據知識工程重點實驗室
- 發表：AAAI 2025
- arXiv：2501.01416v1 (2025-01-02)
- 連結：<https://arxiv.org/abs/2501.01416>

註：使用者描述為「Hierarchical Attribute-to-Group」，但實際論文 A2G 是「Alignment-enhanced Adaptive Grounding」。本摘要以實際論文為準。

1. 任務背景：從 REC 到 GREC

1.1 三種視覺接地任務一次看懂

任務	目標物件數	是否容許 no-target	是否容許 multi-target	代表資料集
經典 REC	恰好 1	否	否	RefCOCO/+g
Phrase Grounding	多個 (依名詞片語)	否	是 (但只看片語)	Flickr30K Entities
GREC	0 ~ 多個	是	是	gRefCOCO

- REC (Referring Expression Comprehension)：「The man in red shirt」→ 強制輸出唯一 box。
- Phrase Grounding：把句子裡每個名詞片語都接到 image region 上，但不一定理解整句語意。
- GREC (Generalized REC)：把 REC 推廣到「任意數量 0、1、多個目標」。例如：
 - no-target：「the player in blue top and black pants」(圖中根本沒這個人)
 - multi-target：「all people」、「three players」
 - 仍允許單目標 REC

1.2 為什麼 GREC 比 REC 難很多


論文點出兩個核心挑戰：

1. 跨模態對齊不夠：現有 REC/RES 方法（MDETR、CLIP、GroupViT 等）通常只做「單一層次」對齊（word-object 或 text-image 二擇一），對於需要拒答（no-target）或需要計數（multi-target）的句子，細節捕捉不足，導致 false positive 或 false negative。
2. 輸出個數不固定：REC 模型強制 top-1 輸出，GREC 需要動態決定「該輸出 0 個還是 5 個 box」。
 - 純粹用「閾值濾候選 box」（如 GREC baseline）會被一個全域閾值卡死，無法適配各個樣本。
 - 把句子拆成多個子句多輪查詢，又無法處理「all people」這種隱式多目標。

→ 必須同時解決對齊與計數這兩件事。

2. 方法概觀：HieA2G 整體架構

整個流程可拆三段：



元件清單

- Visual Encoder：ResNet-101 或 Swin-B。
- Text Encoder：RoBERTa-base。
- Transformer Encoder + Decoder：類 DETR 結構，N 個 learnable object queries 對應 N 個候選 box / mask。
- HMSA (Hierarchical Multi-modal Semantic Alignment)：本論文第一大貢獻，三層對齊。
- AGC (Adaptive Grounding Counter)：本論文第二大貢獻，動態決定輸出數。
- Box Head / Mask Head：標準偵測與分割頭。

3. HMSA：階層式多模態語意對齊（核心貢獻一）

HMSA 同時做三個層次的對齊，每層解決不同粒度的語意鴻溝。

3.1 Word-Object Alignment (W2O)：用「Masked Text Recovery」當代理任務

動機：缺少「word ↔ region」的細粒度標註，無法直接監督。作者借鏡 BERT 的 masked language modeling 概念。

做法：1. 從句子裡抽出「實體名詞」(entity noun)，隨機 mask 成 [MASK]。2. 把 masked 句子送 text encoder 得到 $\tilde{T}_w$ 。3. 拿 N 個 object embeddings O_e 與 $\tilde{T}_w$ 透過一個 Transformer layer 重建出 $\hat{T}_w$ 。4. 損失：

$$L_{w2o} = \lambda \cdot (1 - \cos(T_w, \hat{T}_w))$$

- T_w 是原始未 mask 的完整文字特徵；
- $\lambda = 0$ 當 no-target sample (因為視覺與文字毫無對應，硬重建只會干擾訓練)；其他情況 $\lambda = 1$ 。

效果：強迫 object embeddings 學會編碼「能還原 masked 實體詞」的視覺語意 → 達到隱式的 word-object 對齊。

3.2 Phrase-Object Alignment (P2O)：用 Flickr30K Entities 顯式監督

動機：屬性級資訊 (顏色、形狀、姿態等) 對於區分同類物件至關重要。Flickr30K Entities 提供「片語 → 物件框」的顯式標註，可拿來訓練。

做法：1. 從句子抽 M 個 noun phrases，平均池化得 $T_p \in \mathbb{R}^{M \times C_p}$ 。2. 線性投影到同空間： $T'_p = W_1 T_p$ ， $O'_e = W_2 O_e$ 。3. 計算 phrase-query 相似度矩陣：

$$S = \sigma(T'_p \cdot O_e'^T) \in \mathbb{R}^{M \times N}$$

4. 用 bipartite matching (Mask2Former 式) 配 ground-truth box，得到二值對應 $Y \in \{0, 1\}^{M \times N}$ 。5. 損失 (BCE)：

$$L_{p2o} = - \sum_{i,j} Y_{i,j} \log S_{i,j} + (1 - Y_{i,j}) \log(1 - S_{i,j})$$

效果：object embeddings 被推向「能匹配描述片語的屬性表徵」，提升細粒度區辨力。

3.3 Text-Image Alignment (T2I)：全域對比

動機：除了 word/phrase 級，整句與整圖的整體語意也要對齊。

做法：定義 image-text 全域匹配分數

$$S_T(I, T) = \frac{1}{N} \sum_{j=1}^N \sum_{k=1}^K a_{j,k} \langle \hat{o}_j, \hat{w}_k \rangle, \quad a_{j,k} = \frac{\exp \langle \hat{o}_j, \hat{w}_k \rangle}{\sum_l \exp \langle \hat{o}_j, \hat{w}_l \rangle}$$

(沿文字維 normalize；類似地沿影像維可得 $S_I(I, T)$)。

對 batch 內 image-text 對做 InfoNCE 對比，分四個方向計算 (text-anchor / image-anchor × T 維 / I 維 normalize)，總損失：

$$L_{t2i} = L_{T \rightarrow T}^{t2i}(I) + L_{I \rightarrow T}^{t2i}(I) + L_{T \rightarrow I}^{t2i}(T) + L_{I \rightarrow I}^{t2i}(T)$$

效果：全域語意一致性，幫助 no-target 判斷 (整圖根本不匹配)。

3.4 HMSA 總損失

$$L_{align} = L_{w2o} + L_{p2o} + L_{t2i}$$

三層協同 → object queries 從多個粒度 refine，提升 box regression 與 mask segmentation。

4. AGC：自適應 Grounding 計數器（核心貢獻二）

4.1 為什麼需要 AGC

- 閾值法：He et al. (GREC baseline) 對所有候選 box 的 class score 設一個全域閾值，過高漏抓、過低多抓，無法樣本自適應。
- 拆句多輪查詢：對「all kids」這種隱式多目標無能為力。
- 觀察：gRefCOCO 的目標數呈長尾分布，0~3 個目標佔絕大多數，>3 屬少數。

4.2 設計：把「目標數」當分類任務

1. 取 word feature T_w 與 object embeddings O_e ，做 average pooling 再串接：

$$M_g = [\text{AP}(T_w); \text{AP}(O_e)]$$

2. 用 2-layer MLP 預測 5 類標籤：

$$y_c = \text{MLP}(M_g) \in \{0, 1, 2, 3, 3^+\}$$

3. 輸出策略：

- 若 $y_c \in \{0, 1, 2, 3\}$ ：直接取 top- y_c 分數的候選 box。
- 若 $y_c = 3^+$ ：退回閾值法（因為樣本太少，分類不準）。

4.3 對比學習強化計數能力

只靠 batch 內樣本對比，負樣本不夠多 → 引入 MoCo 風格 memory bank M ，存歷史 multi-modal features。

採用 supervised contrastive loss (Khosla 2020)：

$$L_{con} = -\frac{1}{|P(i)|} \sum_{p \in P(i)} \log \frac{\exp(M_g^i \cdot M_g^p / \tau)}{\sum_{a \in A(i)} \exp(M_g^i \cdot M_g^a / \tau)}$$

- $P(i)$ ：與 anchor 同計數的正樣本集合； $A(i)$ ：所有正負樣本。- 把「同計數」拉近、「不同計數」推遠 → 顯式塑造可計數的多模態特徵空間。

AGC 總損失：

$$L_{agc} = L_{cls} + L_{con}$$

4.4 直觀理解

- HMSA 解決「看懂語意」；
- AGC 解決「算清楚幾個」；
- 兩者解耦但互補：HMSA 提供區辨性表徵 → AGC 在這個空間裡分類個數比較容易。

5. 訓練流程

5.1 兩階段

1. Pretrain（聯合）：在 RefCOCO/+g + Flickr30K Entities + gRefCOCO 訓練集合併上訓練：

$$L_{pretrain} = L_{align} + L_{det}$$

$$L_{det} = \lambda_{bbox} L_{bbox} + \lambda_{giou} L_{giou} + \lambda_{class} L_{class}$$

2. Finetune (下游)：對各下游任務分別微調：
 - REC / Phrase Grounding：用 L_{det}
 - RES：加上 $L_{seg} = \lambda_{mask}L_{mask} + \lambda_{dice}L_{dice}$
 - GREC / GRES：再加上 L_{agc}

5.2 細節

- Visual backbone：ResNet-101 / Swin-B
- Text encoder：RoBERTa-base
- Box loss：L1 + GloU + cross-entropy class
- Mask loss：Focal loss + Dice loss

6. 與既有方法的差異對比

維度	傳統 two-stage REC	傳統 one-stage REC	Phrase Grounding	ReLA (GRES)	HieA2G
輸出數	1	1	多 (依片語)	多 (二元判存)	0~多 (顯式計數)
對齊層次	word/region	text-image	phrase-region	region-image	word + phrase + text 三層
no-target 處理	無	無	無	二元分類	AGC=0 類 + T2I 全域對齊
multi-target 處理	不支援	不支援	限名詞片語	全部 candidate 過閾值	AGC 動態選 top-k 或閾值
計數能力	無	無	無	隱式	顯式分類 + supervised contrastive

7. 實驗

7.1 資料集

- gRefCOCO (主場, GREC / GRES)
- RefCOCO / RefCOCO+ / RefCOCOg (REC / RES)
- Flickr30K Entities (Phrase Grounding)

7.2 評估指標

- GREC：Pr@(F1=1, IoU $\geq$ 0.5)、N-acc. (no-target 判定正確率)
- REC：Pr@(IoU $\geq$ 0.5)
- RES：cloU、gIoU
- GRES：cloU、gIoU、N-acc.、T-acc.
- Phrase Grounding：Recall@1/5/10 (ANY-BOX protocol)

7.3 主要結果

Table 1：gRefCOCO (GREC 主戰場)

Method	val Pr / N-acc	testA Pr / N-acc	testB Pr / N-acc
MCN †	28.0 / 30.6	32.3 / 32.0	26.8 / 30.3
VLT †	36.6 / 35.2	40.2 / 34.1	30.2 / 32.5
MDETR †	42.7 / 36.3	50.0 / 34.5	36.5 / 31.0
UNITEXT †	58.2 / 50.6	46.4 / 49.3	42.9 / 48.2
Ferret †	54.8 / 48.9	49.5 / 45.2	43.5 / 43.8
HieA2G (R101)	67.8 / 60.3	66.0 / 60.1	56.5 / 56.0

對比 MLLM-based Ferret (>7B 參數)，HieA2G 用 ResNet-101 backbone 平均 +14.2% Pr@(F1=1)、+9.4% N-acc (vs UNITEXT)。

Table 2：RefCOCO+/g (REC) HieA2G-R101 在所有 split 都超過 MDETR、SeqTR、TransVG++ 等專用 REC 方法，甚至超過 7B 級 MLLM (GSVA-7B、LISA-7B)。

Table 3：Flickr30K Entities (Phrase Grounding) R@1 / R@5 / R@10 全面超 MDETR、Shrika-7B、Ferret-7B。

Table 4：RefCOCO+/g (RES) HieA2G-Swin-B 與 ReLA (同 backbone) 相比有穩定提升，與 GSVA-7B、LISA-7B 競爭。

Table 5：gRefCOCO (GRES) Swin-B backbone 下：- val：cloU 68.4 / gloU 62.8 / N-acc 70.4 - 超過 ReLA、LISA-7B，cloU 與 gloU 也略勝 GSVA-7B。

7.4 Ablation (Table 6)

#	W2O	P2O	T2I	Classifier	L_{con}	Pr	N-acc
1	☒	☒	☒	✓	✓	65.2	54.9
2	☒	✓	✓	✓	✓	67.5	58.1
3	✓	☒	✓	✓	✓	67.1	57.3
4	✓	✓	☒	✓	✓	67.0	56.4
5	✓	✓	✓	☒	☒	53.9	48.0
6	✓	✓	✓	✓	☒	66.5	57.3
7	✓	✓	✓	✓	✓	67.8	60.3

讀法：- 拿掉整個 HMSA (#1 vs #7)：Pr -2.6, N-acc -5.4 - 拿掉任一單層對齊 (#2/#3/#4 vs #7)：都退步，證明三層互補 - 拿掉整個 AGC 改回閾值法 (#5 vs #7)：Pr -13.9, N-acc -12.3 → AGC 是巨大關鍵 - 加 classifier 不加 contrastive (#6 vs #7)：Pr -1.3, N-acc -3.0 → L_{con} 提升計數穩定性

7.5 定性分析

成功案例：- 多目標：「two airplanes」精準算對 2 個；「the 2nd bus」能辨識序數。- no-target：「the board in man hand」（圖中沒這東西）能正確拒答。

失敗案例：- 視覺線索模糊：難以分辨所有目標、誤判 no-target。- 關鍵物件被遮擋：漏抓或誤抓。

8. 關鍵洞見與貢獻總結

1. 「對齊不該是單層」：作者明確主張 REC/GREC 過去靠單一層次對齊 (word-object 或 text-image)，對 GREC 這種需要同時做精細區辨 + 全域拒答的任務不夠用，三層次階層對齊才是正解。
 2. 「計數能力應顯式建模」：把目標數當分類問題，加 supervised contrastive 顯式塑造特徵空間，比閾值法穩健太多 (ablation 顯示這是最大貢獻來源)。
 3. 「Masked Text Recovery 是巧妙代理任務」：在缺乏 word-region 標註下，用文字重建作為自監督，幾乎不增加成本就獲得 word-object 對齊。
 4. 「無視 no-target 樣本的不一致性」：在 L_{w2o} 設 $\lambda = 0$ 處理 no-target，避免硬重建反而干擾收斂——細節上很體貼。
 5. 泛化性強：同一架構橫掃 5 個任務 (GREC、REC、Phrase Grounding、RES、GRES)，不是只在 GREC 過擬合。
-

9. 與相關論文的关系

9.1 vs. COPS-Ref (Compositional Phrase Grounding)

- COPS-Ref (CVPR 2020 系列) 強調 composition：把表達式拆成可組合的「主體 + 屬性 + 關係」三元組，再做 modular reasoning。
- HieA2G 不顯式做組合推理，而是用三層對齊把細到粗的語意統統壓進 object embedding。
- 兩者對「屬性區辨」都很重視，但路徑不同：COPS-Ref 走 modular network；HieA2G 走 alignment+contrastive。
- HieA2G 的 P2O alignment 其實隱式達到了 COPS-Ref 想要的「屬性匹配」效果。

9.2 vs. GREC (He et al. 2023, baseline benchmark)

- GREC paper 本身是定義任務、提出 baseline (用閾值濾候選 box)；它把 MDETR/UNITER 等改成多輸出版本。
- HieA2G 是首批在 gRefCOCO 上做 GREC 的專用方法之一，把 baseline 的閾值法升級成 AGC 分類 + 對比學習。
- ablation Table 6 第 5 row 直接量化「換掉閾值法的代價」：-13.9 Pr / -12.3 N-acc。

9.3 vs. Modeling Relationships in Referential Expressions (Hu et al. 2017, CMN)

- CMN (Compositional Modular Networks)：早期 REC 經典，把表達式拆成 (subject, relationship, object) 三模組，分別在影像上做 attention。
- 與 HieA2G 對比：
 - CMN 顯式建模 relationship；HieA2G 沒有顯式關係模組，但 phrase-object alignment 隱式抓到「修飾關係」。
 - CMN 是 two-stage 架構 (先有 proposal 再選)，HieA2G 是 DETR-like one-stage (learnable queries)。
 - HieA2G 在多目標、no-target 上完勝 CMN (CMN 沒這設計)。

9.4 對 selective grounding 研究的啟示 (個人觀點)

對於你正在做的 post-hoc reliability / calibration 研究：

- HieA2G 的 AGC 分類器等於把「該輸出幾個」做成一個可學習的、可校準的模組，比 ReLA 的二元判定更接近「概率化拒答」。
- 它與你的 CRS (Conformal Referring Set) 思路有對話空間：
 - HieA2G 用「分類 + contrastive」軟性決定 cardinality；
 - CRS 用「conformal LTT」硬性保證 risk。
 - 兩條路其實互補：AGC 可以當 score function，CRS 在它的輸出上加 conformal 包裝以獲得分布無關的保證。

- 對你的 N-acc / T-acc 量測：HieA2G 在 N-acc 推到 60 左右，但 T-acc 提升幅度沒講得很明確 (gRefCOCO 仍有 multi-target T-acc 天花板問題，這跟你 M4 評估上限觀察一致)。

10. 個人評價

10.1 優點

- 方法清晰、貢獻可獨立 ablation：HMSA 三層 + AGC 兩元件每塊都有對應 ablation row。
- 不用 7B+ MLLM：用 ResNet-101 + RoBERTa-base 就贏過 Ferret-7B、GSVA-7B 這類大模型，參數效率高。
- 泛化性強：5 個任務通吃，不像許多 GREC 方法只在 gRefCOCO 上炫技。
- AGC 是被低估的真正主角：ablation 顯示其貢獻 > HMSA。
- 細節品質高：no-target 樣本特別處理 ($\lambda = 0$)、memory bank 增加負樣本、 3^+ 退回閾值——都顯示作者了解任務細節。

10.2 限制與缺點

- 計數類別硬切 5 類 (0/1/2/3/3+)：對於 >3 的多目標仍依賴閾值，沒有徹底解決長尾。實務上 >3 的訓練樣本少，分類退化是必然，但這也是潛在改進點。
- 缺乏不確定性量化 / 校準分析：論文只報 $\text{Pr}@(\text{F1}=1)$ 與 N-acc，沒有提供 reliability diagram、ECE、coverage 等校準指標。對你的研究而言這是一個明顯的「沒做」的縫隙。
- 對 occlusion / ambiguous case 沒設計專屬機制：失敗案例自己揭露了這兩種，但方法層沒對應對策。
- HMSA 的 W2O 太依賴 entity noun 抽取品質：用 spaCy/NLTK 抽 noun 會把抽象詞、複合名詞處理不好，論文沒分析這層失敗。
- Phrase-Object alignment 強依賴 Flickr30K Entities：對沒有此類標註的資料集（如純 RefCOCOg）這一支訓不到，泛化到其他 domain 時 P2O 等於關掉。
- 沒做 efficiency 比較：N=N queries、memory bank、三層對齊都增加訓練開銷，論文沒給 FLOPs / latency。
- AGC 的 3^+ 邊界值靠工程拍腦袋：缺少 hyperparameter sensitivity 分析。

10.3 後續可探方向

1. 連續性計數：把 AGC 從分類改成回歸或 Poisson regression，配 quantile head，更平滑且能延伸到 >3。
2. conformal wrapping：對 AGC + box selection 整體做 split conformal 或 LTT，提供 PAC 級的覆蓋保證（這就直接走向你的 CRS 路線）。
3. 更強的 no-target 機制：用 OOD detection（如 score entropy、energy-based）強化 N-acc，不只靠 AGC 0 類。
4. 多語言 / open-vocabulary 擴展：把 text encoder 換 CLIP-text、把 visual encoder 換 OWL-ViT，看是否仍 work。
5. 與 LLM agent 結合：把 HieA2G 包成工具，讓 LLM 在 visual reasoning 鏈條中呼叫，處理複雜 instruction following。

11. 一頁速記（給趕時間的人）

- 誰：Yaxian Wang 等，AAAI 2025，arXiv 2501.01416。
- 要解決什麼：GREC——文字表達式對應 0、1、多個目標的視覺接地。
- 怎麼做：
 1. HMSA：三層對齊（word-object 用 masked text recovery；phrase-object 用 BCE 監督；text-image 用對比學習）。

2. AGC：把「該輸出幾個」當 5 類分類，加 memory-bank supervised contrastive 拉開不同計數的特徵。
- 成果：gRefCOCO Pr@(F1=1) 上 testA/testB 平均比 SOTA 提 14%，5 個任務全 SOTA 或競爭力，用 R101 backbone 贏 7B MLLM。
 - 真正的英雄：AGC（ablation 顯示移除損失最大）。
 - 沒做的事：校準 / 不確定性 / efficiency / >3 長尾。
 - 與你的研究關係：AGC 是一個天然可被 conformal calibration 包裝的 score function；可以作為 CRS 的另一條 base 線實驗。
-