

# MAttNet: Modular Attention Network for REC

## 詳細導讀

整理：kuo

2026-06-19

## MAttNet: Modular Attention Network for Referring Expression Comprehension ( 詳細導讀 )

### 0. 論文基本資訊

- 論文標題：MAttNet: Modular Attention Network for Referring Expression Comprehension
- 作者：Licheng Yu, Zhe Lin, Xiaohui Shen, Jimei Yang, Xin Lu, Mohit Bansal, Tamara L. Berg
- 單位：UNC Chapel Hill、Adobe Research
- 發表會議：CVPR 2018
- arXiv：1801.08186v3 ( v3 提交於 2018-03-27 )
- Code：https://github.com/lichengunc/MAttNet ( 另有 Mask R-CNN 實作 https://github.com/lichengunc/mask-faster-rcnn )
- Demo：vision2.cs.unc.edu/refer/comprehension
- 任務範疇：Referring Expression Comprehension ( REC · box-level ) + Referential Segmentation ( pixel-level )

註：本文是 modular REC 研究線的代表性後繼。前傳是 Hu et al. *Modeling Relationships in Referential Expressions* ( CVPR 2016 · 本目錄 modeling-relationships-summary.md ) 與 *Compositional Modular Networks* ( CVPR 2017 )。MAttNet 把「Subj/Loc/Rel 三模組 + 語言解析」全面升級成可端到端學習的 attention 版本，成為其後多年 REC 的強 baseline。

---

### 1. 問題定義與動機

#### 1.1 任務

給定影像  $I$ 、一組候選物件  $O = \{o_i\}_{i=1}^N$  ( proposal 或 GT box )、一段 referring expression  $r$ ，從  $O$  中挑出  $r$  所指的物件。本質是 language-conditioned region selection。

## 1.2 動機：兩個既有缺陷

1. 「一鍋燴」特徵 + 單一 LSTM：先前主流 ( Speaker/Listener/Reinforcer、visdif 等 ) 把 target 外觀、位置、context 特徵直接 concat，用單一 LSTM 編碼整句，忽略不同 **referring expression** 強調的資訊型態不同。論文舉例：同一顆紅球，在黑球堆裡只需說 “red ball”；在紅球堆裡要說 “red ball on the right”；在 100 顆紅球裡要說 “red ball next to the cat” ——不同情境該觸發不同的視覺處理模組。
2. 外接 language parser 會傳遞錯誤：早期 modular network ( NMN、CMN ) 靠 off-the-shelf parser 把句子拆成元件再組裝模組，parser 的解析錯誤會直接污染模型。

## 1.3 三大新穎點 ( 作者自陳 )

1. 為「通用」referring expression 設計的三模組：subject ( 類別/顏色/屬性 )、location ( 絕對 + 相對位置 )、relationship ( 與其他物件的關係 )，涵蓋 Yu et al. 2016 定義的 7 種 referring attribute。各模組在自己的參數空間學習、互不干擾。
2. soft attention 學會「解析」句子，取代外接 parser：對句子自動算出每個詞屬於哪個模組 ( word attention ) + 每個模組該貢獻多少 ( module weight )。
3. subject/relationship 模組各用不同視覺 attention：subject 用 “in-box” soft attention ( 句子提到 “man in red shirt” → 注意框內紅色衣物區 )；relationship 用 “out-of-box” hard attention ( “cat on chair” → 注意框外的 chair 來定位 cat )。

訓練只用 (o\_i, r\_i) 配對監督，word attention / module weight / spatial attention / relative-object attention 全部端到端弱監督學成。

## 2. 方法架構

模型 = 語言注意力網路 + 三個視覺模組 ( subject / location / relationship )，最後加權合成總分。

### 2.1 語言注意力網路 ( Language Attention Network )

- 詞 embedding → 雙向 LSTM，每個詞的表示  $h_t = [\rightarrow h_t, \leftarrow h_t]$ 。
- 三個可訓練向量  $f_m (m \in \{\text{subj}, \text{loc}, \text{rel}\})$  對所有詞算 attention： $a_{\{m,t\}} = \text{softmax}_t(f_m^T h_t)$ ，模組片語 embedding  $q_m = \sum_t a_{\{m,t\}} e_t$ 。
- 模組權重：concat 首尾 hidden  $[h_0, h_T]$  過 FC + softmax →  $[w_{\text{subj}}, w_{\text{loc}}, w_{\text{rel}}]$ 。
- 對比 *Modeling Relationships* ( CMN ) 固定 (Subject, Preposition/Verb, Object) 三元結構：MAttNet 不假設固定句法模板，故能處理 “smiling boy” ( 只有 subj )、 “man on left” ( subj+loc )、 “cat on the chair” ( subj+rel ) 等各種變體。

### 2.2 視覺骨幹

- **Faster R-CNN ( ResNet-101 )** 當 backbone。對每個 o\_i 取 C3 feature ( 低階：顏色/形狀，利於 proposal 判斷 ) 與 C4 feature ( 高階：類別語意 )。兩者都用。
- 與多數前作只用單張 region CNN feature 不同，這裡用偵測器骨幹更原則化也更快。

## 2.3 Subject Module

兩個子任務：

1. 屬性預測分支 ( **Attribute Prediction** ) : concat C3+C4  $\rightarrow$  1 $\times$ 1 conv  $\rightarrow$  avg pool  $\rightarrow$  multi-attribute 分類 ( binary cross-entropy · 類別權重  $w_j = 1/\sqrt{\text{freq}}$  緩解不平衡 ) 。屬性標籤用 template parser 從訓練句抽 color/generic word ( 取最常用 50 個 ) 。只有含屬性詞的句子走這分支。
2. 片語引導的注意力池化 ( **Phrase-guided Attentional Pooling** · “in-box” ) : 把 attribute blob 與 C4 融成 subject blob ( 14 $\times$ 14 grid ) · 用  $q_{\text{subj}}$  算 grid 上 spatial attention · 加權求和成  $v_i^{\text{subj}}$  。

匹配函式  $S(o_i|q_{\text{subj}}) = F(v_i^{\text{subj}}, q_{\text{subj}})$  : 兩條 MLP + L2 normalize · 內積算相似度。同一匹配函式也用於 loc / rel 分數。

## 2.4 Location Module

- 絕對位置 5 維 :  $[x_{\text{tl}}/W, y_{\text{tl}}/H, x_{\text{br}}/W, y_{\text{br}}/H, w\cdot h/W\cdot H]$  ( RefCOCO 41%、RefCOCOg 36% 句子含絕對位置詞 ) 。
- 相對位置 ( “dog in the middle”、 “second left person” ) : 取同類別最多 5 個鄰居 · 算 offset 與面積比  $l_{ij}$  。
- 合成  $l_i^{\text{loc}} = W_l[l_i; l_{ij}] + b_l$  · 分數  $S(o_i|q_{\text{loc}}) = F(l_i^{\text{loc}}, q_{\text{loc}})$  。

## 2.5 Relationship Module ( “out-of-box” )

- 對候選  $o_i$  取周圍 ( 最多 5 個 · 不分類別 ) 支援物件  $o_{ij}$  · 用其 avg-pooled C4 當外觀  $v_{ij}$  · 加上相對 offset  $m_{ij}$  。
- $v_{ij}^{\text{rel}} = W_r[v_{ij}; m_{ij}] + b_r$  · 對每個鄰居算分取最大 :  $S(o_i|q_{\text{rel}}) = \max_{\{j\}} F(v_{ij}^{\text{rel}}, q_{\text{rel}})$  。
- 取 max 等價於弱監督的 Multiple Instance Learning ( MIL ) 。

## 2.6 損失函式

總分 ( hard attention 由 module weight 體現 ) :

$$S(o_i|r) = w_{\text{subj}}S(o_i|q_{\text{subj}}) + w_{\text{loc}}S(o_i|q_{\text{loc}}) + w_{\text{rel}}S(o_i|q_{\text{rel}})$$

每個正例 (  $o_i, r_i$  ) 取兩個負例 ( 同物件配別句  $r_j$ 、同句配別物件  $o_k$  ) · combined hinge / ranking loss :

$$L_{\text{rank}} = \sum_i [\_1 \max(0, \Delta + S(o_i|r_j) - S(o_i|r_i)) + \_2 \max(0, \Delta + S(o_k|r_i) - S(o_i|r_i))]$$

總損失  $L = L_{\text{subj}}^{\text{attr}} + L_{\text{rank}}$  。

### 3. 實驗

#### 3.1 數據集

RefCOCO、RefCOCO+、RefCOCOg (皆建於 MS COCO)。

- RefCOCO / RefCOCO+：互動式遊戲收集，句短 (平均 3.5 詞)、同類物件多 (平均 3.9)。RefCOCO+ 禁用絕對位置詞，逼模型靠外觀。
- RefCOCOg：非互動收集，句長 (平均 8.4 詞)、關係描述多、同類物件少 (1.63)。
- RefCOCO/RefCOCO+ 測試分 testA (多人) / testB (多物)。
- 評估：IoU > 0.5 為正確。

#### 3.2 GT box 下的主結果 (Table 1 · res101-frcn 全模型)

| Split                     | RefCOCO<br>testA | RefCOCO<br>testB | RefCOCO+<br>testA | RefCOCO+<br>testB | RefCOCOg<br>val | RefCOCOg<br>test |
|---------------------------|------------------|------------------|-------------------|-------------------|-----------------|------------------|
| <b>MAttNet<br/>(full)</b> | <b>85.26</b>     | <b>84.57</b>     | <b>75.13</b>      | <b>66.17</b>      | <b>78.10</b>    | <b>78.12</b>     |

相較前 SOTA (Speaker+Listener+Reinforcer) 在 bbox localization 上有約 10% 的提升；vgg16 版 (Line 9, testA 79.99) 已勝所有 vgg16 前作。

#### 3.3 模組 ablation (Table 2 · res101-frcn · GT box)

| 配置                                                 | RefCOCO testA | RefCOCO+ testA | RefCOCOg test |
|----------------------------------------------------|---------------|----------------|---------------|
| Matching:<br>subj+loc<br>(baseline · concat<br>特徵) | 79.42         | 62.71          | 70.92         |
| MAttN: subj+loc                                    | 80.20         | 64.20          | 72.62         |
| + loc(+dif) (相對位置)                                 | 81.28         | 65.77          | 74.46         |
| + rel (關係模組)                                       | 81.58         | 66.59          | 74.56         |
| + attr (屬性分支)                                      | 82.66         | 69.93          | 75.92         |
| + attn (片語引導注意力池化)                                 | <b>85.26</b>  | <b>75.13</b>   | <b>78.12</b>  |
| parser+MAttN (用<br>template parser 取代學到的解析)        | 79.10         | 62.94          | 73.72         |

關鍵讀法：1. 每個模組逐步加分，乾淨可加性 ablation。2. 片語引導注意力池化在 **person 類 (testA)** 增益最大 (RefCOCO+ 69.93→75.13)，印證 “in-box” attention 對「girl with red hat」這類框內細節有用。3. 學到的 **soft attention** 解析 > 外接 **parser** 約 5% (RefCOCOg val 78.10 vs 73.82)，證成「不用外接 parser」的設計選擇。

### 3.4 全自動偵測 ( Table 3 )

換成 Faster R-CNN / Mask R-CNN 自動偵測 **proposal** ( 非 GT box ) 後，分數下降但各模組增益順序與 **GT box** 一致 ( 穩健 )，且全面勝過前 SOTA。Mask R-CNN 偵測分支 ( res101-mrcn ) 甚至優於 Faster R-CNN ( 多任務訓練帶來更高 AP )。RefCOCO testA 全自動 80.43–81.14。

### 3.5 Referential Segmentation ( Table 4 )

不另訓 FCN，而是解耦：MAttNet 選出最佳 box → 餵 Mask R-CNN mask 分支出 pixel mask。在 RefCOCO/RefCOCO+ 上 Pr@0.5 與 IoU 大幅勝過前 SOTA ( D+RMI+DCRF )，例如 RefCOCO val IoU 45.18→56.51、Pr@0.5 約翻倍。附錄甚至顯示 **MAttNet+GrabCut** ( 劣等分割法 ) 都還勝過前 SOTA → 論證「box 定位與分割解耦」優於 FCN 式前景/背景分類。

### 3.6 效率 ( 附錄 )

全自動推論平均 0.33 s/張：Mask R-CNN 0.31 s + MAttNet 僅 0.02 s。訓練約半天 ( 單張 Titan-X )。

---

## 4. 關鍵洞見與貢獻

1. 可端到端學的 **modular attention**：把 Subj/Loc/Rel 從「外接 parser 拼裝」升級成「soft word attention + module weight 自動解析」，且勝過 parser。
2. **雙視覺 attention**：subject in-box ( 框內細節 ) + relationship out-of-box ( 框外支援物件 )，各司其職。
3. 屬性預測輔助分支：明確處理 “woman in red” 這類屬性區分。
4. **box 定位與分割解耦**：對 instance-level referential segmentation 比 FCN 式分類更優。
5. 多年強 **baseline**：RefCOCO+/g 三庫 SOTA，成為後續 REC 的標準對照。

---

## 5. 限制 ( 以 2026 年眼光 )

1. **single-target** 假設：最終 argmax 只挑一個 region，無法處理 **no-target / multi-target**——與 GREC/gRefCOCO 設定不相容 ( 需外接 abstention/set-prediction head )。
2. **task-specific supervised**：需在 RefCOCO 系列 fine-tune，非 frozen / zero-shot；對比 CLIP/OWL-ViT/GroundingDINO 內建跨模態對齊已過時。
3. 無 **calibration** / 無可靠性分析：合成分數只用來 argmax，沒有覆蓋率、棄答、信賴度保證——正是 selective grounding / CRS 主線要補的洞。
4. 依賴鄰居枚舉：location 相對位置與 relationship 模組都要枚舉周圍物件，大場景下成本高。
5. 關係語意有限：spatial offset 抓得到左右/上下/距離，semantic relation ( holding、belonging ) 仍弱。

---

## 6. 對使用者主線 ( selective grounding / CRS ) 的對位與借鏡

主線見記憶 [[crs-pivot-conformal-referring-set]] / [[crs-litreview-15papers]] ; 本目錄索引 reading-log.md。

1. **SOTA 雙區塊表的「Trained」代表** : MAttNet 是經典 trained REC , 恰好放進 reading-log 規劃的「雙區塊 + Guarantee? 欄」——MAttNet 標 **Guarantee** □ ( **point estimate** 、無分布無關保證 ) 對照 Frozen CRS 標 □ 。它的高絕對分數 ( 如 testA 85.26 ) 正可用來說明「高準確率 ≠ 有限樣本保證」的 framing 守則。
2. **factorization ablation 範式** : MAttNet 的 subj→loc→rel→attr 逐步加法 ablation , 是 CRS 2×2 ( OWL gate × GD box ) factorization ablation 的可對照前例 ; 差別在 CRS 證的是「跨兩異質 frozen base 分工非 ensemble」, MAttNet 是「同模型內模組可加性」。
3. **module weight 概念可借** : MAttNet 用 module weight 動態決定各模組貢獻——CRS 在 multi-target referring set 內部一致性評分時 , 可借 attention-aggregation 思路聚合候選集分數。
4. **解耦 box/segmentation 的精神** : MAttNet「先定位 box 再交 mask 分支」與 CRS「OWL gate 控可用性/棄答、GD box 控集合緊緻」的分工哲學相通——都把單一複雜任務拆成各自最擅長的凍結元件。
5. **Related Work 定位** : MAttNet 與 *Modeling Relationships* ( explicit relational REC 起點 )、Cops-Ref ( bias-control benchmark )、GREC ( 任務泛化 )、Zero-Shot True/False Verification ( 新威脅 ) 並列 , 鋪陳「REC 從 modular-supervised → frozen/zero-shot → 需要可靠性保證」的十年演進弧線 , 襯托 CRS 補上的「分布無關 recall+abstention 雙保證」這一空缺。

引用優先級 : 中 ( REC modular 經典/強 baseline , SOTA 對照表與演進敘事用 ; 非 CRS 直接競品 , 無切割壓力 )。

---

## 7. 一句話總結

MAttNet 是 2018 年把 modular REC 推到可端到端學習的代表作 : 用語言 soft attention 自動把句子解析成 subject/location/relationship 三模組 ( 取代外接 parser ) , 各模組配專屬視覺 attention ( in-box 看框內細節、out-of-box 看框外關係 ) , 在 RefCOCO+/g 三庫 box 與 pixel 兩層級都大幅刷新 SOTA , 成為其後多年 REC 的標準強 baseline——但它 single-target、需訓練、無 calibration , 正好是 selective grounding / CRS 主線要超越的「高準確率卻無保證」對照組。

---

## 8. 參考連結

- arXiv : <https://arxiv.org/abs/1801.08186>
- Code : <https://github.com/lichengunc/MAttNet>

- Mask R-CNN 實作 : <https://github.com/lichengunc/mask-faster-rcnn>
- 前傳 CVPR 2016 : *Modeling Relationships in Referential Expressions* <https://arxiv.org/abs/1607.07702>
- 前傳 CVPR 2017 : *Compositional Modular Networks* <https://arxiv.org/abs/1611.09978>