

Modeling Relationships in Referential Expressions 詳細導讀

整理：kuo

2026-06-18

Modeling Relationships in Referential Expressions (詳細導讀)

0. 論文基本資訊

- 論文標題：Modeling Relationships in Referential Expressions
- 作者：Ronghang Hu, Marcus Rohrbach, Jacob Andreas, Trevor Darrell, Kate Saenko
- 單位：UC Berkeley (EECS / ICSI)、Boston University
- 發表會議：CVPR 2016 (IEEE Conference on Computer Vision and Pattern Recognition)
- arXiv：1607.07702 (提交於 2016-07-26)
- CVF Open Access：https://openaccess.thecvf.com/content_cvpr2016/html/Hu_Modeling_Relationships_in_CVPR_2016_paper.html
- Code：https://github.com/ronghanghu/text_obj_retrieval
- Project page：https://ronghanghu.com/text_obj_retrieval/
- 任務範疇：Referring Expression Comprehension (REC · 指稱表達理解)

註：作者群同年另有一篇 Natural Language Object Retrieval (arXiv 1511.04164, CVPR 2016)，那篇是「SCRC (Spatial Context Recurrent ConvNet)」；本篇則是其後續，重點放在「物件之間的關係」建模。隔年 (CVPR 2017) 他們再延伸成 Compositional Modular Networks (arXiv 1611.09978)。三篇是同一條研究線。

1. 問題定義與動機

1.1 任務：Referring Expression Comprehension (REC)

給定：

- 一張影像 I
- 一段自然語言描述 s (例如 “the man next to the woman in red”)

模型要從影像中一群候選 bounding box $\{r_1, r_2, \dots, r_N\}$ 中，挑出 s 所指的那一個物件。本質上是 **language-conditioned object selection**，是 grounding/visual reasoning 的核心子任務之一。

1.2 動機：既有方法把 referred object 「孤立」處理

CVPR 2016 之前主流的 REC 方法 (Mao et al. 2016 的 MMI、Neg Bag、Neg+MMI；Hu et al. 的 SCRC) 有一個共同的盲點：

它們只看「被指物件本身」的外觀 + 位置，沒有顯式建模「它跟其他物件的關係」。

但人類描述物件時，關係性描述非常普遍：

- "the cat **on** the chair"
- "the man **next to** the woman in red"
- "the cup **between** two books"

這些描述如果只看被指物件本身的 CNN feature，會出現兩個問題：

1. 同類物件多時無法區分：場景裡有 5 隻貓，光看貓的外觀區分不開，必須借助「在椅子上」這個關係。
2. 語言中關係名詞被浪費：模型可能完全忽略 "on"，"next to" 這些 prepositional phrase 的資訊。

1.3 本文的主張

作者主張顯式地把 (subject, relationship, object) 三元組的表徵融合進 REC 模型中，並進一步擴充到「同時考慮多個 context object」的情境。實驗顯示，加入關係建模能在 Google-Ref (RefCOCOg) 上把 P@1 從 0.247 (Neg+MMI SOTA) 幾乎翻倍到 **0.493**。

2. 方法架構

整體模型可以拆成 **四個 scoring module**，每個 module 對 candidate region r_i 算一個分數，最後加總得到該 region 是 referred object 的總分。模型的輸出是 $\text{argmax}_i \text{score}(r_i | S, I)$ 。

四個 module 對應論文的 ablation 順序：

縮寫	Module	訊號來源
Subj	Subject module	候選 region 的 CNN 外觀特徵
Loc	Location module	region 的歸一化空間座標 / 面積
Rel	Relationship module	(subject, context object, spatial encoding) 三元組
Dist	Distance / context-distillation module	將多個 context object 的關係資訊聚合

語言端則用一個 **LSTM** 編碼 referring expression s ，並用 **soft attention** 把不同詞分派到不同 module (subject 詞用於 Subj，關係詞用於 Rel，方位詞用於 Loc 等)。

2.1 視覺與語言基本元件

- 影像 backbone：VGG-16，在每個 candidate region 上 RoI-pool 出 $fc7$ (4096 維) feature v_i 。
- 候選 region：使用 **ground-truth bounding box** 作為 candidate (評估時所有方法統一條件，避免被 detector recall 拉低)。
- 語言編碼：將 expression token 用 word embedding 後丟進 **LSTM**，得到每個 timestep 的 hidden state h_t 。
- 語言注意力：對 LSTM 隱狀態做 attention，產生四個 module 各自吃的「語言上下文向量」 q_{subj} ， q_{loc} ， q_{rel} 。
 - 直覺："the man next to the woman in red"
 - * "man" → 偏向 subject module
 - * "next to" → 偏向 relationship module
 - * "in red" 描述 context object 的外觀 → 進 Rel module 的 object 端
 - * 沒有強烈方位詞 → loc 權重小

2.2 Subject Module (Subj)

- 輸入：候選 region 外觀 v_i 、語言查詢 q_{subj}
- 透過 MLP 把兩者投影到共同空間後算內積 (或 cosine)，得到 subject-only 分數 $s_{\text{subj}}(r_i)$ 。

- 等價於一個 image-text matching 的基線。

2.3 Location Module (Loc)

- 輸入：region 的 5 維幾何特徵 $[x_{\min}/W, y_{\min}/H, x_{\max}/W, y_{\max}/H, \text{area}/W \cdot H]$
- 加上 region 相對於其他 region 的位置差異 (可選) · 透過 MLP 與 q_{loc} 結合
- 解決 “the leftmost girl”、“the small cup” 這類純位置 / 尺寸描述

2.4 Relationship Module (Rel) — 本文核心

對每個候選 subject region r_i · 與場景中其他 region r_j (context object) 配對：

1. **subject 端**： v_i (外觀)
2. **object 端**： v_j (外觀)
3. **spatial encoding**：兩個 box 的相對幾何 (中心距離、相對大小、方向 angle、IoU) · 編碼成 visual spatial vector $p_{\{ij\}}$
4. **fusion**： $f_{\{ij\}} = \text{MLP}([v_i, v_j, p_{\{ij\}}])$
5. **語言對齊**：用 q_{rel} 對 $f_{\{ij\}}$ 算分數 $s_{\text{rel}}(r_i, r_j)$

→ 對應 SVO (subject-verb-object) 的三元組表徵 · 這是論文標題「modeling relationships」的核心構件。

2.5 Distance / Multi-context Module (Dist)

單一最強 context object 不夠 (例如 “the cup between two books” 同時需要兩本書) · Dist module 的做法是：

- 對每個 candidate subject r_i · 跟所有其他 region r_j 都算 $s_{\text{rel}}(r_i, r_j)$
- 用 **soft-max attention / weighted aggregation** 把所有 context 的關係分數聚合成一個值
- 也可看成「distillation」：把整個 scene 對該 subject 的關係證據濃縮成一個 scalar

公式上類似：

$$s_{\text{rel}}^{\text{agg}}(r_i) = \sum_{j \neq i} \alpha_{ij} \cdot s_{\text{rel}}(r_i, r_j)$$

其中 α_{ij} 是 context object 的注意力權重 · 可由語言或視覺幾何條件決定。

2.6 總分

$$\text{score}(r_i | S, I) = s_{\text{subj}} + s_{\text{loc}} + s_{\text{rel}}^{\text{agg}}$$

並以 **softmax over candidates** 訓練 (讓 ground-truth region 的分數高過其他)：

$$\mathcal{L} = -\log \frac{\exp(\text{score}(r_{\text{gt}}))}{\sum_i \exp(\text{score}(r_i))}$$

這是 MMI (Maximum Mutual Information · 正例與其他 box 對比) 的精神 · 但施加在更豐富的特徵上。

3. 實驗設定

3.1 數據集：Google-Ref (後來叫 RefCOCOg)

- 由 Mao et al. 2016 提出
- 規模：104,560 referring expressions / 54,822 objects / 26,711 images
- 來源：MSCOCO 影像 + Mechanical Turk 人工撰寫的長描述
- 特色：句子普遍較長、含較多關係描述 (適合測試本文方法)

3.2 評估指標

- **Top-1 Precision (P@1)** on validation split
- 在 ground-truth box 候選下，模型 argmax 是否落在 gt region

3.3 比較基線

- **MMI** (Mao et al. 2016)：純 LSTM-based, 用 expression likelihood 排序 region
- **Neg Bag**：用負例強化的版本
- **Neg+MMI**：兩者合體，CVPR 2016 當時的 SOTA
- 本文自己的 ablation 也作為 baseline 排比

4. 主要結果

4.1 Google-Ref 驗證集 P@1

Method	P@1
MMI (Mao et al., 2016)	0.2336
Neg Bag (Mao et al., 2016)	0.2342
Neg+MMI (Mao et al., 2016)	0.2468
Naïve (Ours)	0.3491
Subj (Ours)	0.4170
Subj + Loc (Ours)	0.4488
Subj + Loc + Rel (Ours)	0.4731
Subj + Loc + Rel + Dist (Ours)	0.4932

4.2 解讀

1. **Naïve > Neg+MMI (0.349 vs 0.247)**：光是把模型從「生成式 likelihood」改成「discriminative softmax over candidates」就已經大躍進；說明訓練 objective 換成直接比候選 region 的 discriminative loss 是重要的設計選擇。
2. **Loc 加 +3.2%**：證明 location 不是被 CNN feature 「順便編碼」進去，加進來有獨立貢獻。
3. **Rel 再加 +2.4%**：核心貢獻—顯式關係建模真的有用。
4. **Dist (多 context 聚合) 再加 +2.0%**：說明「只看一個最強 context 不夠」，多 object 聚合對長描述有幫助。
5. **整體相對前 SOTA 提升約 100% (0.247 → 0.493)**。

4.3 Ablation & 分析

論文中還有以下分析 (依文中與 project page 的圖表)：

- **依描述類型分組**：含明顯關係詞 (“next to” , “on” , “with”) 的子集，Rel module 帶來的 gain 更大。

- **context object 個數 vs P@1**：場景中物件越多時，Dist module 相對 Rel-single 的優勢越大（聚合多個 context）。
 - **attention 視覺化**：定性圖顯示語言 attention 確實會把 “next to” 一類詞投放到 Rel module、把 “man” / “cup” 等實體詞投放到 Subj。
 - **失敗案例**：1) 關係詞模糊（“near”）時候選 context 太多會稀釋；2) 同類物件密集（如人群）時細粒度外觀仍不足。
-

5. 關鍵洞見與貢獻

5.1 貢獻清單

1. **顯式關係建模**：首次把 (subject, relation, object) 三元組整進 REC 的 deep model 中，而不是把關係詞當作 LSTM 內隱信號。
2. **多 context 聚合 (Dist module)**：把 REC 從「只看一個最佳 context」拓展到「整個 scene 的證據聚合」。
3. **soft attention 把語言分派到 module**：本質上是 modular reasoning 的雛形，預告了後來 Compositional Modular Networks (CVPR 2017)。
4. **discriminative training over candidates**：把訓練 loss 從「expression generation likelihood」改成「region softmax」，本身就是強 baseline。
5. **在 Google-Ref/RefCOCOg 上把 SOTA 從 0.247 推到 0.493**：是 2016 年該 benchmark 的標竿結果。

5.2 對後續研究的啟發

- **modular networks**：Hu 等人隔年 (CVPR 2017) 直接把這套 Subj/Loc/Rel 升級成 Compositional Modular Networks，把 module 連接結構也用 language parser 決定。
 - **graph-based grounding**：後續一系列 Scene Graph + REC 方法 (MAttNet、DGA、CMRIN、LGRAN 等) 都建立在「relationship matters」這個認識上。
 - **MAttNet (CVPR 2018)**：直接把 Subj / Loc / Rel 升級成 Modular Attention Network，是這條線最有代表性的後繼，許多年內仍是 REC 的強 baseline。
-

6. 與其他參考論文的關係

使用者目錄下另有四篇相關論文，逐一比較：

6.1 Cops-Ref (CVPR 2020)

- **任務**：構造一個「需要 compositional reasoning」的 REC benchmark；強迫模型真的用到關係，而不是靠 dataset bias。
- **與本文關係**：Cops-Ref 是「評測層」的後繼——本文證明 Rel module 在 RefCOCOg 上有效，Cops-Ref 則挑出 RefCOCO 系列裡 bias-prone 的部分、構造對抗性 distractor，逼模型不能只靠 Subj。如果說本文是「給模型加上關係建模能力」，Cops-Ref 就是「設計題目專門測這個能力是否真的有用」。

6.2 GREC (Generalized REC, 2023+)

- **任務**：把 REC 從「假設恰好一個答案」放寬為「可能 zero / one / multiple」，即 **multi-target** 與 **no-target**。
- **與本文關係**：本文模型架構預設 **single-target** (最終 softmax 只挑一個 region)，無法處理 “no such object” 或多個答案。GREC 是 REC 任務本身的問題定義升級，本文方法需要外接 abstention/multi-pick head 才能適配。對應到使用者主線「selective grounding / CRS conformal referring set」研究，這是直接對位的方向。

6.3 HieA2G (Hierarchical Attention for Grounding)

- 任務：以 hierarchical attention (詞 → 片語 → 句子，或物件 → 組合 → 場景) 做 REC。
- 與本文關係：是本文 attention 思路的深化——本文只在 LSTM 上做一層 soft attention 分派到 module；HieA2G 把 attention 變成多層次的，並讓 visual 端也有層級。本文是「平面 modular + 單層 attention」，HieA2G 是「層級 attention + 層級 visual」。

6.4 Zero-Shot Referring Expression Comprehension via Visual-Language True/False Verification (arXiv 2509.09958)

- 任務：用 VLM 直接做 true/false verification (給定 region + expression，預測是否匹配)，不需要在 REC 資料集 fine-tune，做 zero-shot REC。
- 與本文關係：方法路線完全不同——本文是 **task-specific supervised**、模組化、靠 VGG+LSTM；該文是 **task-agnostic VLM + verification framing**、靠大模型 zero-shot。但兩者面對的核心難題一致：「如何讓模型不只看 subject 本身、而真的理解 expression 的關係結構」。從本文 (顯式模組) 到該文 (靠 VLM 內在能力 + verification scoring)，可以看作 REC 過去 10 年方法論的兩端。對使用者的 selective grounding 研究而言，該文是 2026 年的新威脅模型 (B→B 上限被壓縮)，必須在 Ch5 中正面回應。

7. 個人評價

7.1 優點

1. 直觀且可解釋：Subj / Loc / Rel / Dist 四個 module 對應人類描述物件時用到的四類資訊，ablation 結果乾淨地證明每個都重要。
2. modular 設計開啟一條路線：直接催生了 Compositional Modular Networks、MAttNet 等後續經典工作。
3. 訓練目標升級：從 generation-based MMI 換成 discriminative softmax over candidates，本身就是一個極具影響力的設計選擇 (後續幾乎所有 REC 方法都採用這個 framing)。
4. Dist module 的 multi-context 聚合：在 2016 年是少見的 design，預告了後來 GNN-based grounding 的方向。

7.2 限制

1. 依賴 GT box：評估時用 ground-truth bounding box 當 candidate，沒回答「detector 雜訊下還能不能 work」。
2. VGG + 單層 LSTM：以 2026 年的眼光看極端過時；現在 CLIP/OWL-ViT/GroundingDINO 都已內建跨模態對齊。
3. single-target 假設：無法處理 no-target / multi-target，與 GREC 設定不相容。
4. 關係的語意空間有限：spatial encoding 只能抓「左右、上下、大小、距離」，無法處理「holding」、「belonging to」這類 semantic relation (要等 scene graph based 方法)。
5. 計算開銷：Rel module 對所有 region pair 配對，是 $O(N^2)$ ；大 scene 下不划算。
6. 未報告 calibration / abstention：模型 softmax 出來的分數沒有可靠性分析 (這正是使用者 selective grounding 主線要補的洞)。

7.3 後續方向 (若今天重做)

1. 把 VGG 換成 CLIP image encoder、LSTM 換成 transformer text encoder。
2. Rel module 改用 GAT / cross-attention，避免 $O(N^2)$ 全配對。
3. 直接接 GREC 設定，加 abstention head 處理 no-target，加 set-prediction head 處理 multi-target。
4. 在 Cops-Ref 上補測，驗證 Rel module 是否真的扛得住 compositional 對抗樣本。
5. 增加 calibration (temperature scaling / conformal prediction) 與 selective prediction 分析——這正是 CRS / 使用者論文主線的方向。

6. 加入 verification-style scoring (呼應 zero-shot true/false verification) · 讓 modular 框架也能在 zero-shot 條件下運作。

7.4 給沒讀過 REC 的人的一句話總結

這篇是 2016 年讓 REC 從「只看物件外觀」進化到「也看物件之間關係」的關鍵 paper——它提出把 subject、location、relationship、multi-context 拆成四個可加性的 scoring module，用 LSTM attention 把語言詞分派給不同 module，在 RefCOCOg 上把準確率從 25% 提升到近 50%，並直接催生了後來 Compositional Modular Networks 與 MAttNet 一整條 modular grounding 研究路線。

8. 對使用者主線 (selective grounding / CRS) 的可借鏡點

1. **modular factorization 的乾淨 ablation**：本文 Subj/Loc/Rel/Dist 逐步加法的 ablation，是 CRS 的 2×2 factorization ablation 可以參考的範式。
 2. **Rel module 的 spatial encoding**：CRS 的 OWL-ViT gate 也許可以額外吃 box-pair geometry，作為 multi-target 時 referring set 內部一致性的訊號。
 3. **多 context 聚合 (Dist)**：對應 CRS 在 multi-target 情境的 set-level scoring，可以借這個 attention-aggregation 思路把候選集內部的關係分數聚合起來，作為集合可靠性指標。
 4. **討論章節對位**：在 Ch2/Ch3 文獻回顧中，這篇是「explicit relational REC」的代表，應與 Cops-Ref (bias-control benchmark)、MAttNet (modular SOTA)、GREC (task generalization)、Zero-Shot True/False Verification (新威脅模型) 並列討論，鋪陳 REC 任務 10 年演進史。
-

9. 參考連結

- arXiv : <https://arxiv.org/abs/1607.07702>
- CVF : https://openaccess.thecvf.com/content_cvpr2016/html/Hu_Modeling_Relationships_in_CVPR_2016_paper.html
- Code : https://github.com/ronghanghu/text_obj_retrieval
- Project page (含結果表) : https://ronghanghu.com/text_obj_retrieval/
- Semantic Scholar : <https://www.semanticscholar.org/paper/Modeling-Relationships-in-Referential-Expressions-Hu-Rohrbach/a396a6febdac84340d139096a1c5b2e9a733a3f>
- 後繼 CVPR 2017 : Compositional Modular Networks <https://arxiv.org/abs/1611.09978>
- 前傳 CVPR 2016 : Natural Language Object Retrieval (SCRC) <https://arxiv.org/abs/1511.04164>
- 經典後繼 CVPR 2018 : MAttNet (Modular Attention Network for Referring Expression Comprehension)