

論文深讀筆記：BCEA —Look Again Before You Abstain

一、書目資訊

- 標題：Look Again Before You Abstain: Budgeted Conformal Evidence Acquisition for Reliable Vision-Language Models
 - 作者：Jian Xu (1,2)、Delu Zeng (3)、John Paisley (4)、Qibin Zhao (2)
 - arXiv：2606.16667v1 [cs.CV] · 2026-06-15
 - 授權：CC BY 4.0
 - 領域定位：LVLM (大型視覺語言模型) 幻覺的選擇性預測 (**selective prediction**) + 分布無關保證 (**distribution-free guarantee**)，並引入第三種動作「主動取得更多視覺證據 (evidence acquisition)」。
 - 一句話概括：把「回答 / 棄答」的二元 conformal 過濾器，升級成「回答 / 棄答 / 再看一眼 (zoom-crop / 結構化介入)」的三元決策；關鍵發現是天真地把證據取得插進已校準的過濾器會悄悄破壞統計保證，正確做法是把整個 **acquisition policy** 折進 **score function**、在 **post-acquisition** 分數上重新校準，即可恢復有限樣本保證並提升覆蓋率。
-

二、問題定義與動機

2.1 背景痛點

LVLM 會流暢地「幻覺」出影像中不存在的物件 / 屬性 / 關係。對於醫療、科學、輔助等高可靠場景，光流暢不夠，需要一個保證：無論模型說什麼，未獲影像支持的 **claim** 比例 (幻覺率) 必須低於使用者指定的門檻。

Conformal prediction 正好提供這種保證。最強的既有工作是 **ConflVLMM (Li et al. 2025)**：把每個生成細節當成一個假設，用便宜的不確定性啟發式打分，把分數低於 conformal 校準門檻的 **claim** 過濾掉，於是對「留下來的 **claim**」的事實錯誤率得到有限樣本、分布無關的上界。

2.2 核心張力：保證的代價是「狂棄答」

作者用一個直接的測量點出問題：要把幻覺率壓到 **5%** 以下，在平衡的 object-existence benchmark 上，一個 SOTA conformal 過濾器必須棄答超過 **80%** 的 **claim** (精確數字：LLaVA-1.5 上 $\alpha=0.05$ 只敢 assert 18%，亦即棄答 82%；即使放寬到 $\alpha=0.20$ 也只 assert 40%)。一個「四題拒答三題」的可靠模型，實用價值有限。

2.3 動機觀察

「當更多證據便宜可得時，棄答是浪費的。」人類不確定小物件在不在時會「湊近看」，而不是放棄。LVLM 有對應動作：重新編碼一個放大的 crop、或在針對性視覺介入下重新打分，代價只是幾次額外 forward pass。核心問題是：這個「再看一眼」能否在不放棄統計保證的前提下加進來？

2.4 兩條既有文獻各解一半

- **Conformal LVLM 過濾器 (ConflVLMM、CAP)**：有保證，但只會「丟棄」**claim**，從不取得證據。
- **證據取得方法 (ReCoVERR)**：會收集更多證據來救回被棄答的問題，但靠啟發式 risk-tolerance 門檻、沒有分布無關保證；而且它取得的是文字證據 (LLM 生成的追問)，不是重新檢視像素。

沒有方法同時做到「取得視覺證據 + 保留保證」，而作者證明天真地把兩者合併並不安全。

三、方法詳解：BCEA

BCEA 把二元「answer / abstain」過濾器變成有保證、會找證據的三元決策器：**answer / abstain / acquire**。三項貢獻如下。

3.1 證據充分性分數 (Evidence-Sufficiency Scores)

定義 $\ell(v) = (1/|c|) \sum_t \log p_{\theta}(c_t | v, \text{prompt})$ · 即 claim c 在視覺輸入 v 下的平均 token log-likelihood。

- **Global ungrounding** 分數 (沿用前人直覺) : $s_{\text{glob}}(x, c) = \ell(x) - \ell((\text{blank}))$ · 其中 (blank) 是全黑 (blank) 影像。幻覺 claim 在拿掉影像後幾乎不變 ($s_{\text{glob}} \sim 0$); grounded claim 則會大幅下降。
- **Region / Intervention** 分數 : s_{glob} 把整張圖丟掉 · 無法分辨證據「在哪」也分不出依賴視覺結構的 claim · 改用依 claim 類型選的針對性介入 T : $s_T(x, c) = \ell(x) - \ell(T(x))$
 - 存在 / 屬性 claim : region masking (把被詢問物件所在區域塗黑) 。
 - 左右關係 claim : horizontal flip (水平翻轉) 。正確的方向 claim 翻轉後變假 ($s_T > 0$) · 錯誤的 claim 翻轉後變真 ($s_T < 0$) 。

3.2 Acquisition 動作 (再看一眼)

當 $s(x, c)$ 太低不能 assert · 但又不是明顯 ungrounded (borderline) 時 · BCEA 進行 acquisition : 形成 B 個放大視圖 $\{x^{(1)}, \dots, x^{(B)}\}$ (重疊 crop 的粗網格 · 不需要 ground-truth 定位) · 組成 post-acquisition 分數 :

$$s_{\text{acq}}(x, c) = \max(\ell(x), \max_{b \leq B} \ell(x^{(b)})) - \ell((\text{blank})) \dots (\text{式 3})$$

對真物件 · 某個 crop 放大它會抬高 likelihood ; 對幻覺物件 · 沒有任何 crop 能提供支持。這個 **max** 同時是好處與危險的來源。

3.3 為什麼天真 acquisition 無效 · 以及如何修

天真部署 : 在 base 分數 s_{glob} 上校準門檻 τ_{α} · 部署時卻用 $s_{\text{acq}} \geq \tau_{\alpha}$ 來判定 (取得證據 · 沿用舊門檻) 。

- **Proposition 1 (天真 acquisition 反保守)** : 因為 $s_{\text{acq}} \geq s_{\text{glob}}$ 逐點成立 (式 3 的 max) · 接受集 $\{s_{\text{acq}} \geq \tau_{\alpha}\}$ 是 $\{s_{\text{glob}} \geq \tau_{\alpha}\}$ 的超集。對前者認證的 level- α 保證不會轉移到這個更大的集合。新被納入的 claim $E' = \{s_{\text{acq}} \geq \tau_{\alpha}, s_{\text{glob}} < \tau_{\alpha}\}$ 正好是「全圖分數拒絕 · 但某個 crop 把它推過門檻」的 claim——對幻覺 claim · crop 可能虛假地抬高 ℓ · 所以 $\Pr[Y=0 | E']$ 通常很大 · 保證被破壞。實測 realized risk 超標可達 17 個百分點 (摘要) · 表 1 中 $\alpha=0.20$ 時飆到 0.41 (兩倍違規) 。
- **Proposition 2 (單調 acquisition)** : $s_A^{(B)}$ 對 B 逐點非遞減 · 所以固定 τ 時 coverage 與 false-acceptance probability 都隨 B 非遞減。更多預算讓更多真 claim 過關 · 但也讓更多假 claim 過關 · 除非把 τ 重新調高 · 否則 risk 會爬升。

修法 (核心) : 把整個 acquisition policy 當成 score function 的一部分 · 在校準 claim 的 post-acquisition 分數上校準門檻 · 讓校準與測試走過完全相同的 pipeline · 恢復 exchangeability 。

- **Theorem 1 (Acquisition-adaptive validity)** : 固定一個只用 (x, c) 與模型 · 不讀校準標籤的 acquisition policy A · 映到 post-acquisition 分數 $s_A(x, c)$ · 若校準與測試 claim 可交換 · 則用 Clopper–Pearson fixed-sequence 程序在 $\{s_A(x_i, c_i)\}_{i=1}^n$ 上選 τ · 並以 $\{s_A \geq \tau\}$ 判定 · 即可在測試 claim 上以機率 $1-\delta$ 把 selective risk 控制在 level α · 證明要旨 : 把固定映射 A 套到每個 claim 保持 (s_A, y) 的可交換性 · 其餘就是標準 split-conformal selective risk control · 這是把已知原理 (把固定 · 標籤無關的變換折進 conformal pipeline 不損 coverage ; Shanmugam 2025 · Wang 2026) 實例化 ; 作者強調其價值在於它排除的失敗模式 (Prop 1) 對視覺 acquisition 既容易犯 · 又嚴重 。
- **Proposition 3 (claim 內序列式 acquisition)** : policy 可以一次形成一個視圖 · 邊看邊決定要不要再看 · 何時停 (停止時間 $\kappa \leq B$) · 只要每個決策只看當前 claim 的觀測 · 則 s_A 仍是 (x, c) 的固定可測函數 · Theorem 1 原封不動成立 · 亦即「看 · 判斷 · 再看 · 有信心就停」無需任何修正即合法 。
- **Proposition 4 (Anytime-valid risk control)** : 第二個 optional stopping 來源是校準資料流本身 (一直收標籤 · 看起來好就停) · 此時固定樣本的 Clopper–Pearson 失效 ; 改用 betting confidence sequence (基於 supermartingale + Ville 不等式) · 可在所有樣本量同時有效 · 因此對校準流的任意 data-dependent 停止仍保證有效 · 作者強調這條不是現成實例 · 把保證從 fixed- n 升級到對「claim 內 acquisition」與「校準流」雙重 optional stopping 都穩健——這才是部署中的可靠性監控器真正的處境 。

Algorithm 1 最關鍵的一行是第 7 行：門檻校準在已含 acquisition 的 Score 上，使部署決策（第 9 行）與校準看到同一個映射——這正是 Theorem 1 的條件。實用處方一句話：「在你真正要部署的分數上校準。」

3.4 Acquisition 何時有幫助？(棄答與證據取得的取捨理論化)

Theorem 1 只保證安全，不保證有用。作者精確刻畫 coverage 增益：

- **Proposition 5** (固定 risk 下的 coverage 是一個 ROC 點)：令 $\pi = \Pr[Y=1]$ 。在 selective risk $\leq \alpha$ 限制下，最大 coverage 落在 ROC 空間中斜率 $\rho(\alpha) = \pi\alpha / [(1-\pi)(1-\alpha)]$ 那條射線上的最大 TPR 點，且 $C_S(\alpha) = (\pi + (1-\pi)\rho(\alpha)) \cdot \text{TPR}_S^*(\alpha)$ 。
 - **Theorem 2** (acquisition 有幫助 iff 改善 ROC)：post-acquisition 分數 S' 對每個 α 都使 coverage 不降，當且僅當 $\text{ROC}_S(S')$ 逐點支配 ROC_S 。充分條件： S' 在 Blackwell 意義下對 Y 比 S 更有資訊（其類條件 likelihood ratio 是 S 的單調精化）。
- 這把「acquisition 有沒有用」這個模糊問題變成可測、可證偽的判準，並預測了實驗順序：uniform-grid 把 AUROC 從 0.82 抬到 0.86、CLIP-guided 再到 0.88，因此 coverage 在每個 risk level 都是 **no-acq < grid < guided**。
- 為什麼不主張 **budget allocation** (誠實的負結果)：在固定總預算下不均分配 budget，理論上應由 greedy water-filling 解；但在 existence claim 上沒有任何改善 (≤ 0.4 coverage 點，落在 CI 內)。結構原因：單一全域門檻下，多看一眼同時抬高真假 borderline claim 的分數，而分配時標籤未知，所以任何標籤無關的分配在一階上是 coverage-neutral。作者刻意不把 **allocation** 當貢獻，視為一個澄清性的負結果。

四、實驗

4.1 設定

- 模型：主用 LLaVA-1.5-7B；Qwen2.5-VL-7B 驗證泛化；POPE 實驗再加 LLaVA-NeXT-7B、InternVL2-8B（共四個開源 VLM）。
- 資料：COCO val2017 ground-truth instance 標註自構（不需額外標註）。
 - Existence：present 物件（真）vs 抽樣 absent 物件（假）。
 - Spatial：兩個最大、水平分離的物件「A 在 B 左/右」，方向交換為假 claim。
 - Count (附錄)：「恰有 k 個 A」。
- 每個 claim 一次 forward pass 算分；acquisition 加 **B=5** 個 grid-crop pass。
- Conformal：50/50 split，平均 300 次隨機 split， $\delta=0.1$ ；報告 test coverage 與 **90th-percentile realized risk**（因為保證是 $1-\delta=0.9$ ，所以該對齊的量是 90 分位風險，應坐落在 α ）。

4.2 主結果：天真破壞、BCEA 恢復 (Table 1, 1,440 existence claims)

四個方法共用同一批 acquired evidence，只差在 thresholding：

α	No-Acq (cov/risk)	Naive (cov/risk)	ReCoVERR (cov/risk)	BCEA (cov/risk)
0.05	.19 / .06	.40 / .19	.32 / .08	.22 / .06
0.10	.28 / .11	.57 / .30	.40 / .13	.37 / .10
0.20	.39 / .21	.74 / .41	.50 / .24	.47 / .21

(粗體 risk = 超過目標 α 超出 Monte-Carlo 誤差，即保證被破壞。)

- **No-Acq** (保證棄答) 與 **BCEA** 的 90 分位 risk 都緊貼 α 。
- **Naive** (沿用門檻) coverage 跳升，但 risk 大幅超標 ($\alpha=0.20$ 時 0.41，兩倍違規)。
- **ReCoVERR-style** (用 empirical 校準 risk、無有限樣本修正) coverage 最高但反保守，每個 level 超標約 0.03–0.04。

- **BCEA** 既守住風險，又把 coverage 從棄答的水準大幅抬高（例如 $\alpha=0.10$ ：**0.29** $\rightarrow$ **0.37**）。

一句話貢獻：分布無關保證相對於「無保證的取得器」只付出幾個 coverage 點，而那個無保證取得器是悄悄違規的；同時 BCEA 比純棄答多賺 coverage。

4.3 證據是局部化的 (5.2)

800 個真 existence claim 上，遮住物件 GT 區域使 claim log-likelihood 平均降 0.109，遮住等面積無關區域反而略升 (-0.050)；配對差 $+0.159$ 、勝率 67%、 $p \ll 10^{-10}$ 。Occlusion 熱圖集中在物件上，佐證 region/crop-based acquisition 的前提。

4.4 Coverage 隨 budget 上升 (5.4)

掃 budget B (每 claim 額外視圖數)，每個 B 重新校準：guaranteed coverage 從 $B=0$ 的 0.29 單調升到 $B=5$ 的 0.35 ($\alpha=0.10$)，realized risk 釘在 ~ 0.11 。多看買到更多 coverage 且不損保證。**Where** 分配 (**greedy vs uniform**) 統計上無差別 (皆 ~ 0.34)。

4.5 結構化介入救關係 claim (5.5 · 996 平衡 spatial claim)

Score	AUROC (correct vs swapped)
Raw claim likelihood	0.567
s_glob (global ungrounding)	0.574 (近乎瞎猜)
s_flip (翻轉介入，本文)	0.765

關係 claim 中兩物件都在，blank 影像對正確與交換關係懲罰相同，所以 global 分數無效。單次水平翻轉把驗證從 $\sim$ chance 抬到 0.765 (真關係 mean s_flip $+0.034$ ，假關係 -0.066)。

有效介入需滿足兩條件：必須翻轉 **claim** 真值且保持影像 **in-distribution**。對上下關係用 vertical flip 失效 (AUROC 0.50) —— 上下顛倒是 OOD，likelihood 變得無資訊而非真值反轉。所以設計介入是一個建模步驟，建立 per-claim-type 介入庫是本框架開啟的重要方向。

4.6 模型引導 acquisition (5.6)

用 CLIP 從多尺度候選窗中挑與「a photo of a」嵌入最相似的 5 個 crop (推論時不用 GT 位置)：

	no acq.	uniform grid	CLIP-guided
AUROC	0.824	0.862	0.882
cov @ $\alpha=0.05$	0.19	0.18	0.22
cov @ $\alpha=0.10$	0.28	0.33	0.37
cov @ $\alpha=0.20$	0.39	0.43	0.47

機制：guided crop 在小物件上把 acquisition 增益幾乎翻倍 ($0.25 \rightarrow 0.43$)，而 grid 常把小物件裁掉。

4.7 擴展到 POPE benchmark (5.7)

4 個 VLM $\times$ 3 個 split (random/popular/adversarial)，約 11.5k claim。所有 **12** 個設定一致：acquisition 對每個模型每個 split 都提升 AUROC (最戲劇性是 LLaVA-NeXT random： $0.56 \rightarrow 0.72$)，BCEA 的 guaranteed coverage 處處勝過棄答 (常 2–4 倍)，90 分位 risk 緊貼 $\alpha=0.10$ (誤差 ~ 0.03)。難度上升 (random < popular < adversarial) coverage 隨之下降，acquisition 在 base 分數最弱處幫助最大。

4.8 跨模型泛化 (5.8 · Qwen2.5-VL-7B)

Existence claim : acquisition 把 grounding AUROC 從 0.70 抬到 0.77 ; $\alpha=0.05$ 時棄答幾乎啥都不敢 assert (1%) · BCEA 在同樣認證風險下 assert 15% 。 Spatial 的 global 分數再次 ~chance (0.50) · 確認 global 分數在關係 claim 上的失敗非單一模型特有 。

4.9 棄答率 vs 幻覺率 (重點數字 · 給 CRS 對照用)

- 要把幻覺率壓到 $\leq 5\%$: global-score 純棄答過濾器在平衡 existence 上只能 assert **18%** (棄答 **82%**) (Figure 1 / 5.1) 。
- BCEA 在 $\alpha=0.05$ 仍守住 5% risk 的同時 · 把 coverage 從 0.19 抬到 0.22 (LLaVA) · Qwen 上甚至 1% $\rightarrow$ 15% 。
- $\alpha=0.10$ 時 BCEA 0.29 $\rightarrow$ 0.37 ; $\alpha=0.20$ 時 0.39 $\rightarrow$ 0.47 。
- 換句話說 : 保證越嚴 (α 越小) · 純棄答越接近「全部拒答」 · **acquisition** 的相對救援價值越大 · 但絕對 **coverage** 仍偏低 。

4.10 範圍邊界與限制 (6.)

- 只在 **backbone** 「看得見」的屬性上有訊號 : existence 、 left/right 可救 ; counting 、 relative size 、 above/below 、 color 、 color-object **binding** 全部 ~chance (s_glob AUROC 0.50–0.58) · 任何介入 (instance masking 、 vertical flip 、 grayscaling) 都救不回 · coverage 崩到 0 。
 - **Binding** 結果很關鍵 : 分數無法認證「the red cup」是否正確 binding · 正是因為 backbone 本身就分不出來——這是忠實行為 : backbone 真的看不見時 · 分數回報 ungrounded 而非編造信心 · 過濾器棄答 。
 - 從 **probed claim** 到 **free-form** 生成有真實落差 : 動機是 free-form 描述的幻覺 · 但評估的是 probed/atomic claim (COCO 自構 + POPE 是非題) 。
- 因 BCEA 的分數與保證是 per-claim · 與 claim 怎麼產生無關 · 理論上可接 claim parser 處理 free-form 輸出 · 但 acquisition 在自生 claim 上是否同樣有用 · parser 噪聲如何與 conformal 校準互動 · 尚未測試 · 作者明說 BCEA 是「受控探測下驗證的機制 · 尚非端到端 free-form pipeline」 。

五、與 CRS (使用者碩論主線) 的逐項 Diff 表

CRS = Cross-Base Conformal Composition : 以 **OWL-ViT gate** (控可用/棄答/no-target) + **GroundingDINO box** (控 compact set) 兩個凍結 base 組合 · 用 LTT conformal risk control 同時保證 **recall + abstention** · 在 gRefCOCO/RefCOCO 上輸出一個 **conformal referring SET of boxes** (GREC 指標) · post-hoc 、不重訓 。

維度	BCEA	CRS (你的碩論)
任務	object-existence claim verification (VQA 式幻覺判定 · 是非題 : 「圖中有 X 嗎」「A 在 B 左邊嗎」)	referring expression comprehension / GREC : 給定指稱語句 · 定位框 (box localization)
輸出	對單一 atomic claim 的 assert / abstain / acquire 三元決策	一個 conformal referring SET (多個 box 的集合) + 可棄答 / no-target
保證對象	幻覺率 (hallucination rate) 單一上界 : $\Pr[Y=0 \mid \text{asserted}] \leq \alpha$	雙保證 : recall (漏掉真 referent 的風險) + abstention (no-target/棄答) 同時用 LTT 控制 (R1/R2/R3 多風險)
單模型 vs 組合	單一 LVLm (LLaVA/Qwen/...) 自身 likelihood + 對自己視覺介入 (zoom/crop/flip)	cross-base composition : 兩個異質凍結 base (OWL-ViT + GroundingDINO) 的功能分工組合 · ablation 證明是 factorization 非 ensemble

維度	BCEA	CRS (你的碩論)
「再看一眼」的角色	核心貢獻：budgeted evidence acquisition 是主機制，靠 crop/intervention 抬分救棄答	不是 acquisition；CRS 的「組合」是把不同 base 的互補能力拼起來，無 per-claim 額外 forward 預算概念
conformal 形式	split-conformal selective risk control · Clopper–Pearson fixed-sequence；anytime-valid 版用 betting CS	LTT (Learn-then-Test) 多風險聯合校準 (Bonferroni over grid) · calib-only grid 修 leakage
資料/指標	COCO 自構 existence/spatial claim + POPE (是非題)；指標 coverage / 90th-pct realized risk / AUROC	gRefCOCO/RefCOCO；GREC 官方指標 (Pr@F1=1)、N-acc、T-acc) + set size / recall CI
空間關係處理	靠 horizontal-flip 介入把左右關係從 chance 救到 0.77 AUROC	REC 直接定位被指稱物件，空間語意內含在指稱語句中由 base 處理，非以介入驗證
失敗邊界	counting/binding/above-below 全 chance → coverage 崩 0 (誠實棄答)	已知 multi-target T-acc 天花板來自 frozen detector exact-match 硬上限 (不同瓶頸)
是否凍結 / post-hoc	是 (inference-only、no fine-tuning)	是 (frozen bases、post-hoc) — 兩者在這點同源，需特別切割措辭

結論：CRS 與 BCEA 在「框架詞彙」上高度重疊 (**selective prediction**、**abstain**、**distribution-free guarantee**、**grounded**、**frozen/post-hoc**、**conformal**)，但在「做什麼」上正交。BCEA 是 claim-level 是非驗證 + 單模型證據取得 + 單一幻覺率保證；CRS 是 referring-level 集合定位 + 跨 base 組合 + **recall×abstention** 雙保證。重疊只在外殼，不在內核。

六、論文該怎麼引用 / 切割 (可直接貼進 **Related Work**)

Selective prediction with conformal guarantees for VLMs. A parallel line of work brings conformal selective prediction to vision-language models for *hallucination control*. ConflVLM (Li et al., 2025) tests each atomic claim with a global uncertainty heuristic and conformally filters out ungrounded ones, bounding the residual factual-error rate; CAP (Tayebati et al., 2025) learns adaptive abstention thresholds. Most closely related to our framing is **BCEA (Xu et al., 2026)**, which augments such a binary answer/abstain filter with a third *acquire-evidence* action—re-examining the image via zoom crops or claim-type interventions under a compute budget—and shows that the acquisition policy must be folded into the score and re-calibrated on post-acquisition scores to preserve the finite-sample hallucination-rate guarantee. **We share BCEA’s vocabulary (distribution-free selective risk control over a frozen, post-hoc model) but differ in three load-bearing ways.** (i) *Task and output*: BCEA verifies object-existence and left/right claims as binary, VQA-style judgments and certifies a single hallucination rate over *asserted claims*; we perform referring-expression comprehension and emit a *conformal referring set of boxes* on gRefCOCO/RefCOCO, evaluated with GREC metrics. (ii) *Guarantee*: BCEA controls one risk (the false-assertion rate); CRS jointly controls *recall and abstention* (and no-target detection) via a multi-risk Learn-then-Test calibration. (iii) *Composition*: BCEA acts on a *single* LVLMM’s own likelihoods plus self-applied visual interventions; CRS composes *two heterogeneous frozen bases* (an OWL-ViT gate and a GroundingDINO box predictor) whose factorized roles—abstention/no-target vs. compact-set construction—are validated to be a true composition rather than an ensemble. BCEA’s budgeted acquisition is orthogonal to and could in principle be layered onto either base in our pipeline, but neither addresses set-level recall, cross-base transfer, nor referring-expression localization.

(精簡版一句話切割，若篇幅吃緊)：

與我們框架詞彙最近的是 BCEA (Xu et al., 2026)，但它做的是單模型、is-非題式 **object-existence 驗證 + budgeted 視覺證據取得**，只保證單一幻覺率；我們做的是跨 **frozen base 組合 + referring-set 定位**，並以 LTT 同時保證 recall 與 abstention (gRefCOCO/GREC)，兩者任務、輸出、保證對象與組合結構皆正交。

七、個人評價

優點

1. **負結果驅動的敘事漂亮**：「天真 acquisition 悄悄破壞保證、超標 17 點」這個 Proposition 1 + Table 1 的對照是全文最有說服力的賣點，把一個容易犯的部署錯誤量化得很乾淨。
2. **理論誠實**：Theorem 1 自承是已知原理 (Shanmugam 2025、Wang 2026) 的實例化，價值在於指出視覺 acquisition 的特定失敗模式；Prop 4 的 anytime-valid 升級才是真正新的技術貢獻；連 budget allocation 都明說是負結果——這種自覺難得。
3. **Theorem 2 (ROC 判準) 有實用價值**：把「acquisition 何時有用」化為可測 ROC 支配，並用 AUROC 數字驗證 no-acq < grid < guided 的 coverage 排序，理論與實驗扣得緊。
4. **失敗邊界誠實**：counting/binding/above-below 全崩到 0 並如實報告，把「忠實棄答」當特性而非 bug。

弱點 / 限制

1. **probed claim 與 free-form 的落差是真缺口**：作者自承動機是 free-form 幻覺、評估卻是是非題與 COCO 自構 claim，端到端 pipeline 未驗證。這也是它與真實部署最遠的一塊。
2. **絕對 coverage 仍偏低**： $\alpha=0.05$ 時 BCEA 也才 assert 22% (LLaVA)，「再看一眼」救回的是邊際，沒有改變「嚴格保證下大量棄答」的本質——它讓棄答少一點，但沒讓模型變得能放心多答。
3. **介入庫靠人工設計**：horizontal flip 有效、vertical flip 失效，每種 claim type 都要手工找到「翻轉真值且 in-distribution」的介入，泛化性受限；論文也把建庫列為 future work。
4. **參考文獻有小瑕疵**：正文寫 Qwen2.5-VL，bib 卻列 “Qwen3-vl technical report (arXiv:2511.21631)” ，版本對不上 (可能是預印本的引用筆誤)，引用時宜核對。

對 **CRS** 的威脅評估：低。雖然框架詞彙撞得兇 (這正是必須引用切割的原因)，但 BCEA 是 VQA 式是非驗證 + 單模型證據取得 + 單一保證，CRS 是 referring-set 定位 + 跨 base 組合 + 雙保證，內核完全正交。BCEA 反而可當成「同期、同調、不同任務」的最佳對照來凸顯 CRS 的 moat (set-level recall、cross-base factorization、gRefCOCO)。建議在 **related work** 用上面那段切割文字明確引用並劃清界線，把它變成襯托而非競品。