

論文導讀：Conformal Prediction Sets for Instance Segmentation

整理：kuo (碩論 CRS 主線比對用)

2026-06-18

Conformal Prediction Sets for Instance Segmentation — 深度導讀

0. 書目

- 標題：Conformal Prediction Sets for Instance Segmentation (標題已核對無誤)
- 作者：Kerri Lu (MIT LIDS / EECS)、Dan M. Kluger (MIT IDSS)、Stephen Bates (MIT LIDS / EECS)、Sherrie Wang (MIT MechE / IDSS)
- arXiv：2602.10045v1 [cs.CV]，提交日 2026-02-10
- 程式碼/資料：<https://github.com/conformal-instance-segmentation/conformal-instance-segmentation-code>
- 關鍵字：conformal prediction、instance segmentation、IoU 保證、set cover、Learn-Then-Test (LTT)、Conformal Risk Control (CRC)
- 與本人碩論的關聯：這是與 CRS (Conformal Referring Set) 同型保證、鄰近任務的論文。CRS 是「referring set 內 ≥ 1 個 box 命中 GT (recall 保證) + no-target abstention」，本文是「instance set 內 ≥ 1 個 mask 與 GT 高 IoU」。Stephen Bates 是 LTT / RCPS / conformal 理論大將，本文又明確宣稱勝過 LTT 與 CRC，因此必須逐項比對 nonconformity 設計與「set ≥ 1 命中」的保證結構。

1. 問題定義與動機

1.1 任務設定

- 輸入 $X = (I, (z_1, z_2))$ ：一張影像 $I \in \mathbb{R}^{W \times H \times C}$ 加一個像素座標查詢點 (z_1, z_2) 。
- 該查詢點落在某個 ground-truth 物件實例上，GT 以二值遮罩 $Y \in \{0,1\}^{W \times H}$ 表示。
- 有一個 instance segmentation 模型 $f(X, T)$ ，吃輸入 X 與可調參數 T ，輸出二值遮罩預測 $\hat{Y} = f(X, T)$ 。調 T 即可產生一族多樣化的預測 (例：SAM 的 mask index、watershed threshold、connected-component 前的 logit threshold)。
- 品質度量： $\text{IoU}(Y, \hat{Y}) = |Y \cap \hat{Y}| / |Y \cup \hat{Y}|$ ，完美預測 $\text{IoU}=1$ 。

1.2 動機 (為什麼需要這個)

現有 instance segmentation 模型「平均表現好」，但沒有原則性的不確定性量化：

1. 模型輸出的 logits / confidence 未經統計校準，也不保證任一預測遮罩接近 GT。例如 SAM 對每個 query 吐 3 個 mask + 預測 IoU，但不保證任一個 mask 正確、也不保證它預測的 IoU 準。
2. 既有的 conformal segmentation 方法 (Davenport 2024 ; Mossina & Friedrich 2025) 只會在「單一模型預測 mask」上做修改 (膨脹 dilation、邊界擴張)，只能表達局部邊界不確定性，無法表達真正主宰實務的結構性不確定性 (structural uncertainty) ——例如「相鄰區域到底是一個物件還是該拆成多個」(田地該合還是該分、細胞重疊、車輛遮擋)。
3. 要處理結構性不確定性，confidence set 內必須包含質性不同的 mask，而不是同一個 mask 的小擾動。

→ 本文目標：給定影像 + 像素查詢，輸出一個多樣化的 instance 預測 confidence set，並帶可證明保證：集合內至少有一個預測與 GT 的 IoU 高於門檻 τ ，機率 $\geq 1-\alpha$ 。

2. 方法詳解

2.1 核心保證 (要記住的一句話)

對新的測試點 $(X_{\text{test}}, Y_{\text{test}})$ (與 calib 同分布、IID)，給定使用者指定的 IoU 目標 $0 < \tau < 1$ 與誤差率 $0 < \alpha < 1$ ，演算法輸出 confidence set $C_{\{\alpha, \tau\}}(X_{\text{test}})$ ，滿足：

以機率 $\geq 1 - \alpha$ ，集合內存在某個遮罩 $\square \in C_{\{\alpha, \tau\}}(X_{\text{test}})$ 使得 $\text{IoU}(Y_{\text{test}}, \square) > \tau$ 。

這正是「set 內 ≥ 1 命中」的 marginal、existential (存在型) 保證——和 CRS 的 recall 保證是同一個邏輯骨架 (後面詳比)。

2.2 nonconformity score 怎麼設計? (重點)

關鍵差異：本文不是傳統「單一 nonconformity 分數做 split-conformal 取分位數」的形式，而是把不確定性集合化約成一個 Set Cover 問題。流程 (Algorithm 1)：

1. 先選定可調參數 T 的 k 個格點 $\{t_1, \dots, t_k\}$ 。動機：沒有任何單一 T 對所有 query 都最好——某些設定對某些 query 成功、對另一些失敗 (Figure 2)。
2. 對每個 calib 樣本 (X_i, Y_i) 、每個參數值 t_j ，計算遮罩 $\square_{ij} = f(X_i, t_j)$ 與其品質 $p_{ij} = \text{IoU}(Y_i, \square_{ij})$ 。
 - 這裡的「nonconformity 訊號」本質就是 IoU 本身：對每個 t_j 蒐集「被它覆蓋 (cover) 的 calib 點集合」 $S_j = \{i : \text{IoU}(Y_i, f(X_i, t_j)) > \tau\}$ ，即在 t_j 下預測 IoU 超過 τ 的 calib 點索引。
3. 找最小子集 $J_{\{\alpha, \tau\}} \subseteq [k]$ ，使得這些參數覆蓋的 calib 點聯集 $\bigcup_{j \in J} S_j$ 至少涵蓋 $(1 - \alpha)n$ 個 calib 點： $J_{\{\alpha, \tau\}} = \text{argmin}_{J \subseteq [k]} \{ |J| : |\bigcup_{j \in J} S_j| \geq (1 - \alpha)n \}$ 。
4. 對測試影像，用選出的每個 t_j 產生預測 $f(X_{\text{test}}, t_j)$ ，組成 $\text{set } C_{\{\alpha, \tau\}}(X_{\text{test}}) = \{f(X_{\text{test}}, t_j) : j \in J_{\{\alpha, \tau\}}\}$ 。

因此「nonconformity 設計」可以這樣理解：傳統 conformal 是「對 score 取 $(1 - \alpha)$ 分位數當門檻」；本文則是把校準目標重述為「在 calib 集上，挑一組最小參數集合，使其聯集的 hit 覆蓋率 $\geq 1 - \alpha$ 」。它用的不是一個純量分數，而是「每個參數 t_j 在 calib 集上產生的 hit/miss 二元指示向量 $g_j(X_i, Y_i) = 1[\text{IoU} > \tau]$ 」，再對這些向量做 set cover。校準的統計合法性靠大數法則 (後述 Lemma C.1 / Prop C.1)。

Set Cover 是 NP-hard：實作上先跑多項式時間的 greedy set cover 得初始解 J' ，再對更小基數的子集 brute-force 精煉到真正最小 (greedy 解通常很小所以可行；若太大則略過精煉步)。

2.3 自適應集合大小：去重複 (Algorithm 2)

$J_{\{\alpha, \tau\}}$ 是固定的，但很多 $f(X_{\text{test}}, t_j)$ 其實幾乎一樣。於是用使用者門檻 η (兩 mask $\text{IoU} > \eta$ 視為重複) 做去重，得 $C_{\{\alpha, \tau, \eta\}}(X_{\text{test}})$ ：最小子集使每個被丟棄的 mask 都與保留集中某 mask $\text{IoU} > \eta$ 。這讓集合大小隨 query 難度自適應 (簡單 query $\rightarrow$ 集合小；模糊 query $\rightarrow$ 集合大)。

去重等價於圖論的 Dominating Set 問題 (也 NP-hard)，同樣靠「集合小所以可 brute-force」化解。

去重會破壞原保證，因此要重新校準 IoU 門檻：對每個 calib 點，計算去重後集合內的最佳 $\text{IoU } s_i = \max_{\square \in C_{\{\alpha, \tau, \eta\}}(X_i)} \text{IoU}(Y_i, \square)$ ，取 s_i 的 α -quantile 當新門檻 θ 。新保證 (Theorem 2.1，漸近型)：

$$\liminf_n P(\max_{\square \in C_{\{\alpha, \tau, \eta\}}(X_{\text{test}})} \text{IoU}(Y_{\text{test}}, \square) \geq \theta) \geq 1 - \alpha。$$

實驗中 $\theta \geq \tau$ (接近或大於)，代表去重幾乎不傷原保證； $\theta > \tau$ 發生在覆蓋超過 $(1 - \alpha)n$ 時的 over-coverage。

2.4 為什麼宣稱勝過 LTT 與 CRC? (本文最重要的論證，跟 CRS 直接相關)

本文與 LTT / CRC 同屬「靠調可調參數做 conformal」，但 LTT/CRC 對每個輸入只輸出單一參數值、單一預測。本文列出三個勝點：

1. 可行性 (feasibility) 更廣：LTT/CRC 需要「存在單一參數值在 calib 上達到足夠覆蓋」。但 instance seg 裡，常常不存在單一 T 能對 $(1 - \alpha)$ 比例的 calib 點都產生高 IoU——此時 LTT/CRC 直接回傳錯誤 / 空集。本文改找多個參數的集合，只要「聯集中至少一個參數命中」即可，因此在更多情境可行。(附錄 E + Figure E.1 用田地實例證明：目標 80% 覆蓋，最佳單一參數 $T=0.24$ 只到 $\sim 67\%$ ，單參數方法注定達不到；本文的多參數集合可達 $\sim 80\%$ 。)

2. 不需要單調 loss : CRC (及前身 RCPS, Bates 2021) 要求 loss 對參數單調或近單調。但 IoU loss 不單調——調大 T 既可能改善也可能惡化 IoU。本文的 (漸近版) 方法不需要單調 loss，所以能直接用 IoU-based loss。
3. 自適應 + 多樣性 : LTT/CRC 永遠吐單一 mask，無法表達結構性不確定性；本文吐大小自適應、形狀質性不同的集合。
4. vs. 「把 LTT 套到羈集」的天真做法 : 理論上可把 LTT 的參數空間擴成 $2^{\{t_1..t_k\}}$ 的羈集 (2^k 元素)，但那個超大參數空間 LTT 原論文未探討；本文提供了具規範性的演算法與實作。

2.5 有限樣本版本 (Appendix H, Algorithm 3)

主文用的是漸近保證版 (靠 WLLN)。附錄 H 給有限樣本保證版：

1. 把 calib 隨機切兩半 n_1, n_2 。
2. 用 n_1 跑 greedy 對 k 個參數排序 (高到低優先序 L，每步選覆蓋最多「尚未覆蓋」點的參數)。
3. 用 n_2 跑 CRC 找最小 λ ，使 $L[1:\lambda]$ 的前綴參數集合構成合法 conformal set。為了讓 CRC 能用，去重程序 UNIQUE* 特別設計成 $C_\lambda \sqsubset C_{\lambda+1}$ (巢狀)，使 $\text{loss}_i(\lambda) = 1[\max \text{IoU} \sqsubset \tau]$ 對 λ 非遞增 $\rightarrow$ 單調，滿足 CRC 前提。
4. 有限樣本保證 (Theorem H.1) : $P(\max_{\lambda \sqsubset C_\lambda} \text{IoU}(Y_{\text{test}}, \lambda) > \tau) \sqsubset 1 \sqsubset \alpha$ 。

漸近版通常較緊 (集合更小)，因為可 brute-force 找最小 set cover、最小去重子集；有限樣本版受限於前綴形式 $L[1:\lambda]$ ，無法保證最小。論文實驗一律用漸近版。

2.6 校準合法性 (證明骨架，供本人寫 related work 引用)

- Assumption 1 : calib 與 test IID。
- Assumption A.2 (可行性) : $P(\max_j \text{IoU}(Y, f(X, t_j)) > \tau) > 1 \sqsubset \alpha$ ，可實證檢查；不成立時 Algorithm 1 報錯，使用者要調大 α / 調小 τ / 擴大參數空間。
- Lemma C.1 : $J^{\wedge\{n\}}_{\{\alpha, \tau\}}$ 漸近落在合法集合 $A_{\{\alpha, \tau\}}$ (靠 WLLN，誤選不合法子集或報錯的機率 $\rightarrow 0$)。
- Prop C.1 / Theorem 2.1 : 由上推出漸近 $\geq 1 - \alpha$ 覆蓋。去重後保證靠可交換性 + α -quantile (Fact 2.15(ii)，Angelopoulos 2025a)。

3. 實驗

3.1 資料集與模型 (Table 1 / Appendix I)

應用	資料集	模型	可調參數 T	calib / test 像素
田地切割 Field delineation	Fields of The World (法國 · 350 圖 $\rightarrow$ 250 calib / 100 test 圖)	FoTW U-Net + watershed	watershed threshold (0~1 · 細格)	2476 / 917
細胞切割 Cell segmentation	Cellpose (52 圖 $\rightarrow$ 30/22)	Cellpose-SAM	cell extent threshold (-5~5 · 步長 1)	925 / 659
車輛偵測 Vehicle detection	Cityscapes (200 圖 $\rightarrow$ 100/100)	SAM	T1=mask index $\in\{1,2,3\}$ 、T2=prob threshold (0~1 步長 0.05)	105 / 121

每張圖隨機抽像素查詢點 (只保留落在目標 instance 內者)。 $\eta=0.9$ 統一用於去重。

3.2 (α, τ) 怎麼選

對每個任務畫「每點在所有 T 下可達的最大 IoU 的累積分布」 (Figure D.1)，定出 base model 的性能天花板。選在 Pareto frontier 上的最嚴可行配置：

- 田地： $\alpha=0.2, \tau=0.7$ (最模糊、保證最弱)
- 細胞： $\alpha=0.2, \tau=0.75$
- 車輛： $\alpha=0.1, \tau=0.8$ (SAM 最強)

重要立場：conformal 只能「認證」base model 的可靠性，無法「超越」它的天花板。田地連 90% 信心 + IoU>0.8 都做不到 (最佳 T 下仍 >10% 的點 IoU<0.8)。

3.3 主結果 (Table 2：覆蓋率)

應用	τ	$\tilde{\theta}$	目標覆蓋 ($1-\alpha$)	本文 conformal 覆蓋	LTT/CRC baseline 覆蓋
田地	0.7	0.696	0.8	0.797	0.663
細胞	0.75	0.760	0.8	0.835	0.803
車輛	0.8	0.842	0.9	0.843	0.661

- 本文覆蓋率接近目標 $1-\alpha$ 且顯著高於 feasible LTT/CRC baseline。
- 田地 66.3%→79.7%、車輛 66.1%→84.3% 大幅提升 (救回被單參數合併/拆錯、或被 SAM top-1 漏掉的物件)；細胞僅 80.3%→83.5% (因細胞誤差多為「邊界局部」而非結構性)。
- 注意：車輛雖達 0.843、未到目標 0.9，但這反映 base model 天花板 ($\tilde{\theta}=0.842$ ，且 baseline 僅 0.661)。

3.4 自適應集合大小 (Figure 4)

去重後多數集合 ≤ 3 個 mask，模糊時擴大。田地最大到 5 (對應 under/over-seg 假說)；細胞多塌成 1~2 (有些 size=0，因該像素被判為非細胞)。

3.5 對比 morphological dilation baseline (Appendix F, G)

- Dilation 只保證「GT 被膨脹 mask 包住」，不保證高 IoU。田地上膨脹 $D=2$ 像素，只有 54.4% test 點 IoU>0.7 (本文 79.7%)。
- Dilation 傾向 undersegmentation (為了包住 GT 把 mask 撐大)。用 Persello & Bruzzone (2009) 的 over/under-seg 分數量化 (Appendix G)：兩者 over-seg 都低，但 dilation 的 under-seg 明顯較差；本文因吐多個預測，總有一個避開 under-、一個避開 over-。

3.6 限制 (作者自陳，Discussion)

1. 保證是 global / marginal：每個輸入用同一個 IoU 門檻，簡單與模糊 query 一視同仁 (無 conditional / adaptive 門檻)。
2. 依賴「可調參數」：若沒有能誘發多樣性的參數，方法難用。
3. 組合最佳化 (set cover、去重) 在大集合時可能很貴。
4. 現有模型不被訓練去「產生多個合理替代」，未來工作可朝 diversity-promoting training。

4. 與 CRS 的逐項 diff 表 (本人碩論比對核心)

面向	本文 (Conformal Instance Segmentation)	本人 CRS (Conformal Referring Set)
任務 / query 型態	instance segmentation · 像素座標查詢 (point prompt)	referring expression comprehension · 自然語言查詢
輸出單元	instance 遮罩 mask 的集合	box 的 referring set
核心保證結構	set 內 ≥ 1 個 mask 與 GT IoU > τ · 機率 $\geq 1-\alpha$ (existential/marginal recall)	set 內 ≥ 1 個 box 命中 GT (IoU 門檻) 的 recall 保證 · 機率高

面向	本文 (Conformal Instance Segmentation)	本人 CRS (Conformal Referring Set)
「 ≥ 1 命中」邏輯	相同骨架：都是「集合內存在一個高品質元素」的 existential 保證，都靠 marginal coverage	相同骨架
集合怎麼生成	對單一模型掃可調參數 T 的格點，挑最小參數子集 (set cover)	跨 base 組合：OWL-ViT gate (管 abstention/no-target) + GroundingDINO box (管 compact set) · LTT 聯合校準
校準框架	漸近版用 set cover + WLLN；有限樣本版用 CRC (明確聲稱勝過 LTT/CRC 的單參數做法)	LTT (Learn-Then-Test) · 用 calib-only grid、Bonferroni 多風險校正
nonconformity 訊號	每個參數 t_j 的 hit 指示向量 $1[\text{IoU} > \tau]$ ，化約成 set cover 覆蓋率	OWL-ViT score / consistency 等做 abstention 判斷 + box recall
abstention / no-target	無。每個 query 都假設落在某 instance 上，沒有「該棄答 / 無目標」機制 (細胞偶有 size=0 是模型判非細胞，非設計的 abstention 保證)	有。gRefCOCO no-target，明確的 abstention 雙保證 (recall + abstain)
多模型 / cross-base	單模型 (同一個 f 調參數) · 明說「考慮 base 的 superset」是補救手段而非主軸	cross-base composition 是主結果；factorization (gate vs box) 非 ensemble
set 大小自適應	有 (去重 Algorithm 2，隨 query 難度變)	有 ($\alpha=\beta=0.3$ 下平均 3.21/2.02/3.48 框)
保證型態	漸近 + 有限樣本兩版	有限樣本 (LTT/RCPS 路線)
conditional / per-input	明說是 global 限制，待未來工作	同樣是 marginal (共同弱點)

5. 這篇對 CRS 的威脅評估與借鏡

5.1 「set ≥ 1 命中」保證會威脅 CRS 的 recall-guarantee 新穎性嗎？

結論：不直接構成威脅，但會壓縮「保證骨架本身」的可宣稱新穎性，必須在寫作上明確區隔。

- 保證骨架 (existential recall) 並非 CRS 獨創、也非本文獨創：兩者都是「集合內 ≥ 1 高品質元素，marginal 機率 $\geq 1-\alpha$ 」。事實上 Angelopoulos 2025b 的 LTT 早就對 instance seg 給過 recall/coverage 保證。所以「我們保證 set 內 ≥ 1 命中」這句話本身不能當成 CRS 的核心賣點——本文的存在會讓審稿人說「這是 conformal recall 保證的標準形式」。
- CRS 真正的差異化 (仍站得住) 有三點，這篇都沒做：
 - 語言 query (REC) 而非像素 query：本文是 point-prompt，CRS 是 referring expression。語言語意歧義 + grounding 是不同問題類別。
 - abstention / no-target 雙保證：本文完全沒有 no-target / 棄答機制。CRS 在 gRefCOCO 上同時校準 recall 與 abstention，這是本文不覆蓋的軸。
 - cross-base composition + factorization：本文是單模型掃參數；CRS 是 OWL gate $\times$ GroundingDINO box 的跨 base 分工，且有 2×2 ablation 證明是 factorization 非 ensemble。
- 因此威脅是「修辭層」而非「方法層」：CRS 不應把賣點定位成「我們有 set ≥ 1 命中保證」(會被這篇與 LTT 蓋過)，而要定位成「在語言 grounding 上，把 recall 與 abstention 用跨 base 分工聯合校準」。本文剛好是強力的「同型保證、鄰近任務」對照，能襯托 CRS 的 query 型態與 abstention 差異。

5.2 nonconformity 設計可否借鏡？

- 可借鏡 1：set cover 視角當作 LTT 的替代敘事。本文把「多參數聯集覆蓋 $(1-\alpha)$ 」講成 set cover，並嚴格論證「為何單參數 LTT/CRC 不可行 / IoU loss 非單調」。CRS 用 LTT，但若 CRS 也碰到「單一 threshold 無法同時保證 recall+abstain」的情境，可借這套 set cover / 多參數聯集論證，強化「為何需要組合而非單一門檻」的動機。

- 可借鏡 2：去重 + 重新校準 IoU 門檻 ($\tilde{\theta}$) 的兩階段技巧。CRS 輸出 box set 時若也想做「去近似重複 box → 重新校準命中門檻」，這個 Algorithm 2 的「去重後用 calib 上 best-IoU 的 α -quantile 重新定門檻」是乾淨可移植的模式（保證仍靠 exchangeability）。
- 可借鏡 3：可行性 frontier (α - τ 天花板) 做法。Figure D.1 用「每點可達最大 IoU 的累積分布」畫 base model 天花板、定 Pareto (α, τ)。CRS 的「R1/R2 CI 上界 + size CI」報法已類似，但這篇的「天花板 histogram → 選最嚴可行配置」可作為呈現方式的對照範例，強化 CRS 報「我們選的是 frontier 上最嚴點」的論述。
- 不宜照搬：本文的核心是「單模型掃參數 + set cover」，這與 CRS 的 cross-base 哲學相反，不要把 CRS 改成單模型掃參數（會丟掉 factorization 賣點）。借的是論證與校準技巧，不是架構。

5.3 related work 怎麼寫 (具體建議)

1. 在「conformal for segmentation / detection」段落必引此文，定位為「像素 query 的 instance segmentation 版同型 recall 保證」，並點出三個與 CRS 的差異（語言 query、abstention、cross-base）。
2. 借用本文的「LTT/CRC 單參數不可行 + IoU loss 非單調」論證，當作「為何 CRS 需要 LTT 多閾值 / 跨 base 而非單一門檻」的 supporting citation。
3. 把 Davenport 2024、Mossina & Friedrich 2025 (dilation) 也順帶引為「只保證包含、不保證高 IoU」的反例，與 CRS 的「命中 (hit) 保證 vs 包含 (containment) 保證」對齊——這個「hit vs containment」的區分，CRS 可直接借來強化自己的保證語意。
4. Bates 是共同作者：CRS 已用 LTT (Bates 系)，引此文能讓「CRS 的 conformal 理論血統」更完整、審稿友善。

6. 個人評價

優點

- 問題切得準：把「結構性不確定性」（合/分歧義）與「邊界局部不確定性」分開，並指出既有 dilation 法只能做後者，是很乾淨的 motivation。
- set cover 視角優雅：把「多參數聯集覆蓋」對應到經典 NP-hard 問題，再用 greedy+brute-force 化解，務實。
- 「hit (高 IoU) 保證 vs containment (包住) 保證」的區分有洞見，對整個 conformal segmentation 文獻是有價值的概念釐清。
- 漸近 + 有限樣本兩版都給、證明完整 (WLLN + exchangeability)，理論扎實 (Bates 風格)。
- 誠實：反覆強調「conformal 只認證、不超越 base model 天花板」，車輛達不到 0.9 也照實報。

侷限 / 可挑戰處

- 保證是 marginal/global，沒有 conditional (per-input) 門檻——這是與 CRS 共享的弱點，審稿人會問。
- 強依賴「存在能誘發多樣性的可調參數 T」。一旦模型沒有這種旋鈕（很多端到端模型沒有），方法就難用；這比 CRS 的 cross-base 組合更受限。
- 沒有 abstention / out-of-distribution / no-target 處理——所有 query 都假設落在某 instance 上，實務上「點到背景」沒有保證語意。
- 組合最佳化 (set cover + dominating set 去重) 靠「集合小」才可行，scalability 是隱憂（作者自承）。
- 資料規模偏小 (test 像素 數百級)，雖然 conformal 對 calib size 敏感、有限樣本版有形式保證，但實證涵蓋面不算大。

對本人的 take-away (一句話)：這是 CRS 最該引、也最該主動區隔的「同型保證、鄰近任務」論文。它證明「set ≥ 1 命中」是 conformal 的標準骨架（所以 CRS 不靠這句話取勝），同時它缺 abstention、缺 cross-base、是像素而非語言 query——這三點正好是 CRS 的差異化護城河。技術上值得偷學的是「去重 + 重新校準 $\tilde{\theta}$ 」與「 α - τ 可行性 frontier」兩個乾淨技巧，以及「為何單參數 LTT 不夠」的論證模板。