

論文精讀筆記：視覺基礎模型是好的 Conformal Predictor 嗎？

本筆記為 CRS 碩論 (Cross-Base Conformal Referring Set · 凍結 VL grounding base 上的 post-hoc conformal risk control) 之外部文獻精讀 · 重點在抽取「**post-hoc risk control** 優於重校準 **base** 分數」這條主張的外部支撐與 caveat。

一、書目、問題定義與動機

書目

- 標題：Are foundation models for computer vision good conformal predictors? (已查證標題完全一致)
- arXiv：2412.06082 · 版本 **v3** · **2026-02-16** (cs.CV) · 授權 CC BY 4.0
- 作者：Leo Fillioux、Julio Silva-Rodríguez、Ismail Ben Ayed、Paul-Henry Cournède、Maria Vakalopoulou、Stergios Christodoulidis、Jose Dolz
- 單位：MICS, CentraleSupélec, Université Paris-Saclay；LIVIA / ILLS, ETS Montréal
- 注意：Silva-Rodríguez (few-shot CLIP / CLAP 作者) 與 Ben Ayed、Dolz 是 VLM few-shot adaptation 與 calibration 領域的核心團隊 · 本文的 few-shot 與 calibration 視角有強烈的「VLM 適配可靠性」背景。

問題定義

基礎模型 (DINO、DINOv2、ViTReg、CLIP 等) 正大量進入高風險、安全敏感場景 · 但其**不確定性建模能力**鮮少被系統性研究。Calibration (校準 · 如 Temperature Scaling) 雖普及 · 卻**缺乏理論保證**；Conformal Prediction (CP) 能在 exchangeability 假設下提供**邊際覆蓋 (marginal coverage) 的有限樣本保證** · 且直接作用在模型輸出 (適合黑箱)。然而 CP 在「視覺基礎模型」上的行為此前幾乎無人探討 (既有研究多聚焦傳統監督式模型 · 或只在 LLM 上做過 CP)。

核心研究問題

「在視覺基礎模型時代 · 我該用哪個 CP 方法 · 哪個模型 · 能期待什麼結果？」並特別檢視三個實務常見情境對 CP 的衝擊：分布偏移 (domain shift)、信心校準 (calibration)、few-shot 適配。

動機相對於 calibration 的立論 (與 CRS 高度相關)

本文明確把 CP 與 calibration 並列為兩種不確定性量化路線 · 並指出 CP 三大優勢：1. **直接作用於模型預測** · 適合黑箱模型 (不需重訓、不需碰模型內部)。2. 產出**預測集合**而非單一點校正 · 含最可能的若干類別。3. 在 exchangeability 下有**邊際覆蓋的理論保證** · calibration 沒有。

這正是 CRS「凍結 base + post-hoc 風險控制」的同源哲學。

二、方法與實驗設定

2.1 測試的基礎模型 (共 17 個)

- **DINO** (自監督 · ViT)：DINO-S、DINO-B (2 個)
- **DINOv2**：DINOv2-S/B/L/G (4 個)
- **ViTReg** (自監督 · CNN backbone)：ResNet-50、ResNet-50x2、ResNet-200x2 (3 個)
- **VLM** (8 個)：5 個 CLIP、MetaCLIP、LLaVa、Phi
- 對照組：在 ImageNet 上以**標準監督式訓練**的 ViT-B (與基礎模型同架構 · 做公平比較)

適配方式：基礎模型**全部凍結 (frozen)** · 僅在每個資料集上訓練一個 **Linear Probing (LP) 頭** (一層線性 + softmax · cross-entropy)。這點與 CRS 的「凍結 base」設定極為類似——模型本體不動 · 只在輸出端做事。

2.2 Conformal 方法 (3 種非一致性分數)

1. **LAC** (Least Ambiguous Classifier, Sadinle 2018) : $S = 1 - \pi_x(y)$, 等價於對真類 softmax 做門檻。集合最小, 但無自適應性 (固定門檻) , 在罕見類/不確定預測上覆蓋不穩。
2. **APS** (Adaptive Prediction Sets, Romano 2020) : $S = \rho(x, y) + \pi_x(y) \cdot u$, 累加排序後比 y 更可能的類別之信心, 含 tie-break 隨機量 u 。自適應, 犧牲效率換取對不確定預測的覆蓋。
3. **RAPS** (Regularized APS, Angelopoulos 2020) : 在 APS 上加 $\lambda(o(x, y) - k_{\text{reg}})^+$ 正則項, 超過某集合大小後懲罰加入不可能類別, 壓縮集合大小。

(注意: 本文標題列了 THR/LAC 的脈絡, 但實際只實作 LAC / APS / RAPS 三種; THR 即 LAC 這類 thresholding 家族的代表。)

2.3 資料集

- 主分析: CIFAR-10、CIFAR-100、ImageNet
- **Domain shift**: ImageNet-R、ImageNet-A、ImageNet-Sketch、ImageNet-V2
- **few-shot** (11 個下游細粒度/通用分類): SUN397、FGVCAircraft、EuroSAT、StanfordCars、Food101、OxfordPets、Flowers102、Caltech101、DTD、UCF101 (加上 ImageNet)

每個資料集切成: 訓練集 / conformal 集; conformal 集再切 **calibration 集** (調 CP) 與 **test 集** (評估)。

2.4 評估指標 (如何量 set efficiency 與 coverage)

- **Set size** (效率, $\downarrow$): 測試集上平均預測集合大小 (公式 7)。
- **Coverage** (覆蓋, $\uparrow$): 真類落在集合內的比例 (公式 8) , 目標 = $1 - \alpha$ 。
- **CovGap** (覆蓋落差, $\downarrow$): 各類別 class-conditional coverage 與 $(1 - \alpha)$ 之平均絕對差 (公式 9) —— 衡量條件覆蓋是否均勻。
- **MCCC** (最小類別條件覆蓋, $\uparrow$): 所有類別中最差的 class-conditional coverage (公式 10)。

主實驗目標覆蓋率多設 $1 - \alpha = 0.90$ (表中 coverage 欄皆 0.900)。

三、完整關鍵發現

論文摘要列出 6 條 key observation, 逐條展開:

(i) 基礎模型本身就是好的 conformal predictor

高效能模型 (LP accuracy 高) $\rightarrow$ 一致地產出更小的預測集合, 與 CP 方法無關。且自監督/對比學習的基礎模型優於傳統監督式訓練的同架構模型: - 表 1 (ImageNet, ViT-B 同架構公平比較): 監督式 ViT_ImageNet 雖 accuracy 最高 (76.08%) , 但其 **APS set size** 暴增到 38.75 (CLIP 9.50、DINO-S 10.02、MetaCLIP 9.43) , class-conditional coverage 也明顯較差。- 圖 3 顯示這種 set size 差異是大量樣本的系統性現象, 不是少數離群點。- 結論: 訓練範式 (pre-training scheme) 對 conformal 性質的影響比單純 accuracy 更關鍵。

(ii) APS 覆蓋最穩、RAPS 集合最小 (方法層排序)

- **APS**: empirical coverage / 條件覆蓋最佳, 但 set size 最大。
- **RAPS**: set size 表現最好 (接近 LAC) , 但代價是條件覆蓋範圍變大 (CovGap 變差)。
- **LAC**: 集合最小, 但因無自適應機制, 各類覆蓋率不一致、CovGap 變異大。
- 機制論證: RAPS 的懲罰項使低 accuracy 模型無法為困難類別擴張集合, 導致 MCCC 被壓低 (圖 2 在 CIFAR-100 上實證); APS 則靠擴大集合來補償弱模型, 犧牲效率換條件覆蓋。

(iii) Domain shift 下 APS 最穩健 (覆蓋面)

- 在 ImageNet-R/A/Sketch/V2 上 (calibration 用乾淨 ImageNet、test 用偏移版本, 刻意破壞 exchangeability):

- APS 幾乎一致地維持目標覆蓋 (圖 5 中段) · 但 set size 隨域複雜度大幅膨脹。
- RAPS 表現接近 LAC · 多個模型/域下邊際覆蓋低於目標。
- 圖 4 : ImageNet-A 上 APS 的條件覆蓋分布呈高斯狀 (偏離 $1-\alpha$ 的類別數遞減) · RAPS 則近乎均勻散布且有不可忽略比例的類別跌破目標覆蓋——RAPS 在 OOD 下條件覆蓋結構明顯較糟。
- VICReg (CNN backbone) 在 domain shift 下最差 (更大集合、更低覆蓋) · 呼應 (vi) 。

(iv) 【最關鍵】Calibration (Temperature Scaling) 會降低 CP 集合效率

這是全文與 CRS 立論最直接相關的發現：- 設定：對 §4.2.1 的 ImageNet 結果套用 TS · 掃 $T \in [0.85, 2]$ (14 個值) · 找到 $T=1.1$ 為典型良好校準點 (ECE 下降) 。 - 表 2 結論：模型一旦被 (更好地) 校準，預測集合反而變大，尤其對自適應方法 (RAPS · 特別是 APS) 。例如：- DINOv2-B : APS set size **7.50** → **10.46** (校準後變大) ; - DINOv2-L : APS **6.77** → **9.67** ; - CLIP(ViT-B) : APS **9.50** → **11.11** 。 - LAC 的 set size 幾乎不變 (固定門檻對全域縮放不敏感) 。 - 圖 6 : 校準前後 set size 差異是橫跨樣本的一致性退化，非少數異常樣本造成。 - 機制：TS 平滑 softmax → 預測更不自信 → 主導類別機率下降 → APS 累加更多類別才達到 $1-\alpha$ 門檻 → set size 單調隨 T 上升。 - 代價/補償：校準確實略微改善 **class-conditional coverage** (MCCC 微升) 與 **CovGap** (圖 7 : APS 在 $T=1.1$ 的 CovGap 0.0567 · 接近其最佳 0.0561) 。但 set efficiency 被犧牲。 - 作者立場：在關鍵決策系統中，「適度增大集合換取更好的覆蓋落差」是可接受的取捨；但就效率 (CP 文獻最看重的指標) 而言，**calibration** 是傷害自適應 CP 的。

一句話總結：對 frozen FM 做信心校準 (重新縮放分數) · 會降低自適應 conformal 集合的效率。

(v) Few-shot 適配的 conformal 分數優於 zero-shot (ID 明顯、OOD 邊際)

- 表 3 (CLIP ViT-B) : 相對 zero-shot (ZS) · few-shot 方法 (Adapters: ZSLP/CLAP ; Prompt Learning: CoOp/KgCoOp) 在 ID 情境一致地產出更小 set size 與更小 CovGap :
 - ID APS set size : ZS **6.98** → CoOp **2.87**、ZSLP **3.43** ; ID APS CovGap : 0.094 → 0.059 。
- OOD 情境：只有 APS 一致改善 ZS 的 set efficiency (APS set size 19.22 → 16~17) · CovGap 改善有限。
- 機制連結：呼應 (iv)——Murugesan 2024a 已證 few-shot CLIP 適配會惡化信心估計 (變得 **overconfident**) ; 依本文邏輯，更不校準 (更尖銳的 softmax) 反而對應更小的 conformal 集合，表 3 正好驗證此因果方向。

(vi) ViT 系 (DINO/CLIP) 在 domain shift 下退化幅度小於 CNN 系 (VICReg)

- 含 visual transformer 的基礎模型在 conformal 指標上對域偏移更穩健；CNN backbone (VICReg) 退化最嚴重。

結論 (§5)

- 視覺基礎模型的 conformal 指標優於傳統預訓練對應物，ViT 系 > CNN 系，尤其在域偏移下。
- 分布偏移與信心校準對「某些」CP 方法有害；APS 對這些情境最穩健 (特別是條件覆蓋) · 代價是效率退化。
- 最終選擇取決於任務需求 (如醫療診斷偏好最大化條件覆蓋、容忍大集合) 。

四、對 CRS 的意涵

4.1 哪些發現「支撐」CRS「post-hoc risk control 優於重校準 base 分數」?

支撐點 A (最強) —Finding (iv) : 校準傷害自適應 CP 效率。本文用 17 個 frozen FM、TS 校準、ImageNet 系統性證明：對凍結基礎模型的分數做重新縮放 (**recalibration**) · 會一致性地降低自適應 conformal 集合的效率 (APS/RAPS set size 全面變大 · 表 2 + 圖 6) 。CRS 選擇「不去重校準 base 的原始分數，而是直接在凍結 base 上做 post-hoc 風險控制 (LTT/conformal) 」——本文正好提供獨立的、跨多模型的反面證據：「先校準再 conform」這條路會犧牲效率。可直接作為 CRS「不重校準 base」這一設計選擇的外部背書。

支撐點 B —CP 直接作用於黑箱輸出的哲學 (§1, §2) 。本文反覆強調 CP 相對 calibration 的優勢：直接作用模型預測、適合黑箱、有理論覆蓋保證。這與 CRS「凍結 base、post-hoc」哲學同源，可引用為 motivation 層的範式立論。

支撐點 C —Finding (i) + 表 1 : 凍結基礎模型本身就是好的 conformal 基底。LP-on-frozen-FM 的 conformal 指標優於監督式重訓模型。這支撐 CRS「凍結 base 而非重訓/微調」的合理性——重訓不是 conformal 效率的必要條件，甚至可能更差。

支撐點 D —Finding (iii) : APS 在 domain shift 下最穩健 (維持覆蓋)。CRS 強調「在分布變動下仍要守住召回/覆蓋保證」。本文證明自適應 CP (APS) 在破壞 exchangeability 時仍近乎維持邊際覆蓋 (靠擴大集合)。這支撐 CRS 「靠 conformal/risk control 而非靠校準分數來守覆蓋」的策略選擇。

4.2 Caveat : 從「分類」外推到「grounding」的鴻溝 (必須誠實揭露)

這是引用本文時最重要的限制，審稿人很可能質疑：

1. 分數型態不同。本文的非一致性分數全建立在多類別 softmax 機率 $\pi_x(y)$ (K 個互斥類別、總和為 1 的封閉分布)。CRS 用的是 grounding/detection 分數 (OWL-ViT 的 query-region 相似度、GroundingDINO 的 box logit)。這些不是封閉的 softmax 分布，沒有「對所有類別累加」的天然語意。APS/RAPS 的「排序累加機率」機制無法原樣搬過來。因此本文「APS 最穩 / calibration 傷效率」的具體數值結論不能直接外推到 grounding 分數。
2. 輸出空間結構不同。本文 prediction set 是「類別子集」；CRS 的輸出是「referring set / box 集合」與棄答 (abstention/no-target)，且 CRS 用 LTT (Learn-then-Test) 做風險控制，是 risk control (控 FNR/FDR 等損失) 而非單純 marginal coverage 的 conformal。本文未觸及 LTT 或多風險 Bonferroni 校準。
3. 校準對象的可比性。本文證的是「對 softmax logits 做 TS 會傷 APS 效率」。CRS 的 base 分數未必是過自信的 softmax (grounding score 的尺度與分布很不同)。「校準會傷效率」的因果鏈 (平滑 softmax $\rightarrow$ 累加更多類) 在 grounding 設定下不必然成立。所以本文只能作為「重校準分數不是免費午餐、且在 frozen FM 上常有反效果」的類比性/精神性支撐，不能宣稱「已在 grounding 上證實」。
4. 可信度層級。本文是實證 survey/benchmark，非新方法論文；結論是經驗觀察 (observation)，其機制論證 (如 RAPS 懲罰壓低 MCCC) 是 plausible argument + 實證圖佐證，非嚴格定理。引用時宜定位為「經驗證據顯示」而非「理論證明」。

4.3 該怎麼引用、放哪裡？

- 放 Motivation (首選)：用本文支撐「為何選 post-hoc conformal/risk control 而非重校準 base 分數」。一句範例敘述：> 「近期對視覺基礎模型的大規模 conformal 研究 [Fillioux et al., 2026] 指出，對凍結基礎模型做信心校準 (如 Temperature Scaling) 會一致性地降低自適應 conformal 集合的效率；few-shot 適配雖惡化校準卻反而改善 conformal 分數。這暗示在凍結基礎模型上，重新校準原始分數並非取得可靠不確定性的最佳路徑，從而支持本文採取 post-hoc 風險控制、保持 base 分數不動的設計。」
- 可在 Method Justification 輔助一句：解釋 CRS 為何「不對 OWL/GroundingDINO 分數做 TS/Platt 重校準，而是直接在其上做 LTT」。但務必加 caveat 句，聲明本文結論建立在分類 softmax，CRS 設定為 grounding 分數，故僅作為精神性/類比支撐，CRS 的對應現象由本文自身實驗 (2×2 ablation、cross-base composition) 證成。
- 不要用本文宣稱 APS/RAPS 的數值結論在 grounding 上成立，也不要拿來當「CRS 方法正確性」的證據——它只支撐設計取向 (不重校準)，不支撐 CRS 的具體機制。

4.4 引用優先級

- 中高優先 (建議納入)：作為 motivation 的關鍵外部佐證之一，特別是 §3.x 解釋「為何 post-hoc、為何不重校準 base」時。它是少數直接在 frozen FM + CP 上做系統實證的文獻，新近 (v3, 2026-02)、來源權威 (CLIP few-shot/calibration 核心團隊)，時效性與相關性都好。
- 不必當主引用：因分類 $\rightarrow$ grounding 的外推鴻溝，不宜作為 CRS 核心主張的唯一支柱，宜與 CRS 自身證據並列。

五、個人評價

可信度

- 高：17 個模型 × 3 CP 方法 × 多資料集 × 4 種情境 (標準/域偏移/校準/few-shot) 的廣度紮實；指標定義標準 (coverage/set size/CovGap/MCCC)；coverage 恆守 0.90 的保證在表中明確呈現，符合 CP 理論。
- 機制論證 (RAPS 懲罰壓低弱模型 MCCC、TS 平滑 $\rightarrow$ APS 集合膨脹) 有圖 2/6 的樣本級分布佐證，不只是平均數字，說服力佳。

- 作者群在 VLM few-shot / calibration 領域有深厚 track record (Silva-Rodríguez 的 CLAP、Ben Ayed/Dolz)，few-shot 與 calibration 的因果連結 (呼應 Murugesan 2024a) 有內部一致性。

限制

1. 僅分類任務：無偵測/grounding/分割，對 CRS 是最大外推風險 (見 4.2)。
2. 公平比較的內在難題：作者自承監督式 ViT 與基礎模型的訓練資料規模不同 (ImageNet 無法訓出 FM)，表 1 的「FM 優於監督式」結論受此 confound 限制。
3. **calibration** 只測 **TS + histogram binning** (附錄)：未涵蓋訓練期校準、其他 post-hoc 方法，「校準傷效率」的普適性有邊界。
4. **T=1.1** 的選取：無正式 validation set，靠掃格 + 對齊文獻先驗 (TinyImageNet) 決定，略有主觀。
5. **APS** 的「穩健」帶嚴重效率代價：domain shift 下 APS set size 可膨脹數倍 (如 OOD set size 19.22)，實務可用性需打折扣——這點對 CRS 也是提醒：靠擴大集合守覆蓋，size CI 會變大。

一句話定位 (for CRS)

本文是 CRS「不重校準凍結 base 分數、改採 **post-hoc** 風險控制」這一設計取向的**最佳近鄰外部佐證**——它在分類域、跨 17 個 FM 上實證了「校準會傷自適應 CP 效率、few-shot (更不校準) 反而改善 conformal 分數」。引用時務必標明「分類 softmax → grounding 分數」的外推 caveat，把它放在 motivation 作精神支撐，而非 CRS 機制正確性的證據。

精讀來源：arXiv:2412.06082v3 全文 (*firecrawl* 抓取 HTML，含 abstract、§1–§5、表 1–3、圖 1–7 文字描述)。