

Grounding DINO 1.5 詳細導讀

整理：kuo

2026-06-19

Grounding DINO 1.5 —Advance the “Edge” of Open-Set Object Detection (詳細導讀)

0. 論文基本資訊

- 論文標題：Grounding DINO 1.5: Advance the “Edge” of Open-Set Object Detection
- 作者：Tianhe Ren, Qing Jiang, Shilong Liu, ...Lei Zhang (IDEA Research Team)
- 單位：International Digital Economy Academy (IDEA), IDEA Research
- arXiv：2405.10300v2 (v2 提交於 2024-06-01 · **Technical report**)
- API/Repo：https://github.com/IDEA-Research/Grounding-DINO-1.5-API (API-gated)
- 任務範疇：open-set object detection (text-prompt → box)

註：reading-log 把這篇定為「新 base 實驗標的首選」(取代被排除的 VL-SAM-v3)。本篇任務 = 評估它當 CRS 第四個 frozen base 的可行性，而非方法精讀。結論見 §4。與 read-vlsamv3-summary.md (排除原因)、後繼 read-dino-x-summary.md (次選) 互讀。

1. 一句話定位

GD-1.5 是 Grounding DINO 的放大續作：把 vision backbone 換成 ViT-L、訓練資料擴到 20M+ **grounding** 標註影像 (**Grounding-20M**)，分 **Pro** (高效能泛化) 與 **Edge** (邊緣部署) 兩款。核心架構沿用 GD 的 dual-encoder-single-decoder + GLIP 式「detection 當 phrase grounding」+ deep early fusion + box contrastive loss。

2. 兩個模型

2.1 GD 1.5 Pro

- ViT-L backbone + deep early fusion (decode 前就 cross-attention 融合語言/影像)。
- **early vs late fusion** 的關鍵觀察 (對 CRS 最有用)：

- early fusion → **higher detection recall** + 更準的 **box**，但 更容易幻覺 (預測不存在的物件)。
- late fusion → robust 抗幻覺，但 recall 較低 (跨模態對齊較難)。
- 折衷：保留 early fusion，但訓練時提高負樣本比例來平衡。

2.2 GD 1.5 Edge

- EfficientViT-L1 backbone + 新 efficient feature enhancer (只融合 P5 高階特徵、vanilla self-attention 取代 deformable、cross-scale fusion 補 P3/P4)。
- TensorRT 下 75.2 FPS ; NVIDIA Orin NX 上 >10 FPS @640²。

3. 主要結果 (皆 detection benchmark，非 REC)

Benchmark	GD 1.5 Pro	備註
COCO zero-shot	54.3 AP	+1.8 over GD Swin-L
LVIS-minival zero-shot	55.7 AP	+6.9 over DetCLIPv3
LVIS-val zero-shot	47.6 AP	+6.2 over 前 SOTA
ODinW35 / ODinW13	30.2 / 58.7 AP	open detection in the wild
GD 1.5 Edge LVIS-minival	36.2 AP	勝所有即時開集偵測器

□ 全文無 RefCOCO/RefCOCO+/gRefCOCO/REC 評測——它評的是 category/phrase 偵測 (COCO/LVIS/ODinW)，不是 referring expression comprehension。

4. 對使用者主線 (CRS) 的可行性裁定

CRS 主線見 [[crs-pivot-conformal-referring-set]] / [[crs-litreview-15papers]]；現有 base = OWL-ViT gate + GroundingDINO box。

4.1 當第四個 frozen base：有條件可行，但比 reading-log 原本想像的更受限

維度	裁定
介面相容	□ 吃自然語言 text prompt、出 box，與現有 GD box base 同家族同介面 (GD→GD-1.5 是直系升級)，整合風險低——這是 reading-log 選它為首選的主因，成立。

維度	裁定
frozen 可用	□ 部分。論文是 technical report，Pro 僅 API-gated (無公開權重)；要當「凍結本地 base」跑 calibration/大量推論，得靠 API (成本/速率/可重現性風險)。Edge 也未明確釋出 checkpoint。對比現有 GroundingDINO (開源權重) 這是退步。
分數異質性	□ box contrastive score 與現有 GD 同源 → 但這也意味與現有 GD box base 分數同質，當「第四個異質 base」強化 cross-base 的價值有限 (不如 DINO-X 換 CLIP text encoder 來得異質)。
REC 適配	□ 無 RefCOCO 證據；GD 家族本身可做 REC，但要自行在 gRefCOCO 上驗證 no-target/multi-target 行為。

4.2 最有價值的 take-away (不只可行性)

early-fusion → 高 recall 但高幻覺；**late-fusion** → 抗幻覺但低 recall 這個 tradeoff 是 CRS motivation 的外部佐證彈藥：- 它白紙黑字說明「更強的 grounding base (high recall) 天生伴隨更多幻覺 (FP)」——正好呼應 CRS「base 越強越需要在輸出端加 recall + abstention 雙保證」的核心論點。- 可寫進 motivation：連 SOTA 偵測器作者都承認 recall/hallucination 是結構性 tradeoff，靠訓練負樣本只能「平衡」不能「保證」——這正是 CRS 用 LTT 給有限樣本保證要補的洞。

4.3 建議

1. 若要加第四 base 強化 cross-base 異質性 → 優先 **DINO-X** (CLIP text encoder · 分數更異質) 而非 **GD-1.5** (GD-1.5 與現有 GD box 太同源)。
2. **GD-1.5** 的最佳用途是 **motivation** 引用 (early/late fusion 的 recall-hallucination tradeoff)，而非當 base。
3. 若仍要當 base，務必先確認權重可得性 (API vs 本地)，否則 frozen-base 的可重現性故事會被審稿人質疑。

引用優先級：中 (motivation 引用 recall-hallucination tradeoff；當 base 退居次選，異質性不足 + API-gated)。

5. 一句話總結

GD-1.5 是 Grounding DINO 的 ViT-L + 20M 資料放大續作 (Pro/Edge 兩款)，在 COCO/LVIS/ODinW 偵測 benchmark 刷新開集偵測 SOTA——但它是 **API-gated** 的 technical report、無 RefCOCO/REC 評測、box score 與現有 **GD base** 同源，當 CRS「第四個異質 frozen base」性價比不如 DINO-X。它真正對 CRS 有價值的是 **early-fusion** 高 recall 必伴高幻覺的 tradeoff

自白，可當 CRS 「base 越強越需 recall+abstention 雙保證」的 motivation 外部佐證。

6. 參考連結

- arXiv : <https://arxiv.org/abs/2405.10300>
- API/Repo : <https://github.com/IDEA-Research/Grounding-DINO-1.5-API>
- 前作 Grounding DINO : arXiv 2303.05499
- 後繼 DINO-X : [read-dino-x-summary.md](#) (arXiv 2411.14347)