

Does Object Grounding Really Reduce Hallucination of LVLMs? 詳細導讀

整理：kuo

2026-06-19

Does Object Grounding Really Reduce Hallucination of Large Vision-Language Models? (詳細導讀)

0. 論文基本資訊

- 論文標題：Does Object Grounding Really Reduce Hallucination of Large Vision-Language Models?
- 作者：Gregor Geigle, Radu Timofte, Goran Glavaš
- 單位：University of Würzburg (WüNLP / Computer Vision Lab, CAIDAS)
- arXiv：2406.14492v1 (提交於 2024-06-20；後收錄於 EMNLP 2024 Findings)
- 任務範疇：實證檢驗「grounding 目標能否減少 LVLM 物件幻覺」這個流行宣稱

註：reading-log 把這篇定為「framing/動機」標的。它對 CRS 的價值 = 一篇打臉「**grounding** 自動帶來可靠性」的實證論文，正面背書 CRS「光靠更強 grounding 不夠、必須在輸出端加保證」的立論。與 read-gd15-summary.md (recall-hallucination tradeoff)、read-dino-x-summary.md 的 motivation 鏈合流。

1. 核心主張與動機

1.1 被檢驗的宣稱

近期一系列工作 (Chen et al. 2023b、You et al.、Pramanick et al.) 宣稱：把 **grounding** 目標 (如 referring expressions、grounded captioning) 加進 LVLM 訓練能減少物件幻覺。直覺上合理——region-level 目標要求比 global captioning 更細粒度的影像理解，應該會抑制「無中生有」。

1.2 本文的質疑：這個宣稱建立在有瑕疵的評估協議上

作者指出既有「減幻覺」證據有兩大缺陷：1. 資料污染：都用 **MSCOCO**——而 MSCOCO 早已大量進入 LVLM 訓練混合，模型對它先天較不幻覺 → 低估真實幻覺。2. 評估方式失準：

用 QA 式 (POPE : 「圖中有 X 嗎？」yes/no) 衡量，而非開放式 caption 生成——QA 是「未經驗證的 proxy」，與真實世界自由生成任務對不上。

1.3 本文貢獻：第一個健全協議下的系統分析

- 控制變因：同一架構/訓練流程，只切換 grounding 資料的有無 (Base vs +RE vs +GC vs +RE+GC)。
- 三個 LLM backbone (Vicuna-1.5-7B、Llama-3-8B、Phi-3-mini) 增強可轉移性。
- OOD 評估：除 MSCOCO 外加 Objects365 (365 類，含 80 COCO 類) 作分布外資料。
- 雙幻覺指標互補：CHAIR (+ 自提的語意版 CHAIR-MEN，用句子編碼器 cosine 取代字串比對，可擴大類別集) + FaithScore (LLM 抽 atomic facts → VQA 驗證)。並用 CIDEr/CLIPScore/coverage 監控 caption 資訊量。

2. 核心發現

三個 backbone 一致：在健全協議下，grounding 目標 (RE/GC) 對開放式 caption 的物件幻覺幾乎無影響 (little to no effect)，QA 與開放生成皆然。

細節：1. 訓練時加 grounding 目標 → CHAIRi、FaithScore、caption 品質 (CIDEr/CLIPScore)、資訊量幾乎都沒差 (Table 3)。2. 推論時強制生成 grounded caption (caption 中插入 box 座標) → 略減幻覺，但效果小，且犧牲 caption 細緻度 (faithfulness ↔ informativeness tradeoff)。3. 定性檢查：逼模型為提到的物件生 box，多數情況仍無法阻止它幻覺內容 (生了 box 還是亂講)。4. 方法論收穫：CHAIR-MEN 與 vanilla CHAIR 高度成比例 → 驗證語意匹配可作為大類別集 (如 Objects365) 的可擴替代。

結論：grounding 目標未能有意義地降低 LVLM 幻覺，呼籲新的減幻覺方法。

3. 對使用者主線 (CRS) 的對位與借鏡

CRS 主線見 [[crs-pivot-conformal-referring-set]] / [[crs-litreview-15papers]]。

3.1 最強用途：motivation 的「反面背書」

這篇是 CRS framing 的核心彈藥：- 它實證「把 grounding/referring 目標塞進訓練不會自動帶來可靠性 (不減幻覺)」。- → 直接支撐 CRS 立論：「可靠性不是靠更強/更多 grounding 訓練就能得到的；必須在輸出端外加分布無關保證 (LTT recall+abstention)」。- 可寫進 introduction/motivation：「即使是專門設計的 grounding 目標，在健全評估下都無法保證模型不幻覺 (Geigle et al. 2024)；這說明 reliability 是一個正交於 grounding 能力的問題，需要 post-hoc 的形式化保證來補。」

3.2 與既有閱讀的 motivation 鏈

構成一條完整的「grounding $\neq$ reliability」論證鏈：- **GD-1.5** (read-gd15-summary.md)：偵測器作者自承 early-fusion 高 recall 必伴高幻覺 (架構層 tradeoff)。- 本文：訓練目標層——加 grounding objective 也不減幻覺 (訓練層無效)。- **CRS**：→ 既然架構與訓練都解不掉，只能在輸出端加有限樣本保證。

3.3 方法論借鏡

1. **健全評估協議的警示**：本文證明「在訓練見過的資料 (MSCOCO) 上評估會低估失效」。CRS 必須注意 **RefCOCO 飽和/捷徑問題** (呼應 reading-log 核心問答「92.7% 有水分」)，且最好補 OOD / 跨域資料 (正好接到 AgroVG 跨域 GREC，見後續 read-agrovg-summary.md)。
2. **faithfulness $\leftrightarrow$ informativeness tradeoff**：與 CRS 的 recall $\leftrightarrow$ set-size / abstention tradeoff 同構——「為了不幻覺而棄答/縮集合」會犧牲資訊量，CRS 的 Pareto 曲線 ([[crs-redteam-p0-fixes]] 的 crs_pareto.png) 正是量化這個取捨，本文給了同型 tradeoff 的外部佐證。
3. **CHAIR-MEN 的語意匹配思路**：CRS 若需在開放詞彙下判斷「referring set 是否命中正解」，語意 cosine 匹配 (取代 exact match) 是可借鏡的 nonconformity 設計 (但 CRS 主要用 IoU/box，影響有限)。

3.4 引用注意

- 本文談的是 **LVLm caption 幻覺** (生成式)，不是 REC box 定位的可靠性——任務不同。引用時要框成「reliability 與 grounding 能力正交」的類比/**motivation**，不可暗示它直接量測了 REC 的保證問題 (否則被審稿人抓 over-claim)。

引用優先級：中高 (motivation 核心反面背書；framing 用，非方法/競品)。

4. 一句話總結

這篇用三個 LLM backbone + OOD 資料 (Objects365) + 雙互補指標 (CHAIR-MEN/FaithScore) 的健全協議，實證打臉「把 **grounding/referring** 目標加進 LVLm 訓練能減少幻覺」這個流行宣稱——在開放式 caption 生成下，grounding 目標對物件幻覺幾乎無影響，推論時強制 grounded caption 也只略減且犧牲細緻度。對 CRS 而言這是 motivation 的核心反面背書：**reliability** 正交於 **grounding** 能力，光靠更強/更多 **grounding** 訓練得不到，必須在輸出端外加分布無關保證——與 GD-1.5 的架構層 recall-hallucination tradeoff 接成完整論證鏈。

5. 參考連結

- arXiv : <https://arxiv.org/abs/2406.14492>

- CHAIR : Rohrbach et al. 2018 ; FaithScore : Jing et al. 2023 ; POPE : Li et al. 2023b
- 關聯 : read-gd15-summary.md (recall-hallucination tradeoff)