

InstanceVG 深讀筆記與 CRS 定位分析

一、書目資訊

- 標題：Improving Generalized Visual Grounding with Instance-aware Joint Learning (系統/開源庫名 **InstanceVG**；論文標題本身不含 "InstanceVG:" 前綴，標題即上述句子)
- 作者：Ming Dai (戴明，東南大學自動化學院第一作者)、Wenxuan Cheng、Jiang-Jiang Liu (百度)、Lingfeng Yang (南京理工)、Zhenhua Feng (江南大學)、Wankou Yang (通訊，東南大學)、Jingdong Wang (百度，通訊群)。
- 出處：arXiv 2509.13747 (v1)，標示投往 TPAMI (IEEE Trans. PAMI)，2025。
- 程式碼：<https://github.com/Dmmm1997/InstanceVG> (宣稱將開源 code、model 與重處理後的資料集)。
- 關鍵字：Visual Grounding、Multimodal Transformer、Instance Awareness、Multi-Task Learning。

註：作者群同時是 SimVG (NeurIPS' 24)、PropVG、DeRIS 的作者，InstanceVG 是這條「BEiT-3 fusion encoder 系列」的延伸與集大成之作。

二、問題定義與動機

2.1 任務背景

- 經典 **visual grounding**：REC (Referring Expression Comprehension，輸出單一 bounding box) 與 RES (Referring Expression Segmentation，輸出像素級 mask)，核心假設是「一句話對一個目標」(one-to-one)。
- **Generalized visual grounding (廣義)**：將經典範式擴展到 **multi-target** (多目標) 與 **non-target** (無目標) 兩種情境：
 - **GREC** (Generalized REC)：粗粒度，輸出所有被指涉物件的 bbox。
 - **GRES** (Generalized RES)：細粒度，輸出像素級 mask。
- 應用場景：embodied AI、自駕。

2.2 論文點出的三個缺口 (motivation)

1. **GREC 與 GRES 被獨立處理**：現有方法分別訓練偵測與分割兩個模型，忽略了聯合訓練帶來的「多粒度一致性」與流程精簡。
2. **GRES 被當成語意分割**：現有 GRES (如 ReLA、CoHD) 把所有實例 mask 合併成「單一全域 mask」監督，喪失了 **instance-aware** (實例感知) 能力——多目標時無法區分、定位個別實體。
3. **缺乏 box-mask 一致性機制**：沒有顯式機制保證「同一個實例的預測框與遮罩對應一致」。

2.3 兩個核心研究問題

1. 如何在廣義情境下有效進行 **multi-task** 聯合訓練，精簡流程同時得到互補且實例一致的預測？
 2. 如何設計一個賦予廣義 grounding **instance-aware** 能力的原則性框架，用細粒度監督強化指涉理解？
-

三、方法詳解

3.1 整體架構 (Fig. 2)

InstanceVG = 共享 **multi-modality encoder** + 兩條分支。

- **Multi-Modality Encoder = BEiT-3** (ViT-B / ViT-L)。影像切 patch、文字 tokenize，兩模態特徵串接後丟進 BEiT-3 聯合編碼 (處理細節沿用作者自家的 **SimVG**)。輸出再經影像/文字線性層投影到低維 C ，得 F_i (影像) 與 F_t (文字)。
- 分支 (c) **Global Segmentation Branch** (全域分割分支)：用 **SimFPN** 把 ViT 單層輸出擴成多尺度，接一個簡單 **U-Net decoder** 產生全域語意分割 S_{global} (解析度 $H/4 \times W/4$)。此分支身兼四職：(1) 全域語意分割預測；(2) 判斷是否存在目標 (**non-target** 判別)；(3) 提供多尺度影像特徵給 APD；(4) 與解碼後 query Q_d 互動產生實例語意 query Q_s 。

- 分支 **(a)+(b) Instance Perception Branch (實例感知分支)**：預測 instance box 與 instance mask，由 APD 與 PIPH 兩模組構成。

3.2 APD —Attention-based Point-prior Decoder (注意力點先驗解碼器)

目的：自適應地產生「先驗參考點」並注入 instance query。

(1) IQG —Instance Query Generator (Fig. 3) - Text Filter (Algorithm 1)：從 N_t 個文字 token 中，先去掉 padding，再用 **L2 norm** 分數取 top- N_q 個高響應 token 作為 F_{filter} (不足則 pad)。預設 $N_q = 10$ (因為指涉任務目標數很少超過 10)。- 以 F_{filter} 為 Q、影像特徵 F_i 為 K/V 做 cross-attention 得 attention map M_{attn} ，沿 query 維平均得空間分數圖 M_s 。- **Dynamic Point Selector (Algorithm 2, 貪婪演算法)**：在 M_s 上 sigmoid 後，先取最高分點，之後每步以 $S = M_s + W_{\text{dist}} \times D$ (D 為與已選點的最小距離， $W_{\text{dist}}=0.003$) 選點，兼顧高響應與彼此分散，確保覆蓋所有潛在實例。產出 N_q 個先驗點 P_r 與對應 query。- 作者自訂 **CoverAcc = $(1/N) \sum TP / (TP+FN)$** 衡量點對目標的覆蓋率 (Fig. 4)。證明 dynamic selector 比 TopK 更能覆蓋實例。- 把選到的 query 與 F_q 串接過 MLP 得 instance query Q_{instance} 。

(2) Point-prior Multi-scale Deformable Decoder - 基於 Deformable DETR。關鍵改動：用 IQG 產生的先驗點 p_r 取代 grid 上預設的密集參考點，object query 從隨機 z_q 換成 Q_{instance} 。- 好處：query 數從數百降到 ~ 10 (降算力) + 每個 query 拿到目標中心附近的強位置先驗 (提效能)。輸出解碼後 query Q_d 。

3.3 PIPH —Point-guided Instance-aware Perception Head (點導引實例感知頭)

目的：顯式建立 點 $\rightarrow$ 框 $\rightarrow$ 遮罩 的對應與一致性。

- 實例語意 query： $Q_s = Q_d$ (elementwise) S_{global} (解碼 query 與全域語意特徵點積)。讓 query 抽取全域語意以導引 instance-level 分割。
- **(1) Point-guided Object Matcher (點導引匹配, §3.3.1)**：在 DETR 的匈牙利匹配 cost 上新增點 cost：
 - $C_{ij} = \lambda_{\text{cls}} \cdot \text{CE} + \lambda_{\text{box}} \cdot \text{L1}(\text{box}) + \lambda_{\text{giou}} \cdot \text{GIoU}(\text{box}) + \lambda_{\text{point}} \cdot \text{L1}(\text{point}, \text{center})$
 - $\lambda_{\text{cls}}=1.0, \lambda_{\text{box}}=5.0, \lambda_{\text{giou}}=2.0$ (沿用 DETR)，新引入 **$\lambda_{\text{point}}=2.0$** 。讓參考點盡量靠近目標中心，強化先驗導引。
- **(2) Query-Mask Aligner (§3.3.2)**：利用 box $\leftrightarrow$ mask 的一對一對應，把「query $\rightarrow$ box」的匹配關係 M_{q2b} 傳播成「query $\rightarrow$ mask」 M_{q2m} ，靠 (i) 資料層 gt box 與 gt mask 一對一、(ii) 預測層 Q_d 與 Q_s 順序對齊兩個前提，保證點/框/遮罩一致。

3.4 訓練目標 (§3.4)

四部分損失加權： $L_{\text{total}} = \lambda_{\text{detr}} L_{\text{detr}} + \lambda_{\text{seg}} L_{\text{seg}} + \lambda_{\text{instance}} L_{\text{ins-seg}} + \lambda_{\text{exist}} L_{\text{exist}}$
- **L_{detr}** ：偵測 ($L1 + \text{CE} + \text{GIoU}$ ，DETR 式)。- **L_{seg}** ：全域語意分割 ($\text{BCE} + \text{Dice}$)。- **$L_{\text{ins-seg}}$** ：實例級分割 ($\text{BCE} + \text{Dice}$)，對正樣本算 loss，並用 **$\lambda_{\text{neg}}=0.2$** 加權負樣本 mask 抑制： $L_{\text{ins-seg}} = (1/N_{\text{pos}}) \sum L_{\text{pos}} + (\lambda_{\text{neg}}/N_{\text{neg}}) \sum L_{\text{neg}}$ 。- **L_{exist}** ：non-target 判別 = 二元分類 **BCE loss**，判斷指涉物是否存在。- 權重： $\lambda_{\text{detr}}=0.1, \lambda_{\text{seg}}=1.0, \lambda_{\text{instance}}=1.0, \lambda_{\text{exist}}=0.2$ 。

3.5 後處理 (§3.5, Fig. 5) —與本論文 CRS 最相關的一節

1. query 分數 $\times$ non-target 分數 (dot product) 合併，降低無目標場景的 false positive。
2. 用閾值 **thr_q** 篩出有效 query (index) $\rightarrow$ 偵測分支據此輸出目標。
3. 分割分支：全域 mask 與 instance mask 用閾值 **thr_m** 二值化後，依 index 篩選並做 **logical OR** 合併，補全不完整實例。

關鍵觀察 (給 CRS)：N-acc (無目標正確率) 來自 (a) 一個訓練好的二元 **L_{exist} BCE** 分支的 point estimate，外加 (b) 後處理中 non-target 分數與 **thr_q** 的手動調參融合。完全沒有任何 **calibration / coverage (覆蓋率) / distribution-free 保證**。thr_q 是在 val 集上掃出來的 (見 Table XIII：thr_q 從 0.7 $\rightarrow$ 0.9，F1 由 71.43 升到 74.38)，屬於經驗性閾值選擇，不是統計保證的棄答機制。

四、完整實驗數字

設定：雙 RTX 4090；SOTA 實驗輸入 320×320；GREC/GRES 訓 10 epoch；REC/RES 訓 20 epoch。

4.1 GREC (gRefCOCO · Table VI · 所有方法 score threshold = 0.7)

指標：Pr@(F1=1, IoU≥0.5) (簡稱 F1score) 與 N-acc.

Method	val F1	val N-acc	testA F1	testA N-acc	testB F1	testB N-acc
MCN	28.0	30.6	32.3	32.0	26.8	30.3
VLT	36.6	35.2	40.2	34.1	30.2	32.5
MDETR	42.7	36.3	50.0	34.5	36.5	31.0
UNINEXT	58.2	50.6	46.4	49.3	42.9	48.2
SimVG	62.1	54.7	64.6	57.2	54.8	57.2
PropVG	72.2	72.8	68.8	69.9	59.0	65.0
InstanceVG	73.5	72.8	70.2	71.1	60.8	65.2

這就是使用者記憶中「gRefCOCO GREC val F1 73.5 / N-acc 72.8」的來源，已逐項核實無誤。InstanceVG 比前一代 SimVG 在 val/testA/testB F1 各 +11.4 / +5.6 / +6.0。

4.2 GRES (gRefCOCO · Table III · ViT-B)

指標：gIoU / cIoU / N-acc

Method	Backbone	val gIoU	val cIoU	val N-acc	testA gIoU	testA cIoU	testA N-acc	testB gIoU	testB cIoU	testB N-acc
ReLA	Swin-B	63.60	62.42	56.37	70.03	69.26	59.02	61.02	59.88	58.40
CoHD	Swin-B	68.42	65.17	63.68	72.67	71.85	64.00	63.60	62.63	60.37
PropVG	BEiT3-B	73.29	69.23	72.83	74.43	74.20	69.87	65.87	64.76	64.97
DeRIS	Swin-S+BEiT3-B	74.10	68.06	77.03	73.72	71.99	75.98	65.63	64.65	63.44
InstanceVG	BEiT3-B	73.36	69.22	72.84	75.21	74.51	71.09	66.74	65.67	65.18

對 CoHD：val/testA/testB gIoU 各 +4.9 / +2.5 / +3.1。注意 **N-acc** 在 **GRES** 上 **InstanceVG (72.84)** 其實略輸 **DeRIS (77.03)**，論文宣稱「all metrics SOTA」需小心解讀——它的優勢主要在 gIoU/cIoU。

4.3 其他任務 (佐證「10 資料集 4 任務 SOTA」主張)

- **REC (RefCOCO+/+g · Table I · Prec@0.5)**：ViT-L 版 val/testA/testB = RefCOCO 94.42/96.04/92.39、RefCOCO+ 90.12/92.89/85.94、RefCOCOg 89.58/90.62 (**zero fine-tune** · 僅 **28K pre-train**) · 勝 OneRef-L、SimVG-L。
- **RES (RefCOCO+/+g · Table II · mIoU)**：ViT-L 版 RefCOCO 86.27/87.12/85.30 等 · 勝 OneRef-L、DeRIS-L。
- **Ref-ZOM (Table IV)**：oIoU 71.52 / mIoU 71.12 / Acc 97.42 · 勝 CoHD、GSVA-7B。
- **R-RefCOCO+/+g (Table V)**：rIoU 62.41/59.13/54.36 · 與 PropVG 互有勝負 (rIoU 對 CoHD +8.8/+10.0/+12.2)。

4.4 重要 ablation (解釋方法有效性)

- 核心模組 (Table VII · 224×224): baseline 65.98 → +Multi-Task 67.13 → +APD 69.17 → +PIPH **71.43** F1 (gIoU 65.03→72.41)。
- 不同 backbone (Table XVII): CLIP-ViT-B、ViLT-B、BEiT3-B 加上 APD+PIPH 模組都一致提升 (如 BEiT3-B 67.13→71.43)。證明模組是 backbone-agnostic。
- 後處理閾值 **thr_q** (Table XIII): 0.70→0.90 · F1 71.43→74.38 (val 集調出來的, 非保證)。
- 參數量 (Table XVI): APD+PIPH 僅 ~3M (佔總參數 1.6%) · 算力佔 7.6% · 總模型 ~182.7M params。

4.5 論文自承的限制 (Conclusion)

1. 目標存在性判別準確度不足 (即 N-acc 還有很大空間)。
2. 小物件感知能力有限 (受輸入解析度與早期 16× 降採樣所限)。
3. 細粒度分割不足 (ViT patch embedding 壓縮造成資訊損失)。

五、與 CRS 的逐項 diff 表

面向	InstanceVG (本論文, 現任 GREC SOTA)	CRS (使用者碩論: Cross-Base Conformal Composition)
訓練範式	Trained end-to-end, 整個 BEiT-3 + APD + PIPH 一起 fine-tune (10 epoch, 雙 4090)	Frozen post-hoc : OWL-ViT gate + GroundingDINO box 全程凍結, 零重訓
base 數量	單一統一模型 (single model)	Cross-base composition : 兩個異質 frozen base 組合 (OWL gate 控棄答、GD box 控緊緻集合)
輸出形式	點估計: 一組 box/mask + 二元 existence 旗標	Conformal referring SET (符合保證的指涉集合)
No-target / 棄答機制	訓練好的 BCE existence 分支 (L_exist) + 後處理 thr_q 手動掃出的閾值融合	LTT (Learn-then-Test) 校準的 abstention, 具 distribution-free 棄答保證
N-acc 性質	Point estimate , 無覆蓋保證; 論文自承「準確度不足」	不只報 N-acc, 而是給 同時的 recall + abstention 雙保證 (R1/R2 CI 上界 < 0.3)
統計保證	無任何 calibration / coverage / CI 保證; thr_q 在 val 上經驗選擇	LTT 聯合校準 + Bonferroni 多風險控制, size CI 與 baseline 分離
可靠性視角	追求絕對分數 (F1/gIoU/cIoU 最大化)	追求 可靠性 / 風險可控 (在保證下輸出最小集合)
計算成本	需 GPU 重訓全模型	僅校準階段 (grid search + LTT), base 推論可離線快取
指標	Pr@(F1=1, IoU≥0.5)、N-acc、gIoU/cIoU	同樣用 GREC 指標 Pr@(F1=1, IoU≥0.5)/N-acc/T-acc, 外加 set size、coverage CI

一句話結論: InstanceVG 與 CRS 在同一個 **benchmark (gRefCOCO + GREC metrics)** 競技, 但屬於兩條完全不同的賽道——前者是「訓練式單模型把絕對分數推到最高」, 後者是「凍結式跨 base 組合, 在分布無關保證下輸出符合集合」。兩者不應在絕對分數上正面對撞。

六、論文該怎麼定位 (給 CRS 寫作的具體建議)

6.1 核心定位語：「不比絕對分數，比可靠性」

- 在 related work / SOTA 對照表中，明確把 InstanceVG 標為「**method-layer ceiling** (方法層天花板)」，並用一句話框定：CRS 是 **reliability/calibration study on frozen bases**，與 InstanceVG 的 trained instance-aware end-to-end model 是 orthogonal (正交) 的兩條 track。
- CRS 的賣點不是「F1 比 73.5 高」，而是「在 **distribution-free** 保證下輸出一個可信賴的指涉集合」——這正好補上 InstanceVG 自承的限制 (「target existence determination 不足、無保證」)。

6.2 SOTA 對照表怎麼擺

建議用 **雙欄/雙區塊** 呈現，避免誤導性的同欄直接比分數：1. 「**Trained / method-layer**」區塊：列 InstanceVG (73.5/72.8)、PropVG、SimVG、DeRIS——標註 *requires full retraining, no guarantees*。2. 「**Frozen post-hoc / reliability**」區塊：列 CRS (含 OWL-only、GD-only baseline 與 COMPOSE)——標註 *zero retraining, LTT recall+abstention guarantee, set output*。3. 額外加一欄「**Guarantee?**」：InstanceVG = 無、CRS = 有 (recall + abstention, distribution-free)。這一欄是 CRS 最強的差異化。- 誠實揭露：CRS 全量 val/testA/testB 在 $\alpha=\beta=0.3$ 下輸出 3.21/2.02/3.48 框，Pr@F1=1 約 0.26–0.61 (記憶中 M4 數字)，會明顯低於 InstanceVG 的 73.5。要在表格 caption 與正文把這點講清楚是「保證 vs 點估計」的本質取捨，不是 CRS 弱。

6.3 要不要把 InstanceVG 當成 CRS 的 box base 之一 ? (可行性評估)

短期：不建議納入主結果；長期：可作為 **future work / robustness** 附錄。- 可行性正面：InstanceVG 會開源 code + model (GitHub Dmmm1997/InstanceVG)；它本身就輸出多框 (GREC)，且其 query score 可當作 CRS 校準所需的 nonconformity 分數來源——架構上可插入 CRS 的 box-base 槽。- 可行性風險與成本：1. 凍結純度爭議：CRS 的賣點是「frozen base + 不重訓」。InstanceVG 已在 gRefCOCO 上 end-to-end 訓練過，把它當 base 會讓「凍結 + 跨 base transfer」的故事變模糊 (它不是 RefCOCO 泛用 grounding base，而是 in-domain trained model)——這會稀釋 C4 (cross-base transfer) 的論述。2. 依賴未發布權重：截稿前模型是否真的開源、推論環境 (雙 4090 / GB10 相容性) 都是風險，呼應記憶中 BTS 在 GB10 上遇過的 detector 數值問題。3. 邊際效益：CRS 已用 OWL-ViT + GroundingDINO 證成 factorization (OWL gate + GD box)，再加一個 trained SOTA base 主要是「展示框架可吃更強 base」，屬 nice-to-have 而非核心。- 建議做法：把 InstanceVG 當成 **(a) SOTA 對照表的方法層天花板** (必做)、**(b) 一個 future-work 的「更強 box base 候選」** (提一句即可)。若時間允許，可做一個小型 robustness 附錄：「若以 InstanceVG 的輸出框替換 GD box base，CRS 的保證是否仍成立 / set size 是否縮小」——這能直接展示「CRS 是 base-agnostic 的可靠性外殼」，把 SOTA 方法反過來「包」進 CRS，論述上非常漂亮 (CRS 不與 SOTA 競爭，而是讓任何 SOTA 都能戴上保證)。

七、個人評價

優點

- **工程整合度高**：第一個把 GREC + GRES 在單一 query-based 架構聯合訓練、且引入 instance-aware 的框架；APD (點先驗) + PIPH (點-框-遮罩一致性) 設計巧妙，僅 +3M 參數換來跨 4 任務 10 資料集的全面 SOTA。
- **point-prior 取代 dense grid query** 是務實洞見 (指涉目標 ≤ 10)，同時降算力又給強位置先驗。
- backbone-agnostic 的 ablation (Table XVII) 做得紮實，可信度高。
- 數據覆蓋全面、消融細緻 (光後處理就拆了 thr_q、mask merge、NT score、NMS 四張表)。

缺點 / 它沒做的

1. 完全沒有 **calibration / abstention guarantee**：N-acc 與 existence 判別純靠一個 BCE 分支的點估計 + val 上手動掃的 thr_q。論文自己在 Conclusion 第一條就承認「target existence determination 準確度不足」——這正是 CRS 的整個切入點。
2. thr_q 在 val 集上選：0.7→0.9 把 F1 從 71.43 推到 74.38，有 val-set overfitting 的味道，且沒有任何在 test 上的覆蓋率保證或信賴區間。
3. 「**all metrics SOTA**」略誇：GRES 的 N-acc (72.84) 實際輸給 DeRIS (77.03)，論文行文未充分強調這點。

4. 小物件 / 細粒度分割受限 (自承) , 且 GREC 用固定 threshold=0.7 比較 , 未探討不同 operating point 下的 precision-recall / cost trade-off——而這恰好是 CRS 用 Pareto 與 LTT 風險曲線能補的。
5. **可靠性盲區** : 它給「一個答案」, 但不告訴你「這個答案多可信、何時該棄答」。在 embodied AI / 自駕 (它自己舉的應用) 這種 safety-critical 場景 , 沒有棄答保證是真實短板——CRS 的 distribution-free recall+abstention 雙保證正是針對這個缺口。

對 CRS 的最終 take-away

InstanceVG 是 CRS 必須「站在其下方並標清楚賽道」的方法層天花板 , 但它的存在**強化而非威脅** CRS 的故事 : 一個訓練到極致、且作者自承「存在性判別不足、無保證」的 SOTA , 正好證明「絕對分數的競賽已接近飽和 , 真正缺的是可靠性層」。CRS 應把自己定位成「任何 **grounding base** (含 InstanceVG 這種 SOTA) 都能戴上的 **distribution-free** 保證外殼」, 而非又一個刷分方法。