

LazyMCoT 深讀筆記與 CRS 切割分析

深讀對象：與本論文 (CRS) 最接近的兩篇 2026 競品之一。逐項比對其 conformal 用途，並給出審稿防禦切割文字。

一、書目

- 標題 (已自原始頁面核對) : *Focus When Necessary: Adaptive Routing and Collaborative Grounding for Training-Free Visual Grounding*
 - 註：任務指派的「LazyMCoT」是論文內部的方法代號，正式論文標題並不含 **LazyMCoT** 字樣；arXiv 標題就是 "Focus When Necessary..."。引用時方法名用 LazyMCoT，論文題名用全名。
- arXiv : 2606.16158v1 [cs.CV] · 2026-06-15
- 作者群 : Yifan Wang, Peiming Li, Shiyu Li, Zhiyuan Hu, Xiaochen Yang, Wenming Yang, Yang Tang, Zheng Wei (標註 Tencent BAC ; 通訊作者 Wenming Yang / Yang Tang / Zheng Wei · Zheng Wei 為 Project Lead)
- 程式碼 : <https://github.com/TencentBAC/LazyMCoT>
- 骨幹 VLM : Qwen2.5-VL-7B-Instruct、Qwen3-VL-8B-Instruct、InternVL3-8B-Instruct (全程 frozen · greedy decoding)
- 視覺專家 : SAM3 ("Sam 3: segment anything with concepts" , 2025)

二、問題定義與動機

任務設定

這是高解析度影像的「**training-free 視覺定位 / 細粒度感知**」問題，而且答題格式是多選題 (**multiple-choice**)，最終以 multiple-choice accuracy 衡量。不是 box-level 的 referring expression comprehension，而是「VLM 看高解析度圖回答選擇題，需要時做局部放大/裁切來看清小目標」。

核心痛點 (論文的切入觀察)

現有 training-free 視覺定位方法 (ZoomEye、DyFo、HiDe、DeepScan、ViCrop 等) 對所有樣本一視同仁地施加重度視覺操作 (image scaling + localized cropping)，這帶來兩個問題：

- 計算冗餘：作者在 V*、HR-Bench 4K/8K、TreeBench 統一基準上量測，發現 **平均 67.17% 的樣本** 光靠原始 VLM 一次 forward 就能答對 (Fig.2)，對這些樣本做重度 grounding 純粹浪費算力。
- 準確率反傷：對簡單樣本強制做局部裁切，會截斷必要的全域上下文並引入無關背景噪聲，把本來會答對的題目帶歪 (Fig.3)。在「推理重」的任務上尤其明顯——盲目 grounding 反而拉低整體準確率 (TreeBench 上 HiDe 把 Qwen3-VL-8B 從 43.0% 拖到 41.7% 就是實例)。

核心假設

base VLM 的初始預測不確定性，是「該不該再花力氣做視覺探索」的強指標。因此應該選擇性地施加 grounding，而非一律施加。這個「selective / 按難度分配 grounding 努力」的母題，與本論文 (CRS) 的 selective grounding 母題在精神上同源——這是要特別警覺的相似面。

三、方法詳解

LazyMCoT = **Adaptive Routing** (自適應路由) + **Collaborative Grounding** (協同定位) 兩個模組。流程：圖 I + 多選題 Q → 單 token forward 拿到「直接答案 + 首 token 統計量」→ Router 判斷 → 簡單題直接回答；難題才進 Collaborative Grounding 產生 Localized Panel Display (LPD) → 用 LPD 重新 query VLM 得最終答案。

3.1 First-token uncertainty 是什麼

關鍵設計：用單次 **forward pass**、**max_new_tokens=1** 取第一個答案 token 的 logits $\mathbf{z} \in \mathbb{R}^V$ ，從中抽兩個**零成本**統計量 ($\mathcal{O}$ 為候選選項字母的 token index 集合，靠 regex 從題目解析)：

- **option top probability** : $\text{topp} = \max_{i \in \mathcal{O}} \tilde{p}_i$ (在「只保留選項」重新歸一化分布 $\tilde{p}$ 上的最高選項機率) —— 衡量機率集中度。
- **option-versus-non-option logit gap** : $\Delta_{\text{logit}} = \max_{i \in \mathcal{O}} z_i - \max_{j \notin \mathcal{O}} z_j$ —— 衡量「選一個合法選項 vs 任何非選項 token」的信心。

作者用 1,000 個樣本驗證：這兩個量與 base VLM 的 predictive entropy (option entropy $H(\tilde{p})$) 呈**單調相關**，而且能乾淨地把「原始就答對 (ori-correct)」與「原始答錯 (ori-wrong)」兩類分開 (Fig.4)。這就是「first-token uncertainty」——本質是**單一純量化的**、**一次前傳即得的信心分數**，用來代理樣本難度。

3.2 Adaptive Routing : conformal 在這裡到底保證什麼

把上述 ($\text{topp}, \Delta_{\text{logit}}$) 餵進一棵 **GBDT** (Gradient Boosting Decision Tree · 300 estimators / max depth 3 / lr 0.05 / 5-fold CV) g_θ ，預測「ori-wrong 機率」 $\hat{p}(\mathbf{x})$ ，再取 logit 得 routing score：

$$s(x) = \log \frac{\hat{p}(\mathbf{x})}{1 - \hat{p}(\mathbf{x})}.$$

GBDT 只在 held-out routing 集 $\mathcal{D}_{\text{cal}}$ 上訓練一次，部署時固定、不更新 base VLM、不引入額外可學參數。

Conformal threshold calibration (這是與 **CRS** 最危險的交集點)：- 在 $\mathcal{D}_{\text{cal}}$ 內取一個 **must-recall** 子集 $\mathcal{D}_{\text{mr}}$ (= 所有「ori-wrong 且能從 grounding 受益」的樣本)。- 取這些樣本的 out-of-fold routing score $\{s_i\}$ ，對目標 miscoverage rate α 設門檻為經驗 α 分位數：

$$s_{\text{floor}} = Q_\alpha(\{s_i\}_{i \in \mathcal{D}_{\text{mr}}}).$$

- **保證**：依建構，最多 α 比例的 must-recall 樣本會落在 s_{floor} 之下——即對「困難樣本」提供一個**可控的 recall 下界**。

Routing rule：

$$\hat{y} = \begin{cases} \text{Direct}(I, Q), & s(x) < s_{\text{floor}} \text{ (信心足, 直接回答、零額外成本)} \\ \text{CG}(I, Q), & s(x) \geq s_{\text{floor}} \text{ (不確定, 進協同定位)} \end{cases}$$

α 小 $\rightarrow$ 門檻低 $\rightarrow$ router 保守 $\rightarrow$ 多數樣本都被送去 grounding (recall 困難樣本更穩); α 大 $\rightarrow$ 積極跳過 $\rightarrow$ 多 fallback 到 base VLM。論文預設 $\alpha = 0$ (最嚴 must-recall 保證)。

關鍵閱讀：LazyMCoT 的 conformal 保證的是「**router 把困難樣本送去 grounding 的 recall 下界**」，也就是一個**內部排程/觸發決策的覆蓋率**。它不對最終輸出 (答案集合) 做任何**覆蓋率或正確率保證**——最終答案仍是 VLM 重 query 後吐的單一選項，沒有集合、沒有 size 保證、沒有 abstention。換言之，它的 conformal 是「**效率/觸發層**」的工具，目的是在保住難題 recall 的前提下盡量跳過簡單題以省延遲。

3.3 Collaborative Grounding : 協同定位流程 (只對被路由的難題執行)

1. **Entity decomposition** : 用 rule-based template (沿用 HiDe 的做法) 讓 VLM 把問題 Q 拆成 canonical entity list $\mathcal{E} = \{e_1, \dots, e_M\}$ 。
2. **兩路平行偵測**：
 - *Visual expert branch* : 把每個 entity 當獨立 text prompt 餵 SAM3，得 $\mathcal{B}_{\text{exp}}$ (每 entity 留 k=10 框，cross-entity NMS IoU=0.7 去重)。傾向 recall 最顯著的實例，但會漏小/被遮擋目標。
 - *Attention branch* : 在 VLM 輸入後接 "Search the following entities..." prompt，記錄 cross-modal attention $A \in \mathbb{R}^{T \times N}$ (T=entity token 數，N=visual token 數)，逐 token reshape 到空間網絡、Gaussian blur (=3)、歸一化、跨 token 平均成 saliency map $\mathcal{A}(I)$ ；相對門檻 =0.5 取 connected components 得 $\mathcal{B}_{\text{att}}$ 。覆蓋題目相關區域但較噪。
 - *Per-VLM attention 層選擇*：Qwen2.5-VL-7B / InternVL3-8B (28 層) 取第 15 層；Qwen3-VL-8B (36 層) 因 DeepStack 多層注入，改聚合全部層。
3. **Two-stage refinement**：

- Stage 1：取聯集 $\mathcal{B}^{(1)} = \mathcal{B}_{\text{att}} \cup \mathcal{B}_{\text{exp}}$ 當粗證據池。
 - Stage 2：對每個「未被 $\mathcal{B}_{\text{exp}}$ 覆蓋的 attention 框 b 」，裁切放大區域後重新 query SAM3，新發現的框 $\Delta\mathcal{B}$ 映回原圖座標併入，得 $\mathcal{B}^{(2)} = \mathcal{B}^{(1)} \cup \Delta\mathcal{B}$ 。
4. **Render LPD**：把 $\mathcal{B}^{(2)}$ 用彩色框 + 文字 legend 畫成一張 **Localized Panel Display $\hat{I}$** ，讓 VLM 在一次 forward 內對多個證據 patch 一起推理，輸出最終選項。

四、實驗

資料集與指標

- **V* Bench**：191 張、平均 2246×1582，分 Direct Attribute (Att.) / Spatial Relationship (Spa.)。
- **HR-Bench-4K / 8K**：4K、8K 高解析；各分 Single-Instance (Sin.) / Cross-Instance (Cro.)。人類準確率約 87%。
- **TreeBench**：405 題、平均 2152×1615，10 子類分 Perception (Attributes / Material / Phy. State / Obj. Retr. / OCR) 與 Reasoning (Per. Trans. / Ordering / Con.&Oc. / Spa. Cont. / Comparison)。
- 指標：一律 **multiple-choice accuracy**。完全沒有 **box-level IoU**、沒有 **GREC** 指標、沒有任何 **referring-set** / 集合大小指標。

主結果 (Table 1, HR-Bench + V*)

- LazyMCoT 對三個骨幹相對 base 的平均提升：InternVL3-8B +**3.3**、Qwen3-VL-8B +**7.9**、Qwen2.5-VL-7B +**8.4** 點。
- Training-free 法中每個 **aggregate 欄都排第一**，平均超過 HiDe。
- 在 Qwen2.5-VL-7B 上 V* 平均達 **90.6%**，匹配甚至超過 training-based 法 (DeepEyes / Thyme-VL / TreeVGR)。
- 最大增益在 V*-Spatial (Qwen2.5-VL-7B +**17.1** 點)。

TreeBench (Table 2，反傷驗證)

- Qwen3-VL-8B：HiDe 把 base 從 43.0% 拉低到 **41.7%** (盲目 grounding 傷推理題)，LazyMCoT 拉回 **43.5%**。
- Qwen2.5-VL-7B：LazyMCoT 41.7%，Perception +3.4 點，勝所有 training-free 競品。

Latency (Fig.6)

- 單 H20、batch=1。只開 Collaborative Grounding 比 HiDe 稍慢 (多了 SAM3 驗證)，但開 **router** 後可短路簡單題，平均延遲下降。

消融

- **AR + CG (Table 3)**：CG 全開把 V* 79.1%→90.0%、HR-4K 71.8%→77.4%，但 TreeBench 增益受限；再加 AR 把 V* 推到 90.6%、TreeBench 到 41.7%——兩者互補 (CG 給難題精度，AR 擋簡單題被傷)。
- **兩階段 CG (Table 4)**： $\mathcal{B}_{\text{att}}$ 單獨 80.3%、 $\mathcal{B}_{\text{exp}}$ 單獨 85.9%；Stage 1 聯集 88.4%；加 Stage 2 達 90.6%。
- **conformal α 掃描 (Table 5, Qwen2.5-VL-7B / V*)**： $\alpha = 0 \rightarrow s_{\text{floor}} = -0.25$ 、skip rate 24.7%、V* 90.6% (最佳甜蜜點，省掉約四分之一樣本的 grounding)。 α 越大 skip rate 越高 (最高 94.2%) 但準確率掉到 79.25%。這張表正是「conformal 控的是 routing 觸發率 / 跳過率與準確率之 trade-off」的直接證據。

與 CRS 錨點的對照 (重要)

- 完全沒碰 gRefCOCO、RefCOCO、RefCOCOG。三個 benchmark 全是高解析多選題基準。
- 完全沒有 **no-target / multi-target / abstention (棄答)** 概念。任務裡每題都有唯一正解選項，不存在「圖中無此目標」或「多個目標」的判定，也不會輸出「拒答」。
- 完全沒有 **cross-base 異質組合校準**：它是「單一 frozen VLM + 一個 SAM3 expert」的 pipeline；conformal 校準的是 router 一個純量門檻，不是兩個異質 base 的聯合風險。

五、與 CRS 的逐項 diff 表

維度	LazyMCoT (2606.16158)	CRS (本論文)
任務 / 輸出	高解析多選題 VQA · 輸出單一選項字母	gRefCOCO/RefCOCO 指涉定位 · 輸出 conformal referring SET (一組框)
指標	multiple-choice accuracy	GREC 指標 (Pr@(F1=1) · N-acc · T-acc) · 集合大小 · recall/risk CI
conformal 用在哪一層	效率/觸發層: 校準 router 門檻 s_{floor}	輸出層: 校準輸出框集合本身
conformal 保證什麼	「困難樣本被送去 grounding」的 recall 下界 (routing recall) · $\leq \alpha$ must-recall 樣本被誤跳	輸出集合的 recall (覆蓋) 下界 + abstention/棄答風險上界 · 同時保證 (LTT 聯合控制 R1/R2/R3)
保證對象	內部決策 (要不要進 grounding)	終端使用者看到的輸出集合性質
校準的統計工具	經驗 - 分位數門檻 (single-threshold conformal)	LTT (Learn-then-Test) + Bonferroni 多風險 · calib-only grid 防 leakage
base 結構	單一 frozen VLM (Qwen2.5/3-VL · InternVL3) + 1 個 SAM3 expert	cross-base 異質組合 : OWL-ViT gate + GroundingDINO box · 聯合校準
是否有棄答 / abstention	無	有 (abstention 是核心保證之一)
gRefCOCO / multi-target / no-target	全無 (每題唯一正解 · 無 no-target)	核心 (gRefCOCO no-target / multi-target 正是主場)
factorization / ablation 論證	AR vs CG 互補 · 兩階段 CG	OWL gate $\times$ GD box 的 2×2 factorization (非 ensemble)
router / 決策有沒有可學參數	GBDT 路由器 (held-out 訓練一次 · 部署固定)	frozen 組合 · LTT 純後處理校準 (無新增可學參數於輸出端)
selective 的對象	selective 要不要花力氣 (算力/延遲)	selective 要不要輸出 / 輸出多大集合 (可靠性/棄答)

一句話總結差異: LazyMCoT 把 conformal 當「省算力的開關閘門」(保證難題不被漏送進 grounding 管線); CRS 把 conformal 當「輸出可靠性的合約」(保證使用者看到的框集合同時滿足召回與棄答風險)。兩者都叫 “conformal + selective grounding + frozen backbone + training-free”，但作用平面正交：一個在效率層、一個在輸出層。

六、論文該怎麼引用 / 切割 (審稿防禦)

這幾乎一定是審稿人會丟出「你被搶先了」的那篇——因為標籤高度重合: training-free、frozen backbone、conformal calibration、selective/按難度 grounding、甚至連 α miscoverage、recall lower bound 這些字眼都出現。必須在 Related Work 與 contribution 兩處主動切割，先發制人。可直接取用以下中 / 英兩版段落。

中文切割段 (放 Related Work / 差異討論)

與本工作最接近的並行研究是 LazyMCoT (Wang et al., 2026, *Focus When Necessary*)。兩者皆在 frozen backbone 上採 training-free 的 selective grounding，並借用 conformal 校準提供 recall 下界，表面高度相似。但兩者的 **conformal 作用平面正交**。LazyMCoT 的 conformal 校準的是「自適應路由器」的觸發門檻 s_{floor} ，其保證對象是內部排程決策的 **recall**——即「困難樣本被送入 grounding 管線的比例下界」，目的是在不漏送難題的前提下短路簡單題以節省推理延遲；它的最終輸出仍是單一多選答案，**不對輸出本身提供任何覆蓋率、集合大小或棄答保證**，且實驗僅在高解析多選 VQA (V*、HR-Bench、TreeBench) 上，不涉及 gRefCOCO 的 no-target/multi-target 與棄答情境。相對地，CRS 的 conformal (透過 LTT 多風險聯合控制) 直接校準終端輸出的 **referring set**，同時保證召回下界與棄答風險上界，並建立於 OWL-ViT 與 GroundingDINO 兩個異質 base 的 **cross-base 組合** 之上。因此，LazyMCoT 解決的是「何時值得花力氣」(效率)，CRS 解決的是「輸出能不能被信任、何時該棄答」(可靠性合約)；前者的 conformal 是效率閘門，後者的 conformal 是輸出層覆蓋保證。

英文切割段 (可直接放 paper)

The closest concurrent work is LazyMCoT (Wang et al., 2026), which, like ours, performs training-free selective grounding on a frozen backbone and uses conformal calibration to obtain a recall lower bound. The two methods are nonetheless **orthogonal in what the conformal guarantee controls**. LazyMCoT calibrates the *triggering threshold* of an adaptive router: its guarantee bounds the recall of *hard samples routed into the grounding pipeline*, so as to short-circuit easy cases and reduce inference latency. Its final prediction remains a single multiple-choice answer, and it provides **no coverage, set-size, or abstention guarantee on the output itself**; its evaluation is confined to high-resolution multiple-choice VQA (V*, HR-Bench, TreeBench), with no no-target/multi-target referring or abstention. In contrast, CRS calibrates the **terminal output set** (a conformal referring set) via Learn-then-Test multi-risk control, *simultaneously* guaranteeing a recall lower bound and an abstention-risk upper bound, on a **cross-base composition of two heterogeneous detectors** (OWL-ViT gate + GroundingDINO box). Hence LazyMCoT answers “*when is grounding worth the compute*” (an efficiency valve), whereas CRS answers “*can the output be trusted and when to abstain*” (an output-level reliability contract).

切割要強調的三個硬差 (審稿人一看就懂)

1. 保證的平面不同：routing-recall (內部觸發) vs output-set coverage + abstention (終端輸出)。這是最強、最不可辯駁的差異。
2. 任務與評測不同：多選 accuracy vs GREC (含 no-target/multi-target/棄答)。LazyMCoT 連 referring set 的概念都沒有。
3. base 結構不同：單模型 vs cross-base 異質組合 + 聯合風險 (LTT/Bonferroni)。

七、個人評價

對 CRS 新穎性的威脅判定：低至中、不致命，但「必須引用且必須主動切割」。

- 為何不致命：LazyMCoT 的 conformal 與 CRS 的 conformal 雖共用詞彙 (recall lower bound、miscoverage)，但作用對象完全不同。LazyMCoT 校準一個純量路由門檻、保證「難題進管線」的觸發 recall，目標是省延遲；它的輸出沒有任何集合層的覆蓋或棄答保證。CRS 的招牌——對輸出 **referring set** 同時保證召回下界與棄答上界、且建立在兩個異質 base 的 **cross-base** 聯合校準上——LazyMCoT 一項都沒做。任務 (多選 VQA vs gRefCOCO 指涉集合)、指標 (accuracy vs GREC)、有無棄答、有無 no-target/multi-target，全是乾淨的非交集。因此「被搶先」的指控在技術上站不住腳。
- 為何仍需嚴肅對待：它是同月 (2026-06)、同標籤 (training-free + frozen + conformal + selective grounding)、且來自 Tencent 的高曝光工作。審稿人很可能只看摘要關鍵字就斷定重複。**風險不在技術，而在表面相似的 framing**。防禦方式就是上面那段「conformal 作用平面正交」——把「routing recall (效率閘門) vs output-set coverage+abstention (可靠性合約)」這組對比寫死在 Related Work 顯眼處，並在 contribution 列點中明確聲明 CRS 是「輸出層、跨異質 base、含棄答」的保證。
- 可順手吸收的養分：
 1. LazyMCoT 的 first-token uncertainty (topp / Δ logit / option entropy 單調相關) 是個漂亮、零成本的 reliability 信號。CRS 若日後要做「何時棄答 / 何時觸發第二 base」的成本-Pareto 分析，這套首 token 統計量可當一個便宜的 routing prior 來做 cost-aware 版本 (且可在 Related Work 借它佐證「first-token 統計可作可靠性指標」這個 claim 在文獻中已有支撐)。
 2. 它的 Fig.2/Fig.3「盲目 grounding 反傷簡單樣本」與 TreeBench 反傷數據，是 CRS「selective grounding 有必要」這個母題的現成外部佐證，可引用來強化動機。
 3. 它的 ablation Table 5 (-skip rate-accuracy) 是很好的「conformal 的用途是效率 trade-off」對照組——CRS 可在差異討論直接指這張表，說「對方的 控的是 skip rate，我方的 / 控的是 output recall/abstention risk」，差異一目了然。
- 小瑕疵備忘 (若要在 review 反擊其侷限)：(a) 它的“conformal”其實只是經驗分位數單門檻，沒有 LTT/多風險的嚴謹性，也未討論 exchangeability 假設在 must-recall 子集上的成立性；(b) recall 下界只在 calibration 分布上成立，

未做 cross-split / image-disjoint robustness (CRS 有做三 split 模式); (c) 完全無棄答能力，遇到 no-target 會強制亂答——這正是 CRS 的賣點落差。

結論：引用它、在 Related Work 用「正交保證平面」一段切乾淨即可，不需要改 CRS 主結構。它非但不削弱 CRS，反而可被當作「selective grounding 動機」與「first-token reliability signal」的外部支撐。