

RCPS: Distribution-Free, Risk-Controlling Prediction Sets 詳細導讀

整理：kuo

2026-06-19

RCPS —Distribution-Free, Risk-Controlling Prediction Sets (詳細導讀)

0. 論文基本資訊

- 論文標題：Distribution-Free, Risk-Controlling Prediction Sets
- 作者：Stephen Bates, Anastasios Angelopoulos, Lihua Lei, Jitendra Malik, Michael I. Jordan (前三位 equal contribution)
- 單位：UC Berkeley (Stanford/Berkeley 統計 +EECS 圈)
- arXiv：2101.02703v3 (v3 提交於 2021-08-04；發表為 JACM 2021)
- 專案頁：angelopoulos.ai/blog/posts/rcps/
- 任務範疇：分布無關、有限樣本的風險控制集合預測 (distribution-free risk control)

註：本文是 CRS 主線所用 **LTT (Learn then Test)** 的理論前身。同一作者群 (Bates/Angelopoulos) 隔年提出 LTT (2110.01052) 把 RCPS 的「單調風險 + 單參數 UCB」推廣到「多參數 + 非單調 + 多風險」的 multiple-testing 框架。讀懂 RCPS = 讀懂 CRS 風險控制機制的根。與本目錄 read-crc-nonmonotonic-summary.md (把 LTT 定位成非單調 baseline)、read-conformal-iseg-summary.md (同型 $\text{set} \geq 1$ 保證) 互為一組。

1. 問題與動機

1.1 核心問題

黑箱預測模型部署到高風險場景 (醫療、自駕) 時，很少附帶可靠的不確定性量化，預測失敗往往是「沉默的失敗」。標準 train/val/test 只給平均準確率，不告訴你「這一筆該不該信」。

1.2 本文主張：把任意黑箱改造成「風險受控的集合預測器」

不重訓模型，而是用一個 holdout calibration set，把任意 black-box predictor f 改造成輸出集合 $T(X)$ Y 的預測器，使其在未來測試點上的期望損失 (risk) 以高機率不超過使用者

指定水準。

MRI 範例：每張影像分到診斷類別，誤判 stroke 損失 =100、誤判 normal=0.1。RCPS 輸出一個「合理診斷集合」，保證未來資料上的平均損失低於門檻——醫生可安全排除集合外的診斷。

2. 核心定義與方法

2.1 (α, δ) -RCPS 定義 (Definition 1)

集合預測器 $T : X \rightarrow 2^Y$ (隨機函數，依賴訓練資料) 稱為 (α, δ) -risk-controlling prediction set，若

以至少 $1-\delta$ 的機率 (over calibration data) $R(T) = E[L(Y, T(X))]$ 。

其中 α (風險水準，代表值 10%) 與 δ (失敗機率) 由使用者預先選定。

關鍵：這是 **PAC-style** 高機率保證 ($P(\text{risk} > \alpha) \leq \delta$)，不同於 vanilla conformal 的 marginal 期望保證。CRS 的 LTT 正是繼承這個 PAC 型態。

2.2 兩個結構假設

1. **Nesting (嵌套)**: 集合預測器由單一參數 $\lambda \in \Lambda \subseteq \mathbb{R} \cup \{\pm\infty\}$ 索引， λ 越大集合越大： $\lambda_1 < \lambda_2 \implies T_{\lambda_1}(x) \subseteq T_{\lambda_2}(x)$ 。
2. **Loss monotonicity (損失單調)**: 集合越大損失越小： $S \subseteq S' \implies L(y, S) \geq L(y, S')$ 。經典 tolerance region 損失 $L(y, S) = 1 - \mathbb{1}\{y \in S\}$ 滿足。並假設存在 $\lambda_{\max}$ 使 $R(\lambda_{\max}) = 0$ 。

□ 這正是 **CRS** 不能用 **vanilla RCPS/CRC** 的原因：CRS 的漏框 recall 損失是多維 + 非單調 (見 read-crc-nonmonotonic-summary.md)，不滿足這裡的單調假設 $\rightarrow$ 必須升級到 LTT。

2.3 UCB Calibration 程序 (§2.2)

核心招式：對每個 λ 取 risk 的 **pointwise upper confidence bound** $R(\lambda)$ ，滿足 $P(R(\lambda) \geq L(Y, T_\lambda(X))) \leq 1-\alpha$ 。然後選

$$\hat{\lambda} = \inf\{\lambda : R(\lambda) \leq \alpha\}$$

即「整個右側信賴帶都壓在 α 以下」的最小 λ 。

Theorem 1 (UCB calibration 有效性): 損失單調 + 集合嵌套 + pointwise UCB 成立 + $R(\lambda)$ 連續 $\implies \hat{\lambda}$ 給出 (α, δ) -RCPS。- 精髓：靠 risk function 的單調性，把「逐點收斂」升級成「資料驅動選 λ 仍有效」——不需要 **uniform convergence**。若沒有單調性就得 uniform 收斂 (這也是 LTT 用 multiple testing 處理非單調的動機)。- **Remark 2 (重要)**: 即使初始模型 f 訓練資料來自不同分布，RCPS 仍成立——只要 **calibration data** 與 **test data** 同分布 (exchangeable)。這對 CRS 「frozen base 在 RefCOCO 預訓，calibration 在目標 split」的設定是直接背書。

2.4 具體 Concentration Bounds (§3)

把 pointwise UCB 用各種集中不等式實作：

- **Hoeffding** (簡版 · §3.1.1) : $R = R + \sqrt{(\log(1/\delta))/2n}$ · 僅供說明。
- **Hoeffding–Bentkus** (HB · §3.1.2) : 反轉 tail probability · 二元損失近乎最緊 (Bentkus 不等式讓 Binomial 成最差情形)。
- **Waudby-Smith–Ramdas** (WSR · §3.1.3) : 基於 martingale/online inference 的 hedged capital CI · 自適應變異數 · 非二元有界損失下最優。本文總建議：二元損失用 **exact binomial** · 其他有界損失用 **WSR**。
- **Unbounded losses** (§3.2) : 無界損失需額外正則條件 (Pinelis–Utev · 限制 coefficient of variation) 才有非平凡 UCB。

3. 實驗 (§5)

五大規模任務範框架普適性：1. 不同誤分類代價的分類；2. multi-label 分類；3. 階層式標籤分類；4. 影像分割 (預測含目標物件的像素集合)；5. 蛋白質結構預測。另討論 ranking / metric learning / distributionally robust learning 的延伸。

影像分割那組與 CRS 最相關：把「set of pixels containing object」當 set prediction · 控 false-negative 型損失——與 read-conformal-iseg-summary.md 同脈絡。

4. 對使用者主線 (CRS) 的對位與借鏡

CRS 主線見 `[[crs-pivot-conformal-referring-set]]` / `[[crs-redteam-p0-fixes]]` / `[[crs-litreview-15papers]]`；索引 `reading-log.md`。

1. 理論祖先 · 必引於方法章：CRS 的 LTT 風險控制直接繼承 RCPS 的 (α, δ) -PAC 型態與「holdout calibration 改造黑箱」哲學。方法章談「為何能在 frozen base 上給有限樣本保證」時，RCPS 是源頭引用 (Bates et al. 2021)。
2. 正當化「不重訓 base」：Remark 2 明說「初始模型可來自不同分布，只要 `calib/test` 同分布」——這是 CRS frozen-base 設計的理論護身符，可直接寫進 `method justification`。
3. 反襯「為何要 LTT 而非 RCPS」：RCPS 的兩個假設 (單參數嵌套 + 損失單調) **CRS 都不滿足** (跨兩 base 兩參數、recall 損失非單調)。論文可寫：「RCPS/vanilla CRC 要求單調且單參數；CRS 的 cross-base 雙參數 + 非單調 recall 損失超出其適用範圍，故採 LTT (multiple testing over grid)」——把 RCPS 當「不夠用的起點」引用，與 CRC-Non-Monotonic 的論證合流。
4. **Bound 選擇的工程參考**：CRS 若損失二元 (漏框/不漏框) 用 **exact binomial** · 若是連續型 IoU/recall 用 **WSR**——本文已給出明確選擇準則，可省去重新比較。
5. 與 **conformal** 的關係界定：RCPS 自陳「靈感來自 conformal 的 nested set 詮釋、算法類似 split conformal，但追求 tolerance region 的高機率保證、用完全不同的證明 (concentration 而非 exchangeability rank)」——這段是 CRS 在 background 區分「conformal coverage vs risk control PAC」的好範本 (呼應 read-vlm-calibration-summary.md 的 ECE vs conformal 區分)。

引用優先級：高（方法章理論源頭，必引）。

5. 一句話總結

RCPS 是 2021 年把「分布無關有限樣本風險控制」從 **conformal coverage** 推廣到任意單調損失集合預測的奠基作：用 holdout calibration + UCB（選整段右側信賴帶都壓在 α 下的最小 λ ）把任意黑箱改造成 (α, δ) -PAC 風險受控的集合預測器。它要求單參數嵌套 + 損失單調——而 CRS 的跨 base 雙參數、非單調 recall 損失正好突破這兩個假設，因此 CRS 必須升級到其後繼 LTT；RCPS 是 CRS 風險控制的理論祖先與「不夠用的起點」雙重引用對象。

6. 參考連結

- arXiv : <https://arxiv.org/abs/2101.02703>
- 專案頁/blog : <https://angelopoulos.ai/blog/posts/rcps/>
- 後繼 LTT : Angelopoulos et al., *Learn then Test: Calibrating Predictive Algorithms to Achieve Risk Control* (arXiv 2110.01052)