

論文精讀：Conformal Object Detection by Sequential Risk Control (SeqCRC)

本文是針對 SeqCRC 的深讀筆記，重點放在「方法如何運作」與「它與本論文主線 CRS (Cross-Base Conformal Composition) 的逐項差異」。SeqCRC 是 CRS 在結構上最近的鄰居（同樣是 conformal OD、同樣是兩個參數依序校準），審稿人極可能拿它來質疑 CRS 的新穎性，因此本筆記特別強化「如何切割、如何引用」這一段。

1. 書目

欄位	內容
標題	Conformal Object Detection by Sequential Risk Control
作者	Léo Andéol、Luca Mossina、Adrien Mazoyer、Sébastien Gerchinovitz
單位	Univ Toulouse (Institut de Mathématiques de Toulouse)、SNCF、IRT Saint Exupéry、DEEL / ANITI
形式	期刊投稿稿 (footnote 註明 “submitted to the IEEE for possible publication”) · v2
年份	2025
arXiv	2505.24038 (v2)
程式碼	https://github.com/leoandeol/cods (COD Toolkit · PyTorch · CPU/GPU)

這是一個明確走「安全關鍵工業認證」路線的團隊（鐵路號誌、跑道偵測、航太 DEEL/IRT Saint Exupéry 背景），其前作鏈是 SAFECOMP 2022 [de Grancey et al.]、COPA 2023 鐵路號誌、AI & Ethics 2024，本文是這條線的「集大成統一框架」。

2. 問題定義與動機

2.1 動機

物件偵測 (OD) 已被工業採用，但要部署到 **安全關鍵系統**（自駕、醫療、航太認證）就需要對預測「給統計保證」。神經網路本身不可靠、OD 模型結構又複雜（一張圖未知數量的物件 × 同時要定位 + 分類），因此作者轉向 **Conformal Prediction (CP)**：post-hoc、分布無關 (distribution-free)、有限樣本有效 (finite-sample valid)、與模型/資料分布無關。

2.2 既有工作的缺口（作者自己定位的 gap）

作者主張：現有 conformal OD 文獻各只處理 **OD pipeline** 的一個子步驟或單一模型家族：- 多數只做 **localization**（給 bounding box 加 margin），如 de Grancey 2022、Andéol 2023/2024、Copula-based [Mukama]。- 兩個例外：Timans et al. (ECCV 2024) 處理 classification 且做 class-conditional 的 localization 修正；Li et al. (PAC multi-object) 針對 Faster R-CNN 建「全包式」集合但綁死特定模型。- 沒有人提出一個 **holistic** 框架：對「幾乎所有 OD 模型家族」都成立、且同時對「預測物件數量 + 定位 + 分類正確率」給統計保證。

2.3 本文要解決的核心技術障礙

OD 的 conformal 化天然需要 **多個依序相依的參數**，但經典 CRC (Conformal Risk Control) 只能處理單一純量參數 λ 。這就是本文的技術靶心。

3. 方法詳解：Sequential Conformal Risk Control (SeqCRC)

3.1 三個參數的語意（這是理解全文的鑰匙）

SeqCRC 對 OD 的後處理拆成「1 + 2」三個純量參數：

1. λ^{cnf} (**confidence** · 信心門檻) — 定義一個門檻 $o(x) \geq 1 - \lambda^{\text{cnf}}$ ，低於門檻的預測框被丟掉。控制「保留多少框」。
2. λ^{loc} (**localization** · 定位 margin) — 對保留下來的每個框，加上 margin (加法式 Eq.12，或乘以框寬高的乘法式 Eq.13) 把框「撐大」，使其能涵蓋 ground-truth。
3. λ^{cls} (**classification** · 分類集合) — 對每個框輸出一個「類別集合」(LAC 門檻式 Eq.15，或 APS 累積機率式 Eq.16)，保證以高機率含真類別。

關鍵相依結構：**loc** 與 **cls** 都依賴 **cnf** 的結果（因為先 threshold 才有框可定位/分類），但 **loc** 與 **cls** 彼此平行獨立。所以是「先 1 (cnf)，後 2 (loc、cls 並行)」的 **sequential** 結構 → 名稱由此而來。

3.2 背景：經典 CRC (單參數)

給校準集 $D_{\text{cal}} = (X_i, Y_i)$ ，預測集 $\Gamma_\lambda(X)$ ，損失 $\ell(Y, \Gamma_\lambda(X))$ (要求對 λ 非遞增、右連續、值域 $[0, B]$ ，且在 $\bar{\lambda} = \max \lambda$ 時損失為 0)。CRC 選：

$$\hat{\lambda} = \inf \{ \lambda : (1/(n+1)) \cdot \sum L_i(\lambda) + B/(n+1) \leq \alpha \}$$

保證 (Theorem 1) : $\alpha - 2B/(n+1) \leq E[L_{\text{test}}(\hat{\lambda})] \leq \alpha$ 。注意這是 **對期望值 (marginal over 校準 + 測試集)** 的保證，不是 per-instance、也不是 PAC 式高機率保證。

3.3 SeqCRC 的核心機制（本文真正的新貢獻）

直接把 CRC 串兩次會出問題：第二步的 $\lambda^{\text{loc}}/\lambda^{\text{cls}}$ 是用「第一步選出的 λ^{cnf} 」算出來的，這個相依性破壞了 exchangeability，使 finite-sample 保證失效。SeqCRC 的解法有兩個技巧：

技巧 A — 一個 **confidence step** 產生「兩個」估計量（不是一個）

$$\lambda^{\text{cnf}}_+ = \inf \{ \lambda : n \cdot \hat{R}_n^{\text{cnf}}(\lambda)/(n+1) + \bar{B}^{\text{cnf}}/(n+1) \leq \alpha^{\text{cnf}} \} \quad (\text{Eq.4, 保守 / 加 } B \text{ 項})$$

$$\lambda^{\text{cnf}}_- = \inf \{ \lambda : n \cdot \hat{R}_n^{\text{cnf}}(\lambda)/(n+1) + 0 \leq \alpha^{\text{cnf}} \} \quad (\text{Eq.5, 樂觀 / 不加 } B \text{ 項})$$

- λ^{cnf}_+ (保守估計量) → 實際用在測試影像做 thresholding。
- λ^{cnf}_- (樂觀估計量) → 只在第二步 Eq.6 內部使用，作為對稱性 (symmetry) 證明的關鍵。這是讓有限樣本保證成立的核心數學手法。

技巧 B — 把第二步「錨」在樂觀估計量 λ^{cnf}_- 上

$$\lambda^{\cdot}_+ = \inf \{ \lambda^{\cdot} : n \cdot \hat{R}_n^{\cdot}(\lambda^{\text{cnf}}_-, \lambda^{\cdot})/(n+1) + B^{\cdot}/(n+1) \leq \alpha^{\cdot} \}, \quad \cdot \in \{\text{loc}, \text{cls}\} \quad (\text{Eq.6})$$

技巧 C — 保守化的 **confidence** 風險 $\hat{R}^{\text{cnf}}$ (Eq.3)：第一步的風險不只看 cnf loss，而是取三者最大值 $\hat{R}_n^{\text{cnf}}(\lambda) = \max \{ \hat{R}_n^{\text{cnf}}(\lambda), \hat{R}_n^{\text{loc}}(\lambda, \hat{\lambda}^{\text{loc}}), \hat{R}_n^{\text{cls}}(\lambda, \hat{\lambda}^{\text{cls}}) \}$ 目的是確保第二步 Eq.6 的解集合非空 (feasibility)。

3.4 保證形式 (Theorem 2 + Corollary 1)

在 Assumption 1 (i.i.d. + 確定性預測器) 與 Assumption 3 (兩步版的單調/右連續/值域有界/在 $\bar{\lambda}$ 損失為 0) 下，若 $\alpha^{\cdot} \geq \alpha^{\text{cnf}} + B^{\cdot}/(n+1)$ ：

- 定位 / 分類保證 (Eq.7) : $E[L_{\text{test}}^{\cdot}(\lambda^{\text{cnf}}_+, \lambda^{\cdot}_+)] \leq \alpha^{\cdot}$ 。
- 信心保證 (Eq.8, 需額外假設) : $E[L_{\text{test}}^{\text{cnf}}(\lambda^{\text{cnf}}_+)] \leq \alpha^{\text{cnf}}$
- 聯合保證 (Corollary 1, Eq.9) : 把 α 在任務間「分帳」 $E[\max(L_{\text{test}}^{\text{loc}}, L_{\text{test}}^{\text{cls}})] \leq \alpha^{\text{tot}}$ ，其中 $\alpha^{\text{tot}} = \alpha^{\text{loc}} + \alpha^{\text{cls}}$ (用 $\max\{a, b\} \leq a+b$ 推得；若要把 cnf 也納入則 $\alpha^{\text{tot}} = \alpha^{\text{cnf}} + \alpha^{\text{loc}} + \alpha^{\text{cls}}$)。

保證性質要點：- 是期望值 (marginal/平均) 保證，非 PAC 式 $(1-\delta)$ 高機率保證、非 per-instance。- 重要差異化點 (作者自己強調)：與並行獨立工作 Xu et al. 2024 (Two-stage CRC for ranked retrieval, arXiv 2404.17769) 相比，SeqCRC 只需「單一資料切分 (single data split)」就能拿到有限樣本保證；Xu 等人的方法要嘛是 asymptotic、要嘛

要「兩次資料切分」。這是 SeqCRC 數學上最硬的賣點。- 與 LTT (Learn-Then-Test, Angelopoulos et al.) 對比：LTT 用 multiple testing 處理多參數，本文則用「樂觀/保守雙估計量 + 對稱性」走 CRC 路線（不是 LTT 路線）。

3.5 OD 特有的建模細節 (Section IV)

這些是讓抽象 SeqCRC 在 OD 上「真正能跑」的工程選擇：

- **保證層級 (level of guarantee)**：object-level (每個標註物件為一個 instance) vs image-level (每張圖為一個 instance)。本文核心採 **image-level**，理由是更彈性、可表達物件間互動。
- **Matching (預測框 ↔ ground-truth 配對)**：用「距離」 d 把每個真框配到最近預測框（可非單射；也可用 Hungarian 做單射）。距離選擇：
 - d_{haus} ：非對稱有號 Hausdorff (要把預測框撐多大才能完全蓋住真框的最小 margin) 一定位用。
 - d_{LAC} ：1 - 真類別的 softmax 分數—分類用。
 - $d_{\text{mix}} = \tau \cdot d_{\text{LAC}} + (1-\tau) \cdot d_{\text{haus}}$ (Eq.10, 實驗 $\tau=0.25$) —綜合，整體表現最好。
 - d_{GIoU} ：Generalized IoU —雖然最「OD 直覺」，但**實驗中全面表現最差** (因為與後續 loss 脫節)。
- **損失函數 (新舊都有)**：
 - Confidence：box_count_threshold (嚴格：框數 < 真框數就罰 1)、box_count_recall (鬆弛，缺框比例)。
 - Localization：L_thr (門檻式覆蓋率 $\geq \tau$)、L_box (box-wise recall, Eq.14)、L_pix (pixel-wise，按面積覆蓋比例，Eq. 最鬆、框最小)。
 - Classification：對每個真物件檢查類別是否落在預測集合內，取平均 (Eq.17)。
- **單調化技巧 (monotonization trick)**：loc/cls loss 對 λ^{cnf} 不必然單調 (因為 λ^{cnf} 變大 → 框變多 → matching 改變)，破壞 Assumption 3。作者用 $\sup_{\{\lambda' \geq \lambda^{\text{cnf}}\}} L(\lambda', \cdot)$ 的最小單調上界即時取代原 loss (沿用 Angelopoulos CRC 的做法)，保住保證但代價是更大的集合。
- 兩個演算法：Algorithm 1 (校準，含 on-the-fly 單調化)、Algorithm 2 (推論，只用 λ_+ 值，計算成本相對一次前向傳播可忽略)。

4. 實驗

4.1 設定

- 資料集：MS-COCO，用 validation split，再對切成 calibration / inference 各 $n = 2500$ 。
- 模型：YOLOv8x (68M，單階段) 與 DETR-101 (60M，transformer)，強調 **model-agnostic**。
- 風險層級： $\alpha^{\text{tot}} = 0.1$ ($\alpha^{\text{cnf}}=0.02, \alpha^{\text{loc}}=0.05, \alpha^{\text{cls}}=0.05$) 與 $\alpha^{\text{tot}} = 0.2$ 。NMS IoU 門檻 0.5。額外過濾 $\text{conf} < 1e-3$ (資料無關，不破壞保證) 以減緩單調化造成的爆框。
- 指標：依 CP 慣例報 **Empirical Risk** ($= 1 - \text{coverage}$ ，對 binary loss) 與 **Set Size** (三種：confidence= 平均框數；localization=conformal 框面積/原框面積開根號的 stretch；classification= 平均類別集合大小)。**沒有用 GREC 那套 $\text{Pr}(\text{F1}=1)/\text{N-acc}/\text{T-acc}$** 。

4.2 主要結果

- **風險全面被控制**：幾乎所有設定下 empirical risk $\leq$ 目標 α (少數略超出歸因於抽樣隨機性)，實證驗證 Theorem 2，且對 DETR/YOLO 都成立 → 印證 model-agnosticism。
- **Table I (DETR, $\alpha^{\text{tot}}=0.1$) 關鍵數字**：pixelwise loc loss 給最小 stretch (1.043)，box_count_recall 比 threshold 框數少 (17.8 vs 25.6)。鬆弛 loss → 集合更小但保證更弱。
- **Table II (matching $\times \alpha$)**：Hausdorff 最小化定位 size、LAC 最小化分類 size、Mix 給最佳折衷；GIoU 全面爆掉 (loc size 28、cls size 44)。 α 對 set size 的影響不平滑，小幅改 α 可能 size 大跳。
- **Table III (DETR vs YOLO, $\alpha^{\text{tot}}=0.1$)**：兩模型風險都受控，但 set size 取決於底層模型品質；YOLOv8 傾向「選較少框但定位修正更大」(同一組超參，trade-off 不同)。
- **heavy tail 警告 (Fig.7)**：跨所有 loss $\times$ set $\times$ matching 組合，set size 分布是重尾——很多組合會產生「整張圖那麼大的框」或「幾十個類別的集合」，完全不可用。亦即 loss/組合選錯會毀掉實用性。
- **失敗案例 (Fig.8, 兩隻斑馬)**：除了兩隻斑馬被正確偵測，還多出一個把兩隻都框住的大框 (無 ground-truth 對應)。作者點出兩個根本問題：

1. 本方法只保證 **recall** 夠高，只能「經驗性」限制 **false positive** (precision 是其參數的非單調函數，硬單調化會讓風險過大而無解)。
2. MS-COCO 標註本身不一致 (個別物件旁又有一個大包圍框、漏標)，模型學了就會不可預測地產生 **group box**。

4.3 Toolkit

開源 COD Toolkit (PyTorch，內含 YOLO/DETR、多種 loss、視覺化)，定位為「Conformal OD 的首個大規模 benchmark + 可重現基礎設施」(號稱數百次 run)。

5. 與 CRS (本論文主線) 的逐項 Diff 表

CRS = Cross-Base Conformal Composition : OWL-ViT 當 **abstention / no-target GATE + GroundingDINO** 出 **BOX**，用 LTT 聯合校準，對 **recall** 與 **abstention** (棄答/no-target) 同時給保證，Bonferroni over grid 處理多風險；在 gRefCOCO/RefCOCO 上輸出 conformal **referring set**，以 GREC 指標 (Pr@(F1=1,IoU≥0.5)、N-acc、T-acc) 評估；frozen base、post-hoc、不重訓。

5.1 相同點 (這些一定會被審稿人抓來說「很像」)

面向	兩者皆是
範式	post-hoc、frozen 模型、不重訓、distribution-free、有限樣本保證
家族	都屬 Conformal Risk Control / risk-control 系 (CRC ↔ LTT 同源思想)
結構	都有「兩個依序校準的參數/階段」(SeqCRC: cnf→loc/cls ; CRS: gate→box)
輸出 多風險	都輸出「一組框」而非單框，並對該集合給統計保證 都要處理「同時控多個風險」(SeqCRC 用 α 分帳 +max ; CRS 用 Bonferroni over grid)
評估	都報 risk + set size 類指標

5.2 不同點 (差異化主軸，逐項拆)

維度	SeqCRC	CRS (本論文)
任務本質	通用 OD : 定位 + 分類「閉集 K 類 softmax」	語言指涉 grounding (REC/GREC) : 輸入是自然語言 query，輸出是「query 指到的框集合」；沒有閉集類別、核心是 query↔region 的語意對齊
偵測器配置	單一偵測器 (DETR 或 YOLO，同一個 f 同時出 box+class+conf)	跨 base 異質組合 (cross-base composition) : OWL-ViT 與 GroundingDINO 是兩個不同模型，一個負責 gate/abstention、一個負責 box；組合本身是貢獻
兩參數的語意	cnf (信心門檻) + loc (框 margin) / cls (類別集合) — 都是同一模型內部的後處理旋鈕	gate 門檻 (控 abstention / no-target / recall) + box 選取 (控 compact referring set) — 跨兩個模型的功能分工 (factorization)

維度	SeqCRC	CRS (本論文)
雙風險的內容	loc 風險 + cls 風險 (兩個任務的覆蓋)	recall + abstention(no-target) 雙風險：不只「框要蓋到」，還要「該棄答時棄答」(gRefCOCO 的 no-target 樣本)。abstention 是 SeqCRC 完全沒有的軸
棄答 / no-target	無 abstention 機制；confidence threshold 只是 filter，不是「整張圖判定無目標」	核心貢獻就是 no-target 判定 (GREC 的 N-acc)，這是 grounding 特有、SeqCRC 結構上不存在的問題
集合語意	generic box set (每個框各自加 margin) + per-box 類別集合	referring set ：所有框共同回答「哪些 region 符合這句話」，集合層級語意
評估指標	Empirical Risk、Stretch、類別集合大小 (CP 慣例)	GREC 官方指標 $\text{Pr}@(F1=1, \text{IoU} \geq 0.5)$ 、N-acc、T-acc (grounding 社群指標，與下游使用直接對齊)
多風險聯手法	α 分帳 + Corollary 1 的 max 上界 (兩任務)	LTT + Bonferroni over a grid (multiple testing 路線)
保證數學手法	樂觀/保守雙估計量 ($\lambda^{\text{cnf}_{\pm}}$) + 對稱性 $\rightarrow$ 單切分有限樣本	LTT 的 multiple-hypothesis testing $\rightarrow$ 高機率 ($1-\delta$) 風險控制 (PAC 式，與 SeqCRC 的「期望值」保證型態不同)
應用定位	工業/安全關鍵認證 (鐵路、自駕、航太)	語言指涉 grounding 的 reliability / selective prediction 研究

5.3 一句話的「結構同 vs 本質異」

SeqCRC 與 CRS 在「兩個依序校準的 **conformal** 參數」這個骨架上同形，但 (1) SeqCRC 的兩參數是單一偵測器內部的 conf/margin，CRS 的兩階段是兩個異質模型的 gate/box 功能分工；(2) SeqCRC 控的是 loc+cls 覆蓋，CRS 控的是 **recall + abstention** 雙風險，其中 abstention/no-target 是 grounding 獨有、SeqCRC 結構上不存在的維度；(3) 任務一個是 generic 閉集 OD，一個是開放語言指涉 grounding。「結構撞名、語意不同軸」是 CRS 的防守線。

6. 論文要怎麼引用 / 切割這篇 (Related Work 可直接改寫的一段)

建議 **related work** 段落 (中文草稿，可翻英)：

在 conformal object detection 方向，最接近本文結構的是 Andéol et al. 的 Sequential Conformal Risk Control (SeqCRC) [arXiv:2505.24038]。SeqCRC 將 Conformal Risk Control 推廣到「1+2 個依序相依的純量參數」(信心門檻、定位 margin、分類集合)，對單一通用偵測器 (DETR/YOLO) 在 MS-COCO 上同時控制定位與分類風險，並以樂觀/保守雙估計量取得「單一資料切分」的有限樣本保證。我們的 CRS 在三個層面與之根本不同：(i) 任務軸不同——SeqCRC 處理閉集通用 OD 的定位/分類，本文處理開放詞彙的語言指涉 grounding (GREC)，核心是 query $\leftrightarrow$ region 對齊與 no-target 判定；(ii) 組合形態不同——SeqCRC 的兩參數是「單一偵測器內部」的後處理旋鈕，CRS 則是「兩個異質凍結模型」(OWL-ViT 作 abstention/no-target gate、GroundingDINO 出 box) 的功能分工式組合 (factorization)，並以 ablation 證實此分工非單純 ensemble；(iii) 風險軸不同——SeqCRC 控定位 + 分類覆蓋，CRS 則同時對 **recall 與 abstention (no-target)** 給保證，而 abstention 是 grounding 特有、SeqCRC 結構上不涉及的維度。此外，SeqCRC 採 CRC 的期望值保證並以 α 分帳處理多任務，CRS 則採 LTT + Bonferroni-over-grid 取得高機率 (PAC 式) 多風險控制，並以 GREC 官方指標 ($\text{Pr}@(F1=1)$, N-acc, T-acc) 評估，與下游使用直接對齊。

切割要點 (口袋清單，被審稿人 challenge 時用)：1. 「你不就是 SeqCRC 換個任務？」 $\rightarrow$ 不是。SeqCRC 沒有 abstention/no-target 軸，而那是 grounding 的核心；SeqCRC 是單一偵測器內部旋鈕，CRS 是跨異質 base 的功能 factorization (有 2 $\times$ 2 ablation 證成)。2. 「兩個依序參數的數學是不是一樣？」 $\rightarrow$ 同屬 risk-control 家族但路線不同：SeqCRC 走 CRC 的雙估計量 + 對稱性 (期望值保證、單切分)；CRS 走 LTT+Bonferroni (PAC 式高機率、grid multiple

testing)。可主動承認結構同源，把差異收斂到「保證型態 + 風險語意」。3. 指標不可比：SeqCRC 報 stretch / 類別集合大小；CRS 報 GREC 指標。可在實驗章節說明「為何 grounding 必須用 GREC 而非 generic CP set-size」。4. 可引為「同期獨立、結構最近鄰」，承認其貢獻（首個 holistic conformal OD 框架 + 大規模 benchmark + 開源 toolkit），藉此凸顯 CRS 把同一骨架搬到「語言指涉 + 跨 base + 棄答」這個更難且 SeqCRC 未觸及的設定。

7. 個人評價

優點

- 問題定位漂亮：把「conformal OD 只做子步驟」這個 gap 講得很清楚，holistic 框架 + 三參數拆解確實補了洞。
- 數學賣點硬：相對 Xu et al. (ranked retrieval) 的「兩次切分 or asymptotic」，SeqCRC 用樂觀/保守雙估計量做到單切分有限樣本，這是真正可被引用的技術貢獻。
- 工程誠實：單調化技巧、GIoU 失效、heavy-tail set size、斑馬 false positive、COCO 標註不一致——把 conformal OD 的實務陷阱攤開講，對後續研究很有價值。
- 可重現性強：開源 toolkit + 數百 run benchmark，社群基礎設施貢獻明確。

缺點 / 侷限

- 只保證 recall，不保證 precision：作者自己承認 precision 非單調、無法在框架內控制。對安全關鍵應用（要少誤報）其實是大坑。
- 期望值保證偏弱：是 marginal 期望值，不是 per-instance、不是 PAC 高機率。實務上「平均達標但某些圖爆掉」的風險仍在（heavy tail 正是這個徵兆）。
- 聯合保證過保守：Corollary 1 的 $\max \leq a+b$ 分帳，作者自承 global risk「常常不必要地保守」。
- set size 對 α 不平滑：小改 α 可能讓集合大跳，調參體驗差，實務難用。
- 依賴 ground-truth 品質：若標註比模型還差，conformal 會被迫加超大修正 → 集合不可用。這在 grounding（標註更主觀）只會更嚴重，對 CRS 反而是要警惕的共通風險。
- 任務範圍窄於它的雄心：號稱 holistic，但實際只在 COCO + 兩個偵測器、閉集分類上驗證；沒碰開放詞彙、沒碰 abstention ——正好是 CRS 的主場。

對本論文 (CRS) 的戰術啟示

- SeqCRC 是最該主動引用且主動切割的對象，不要迴避。承認結構同源能降低審稿人「你在規避」的疑慮。
- 把 CRS 的差異化收斂到三個不可被吸收的軸：abstention/no-target、cross-base factorization、PAC-式雙風險（recall+abstention）。這三個 SeqCRC 結構上都沒有。
- SeqCRC 的 heavy-tail 與 precision 缺口，可在 CRS 的 discussion 借力：說明 CRS 用 LTT 高機率保證 + abstention 軸，正是在補「只控 recall、只給期望值」的不足。