

VIRO 深讀筆記—Verification-Integrated Reasoning Operators

為碩論 selective grounding / CRS (Cross-Base Conformal Referring Set) 整理。本篇是「no-target / abstention 軸」上最需要劃清界線的競品之一 (另一篇為 True/False Verification, 2509.09958)。

一、書目資訊

- 標題：VIRO: Robust and Efficient Neuro-Symbolic Reasoning with Verification for Referring Expression Comprehension
 - 注意：縮寫 VIRO 在論文裡實際展開為 **Verification-Integrated Reasoning Operators** (標題用的是另一個 backronym 的全稱，但摘要與內文明確定義 VIRO = Verification-Integrated Reasoning Operators)。
- arXiv：2601.12781 (v2 · 標頭顯示 [cs.AI] 20 Mar 2026)
- 作者 / 單位：Hyejin Park、Junhyuk Kwon、Suha Kwak、Jungseul Ok († 通訊) —POSTECH (南韓浦項工科大学)
- 程式碼：<https://github.com/ml-postech/VIRO-neuro-symbolic-reasoning-with-verification>
- 推測場合：CVPR 2026 等級 (neuro-symbolic compositional REC 主流會議圈，與 NAVER@ICCV、HYDRA 同梯)。
- 一句話定位：在「LLM 把 query 拆成符號程式 → 逐步執行」的 compositional REC 流程裡，於每個 operator 內嵌輕量驗證器，驗證不通過就回傳空集合 $\emptyset$ 並提早終止，從而能顯式處理「圖中根本沒有 target」的 no-target case，不再被迫硬輸出一個框。

二、問題定義與動機

2.1 任務形式化 (含 no-target)

傳統 REC 假設 query 描述的物件一定存在於影像中。VIRO 把輸出形式化為：

$Y = B$ 若 I 中存在 target ($B = (x, y, w, h)$ 像素座標框)
 $Y = \emptyset$ 否則 (no-target · 影像中沒有任何符合 query Q 的物件)

這正是 GREC / gRefCOCO 引入的「廣義 REC」設定 (可能 0、1 或多個 target)，但 VIRO 在本文只聚焦 **0-target (no-target) vs 1-target** 的二元軸，沒有處理 multi-target。

2.2 核心痛點：cascading error → forced prediction (強迫輸出)

論文點名 compositional / neuro-symbolic REC 的根本失效模式：

1. 中間步驟被假設為正確：ViperGPT / VisProg / HYDRA / NAVER 這類方法把 query 拆成 object detection、attribute filtering、spatial reasoning 等步驟，但每一步的中間輸出 (proposals、屬性匹配、空間關係) 被預設正確、直接往下傳，沒有顯式檢查。
2. OVD 的高信心 false positive：open-vocabulary detector (GroundingDINO / GLIP) 即使在圖中沒有該物件時，仍會對「視覺或語意相似」的區域給出高信心誤檢 (object hallucination)。
3. 錯誤級聯 (cascading error)：上述 FP 沿 reasoning chain 一路傳播，最終在 no-target 情形下，pipeline 被「強迫」從這些 FP 中挑一個當答案 → 產生高信心的錯誤框。
4. 效率/擴展性問題：(i) 不少系統把重量級 multimodal LLM 放在 inner loop → 高延遲；(ii) 程式生成與執行耦合，video / 多影像時要對每張影像重新生成程式 → 計算量隨影像數線性增長。

Figure 1 的兩個例子：query「the person to the left of the elephant」中圖裡根本沒大象 → 先前方法被迫輸出框；VIRO 的 FIND 發現「圖裡沒有 elephant」、或 FIND_DIRECTION 發現「person 並不在 elephant 左邊」→ 提早終止、回傳 no-target，而非幻覺一個答案。

2.3 三大貢獻

1. 把 **forced prediction** 指認為 compositional vision-language reasoning 的根本失效模式，並用 verification-integrated operators 對症。
2. 設計 **operator-level program**：每個 operator 同時「執行 reasoning」與「自我驗證」，用 uncertainty-based + logic-based 檢查抑制 error cascade，並達成顯式 no-target 偵測。
3. zero-shot 下在 gRefCOCO no-target split 展現強 robustness，並在標準 REC (RefCOCO+/g、對抗 RefAdv、egocentric RefEgo) 達 compositional baseline 中的 SOTA；藉「程式合成與執行解耦」實現 1-query-N-images 的良好擴展性。

三、方法詳解

3.1 整體：兩階段 neuro-symbolic pipeline

Q (自然語言 query)

└ [Pre-execution stage] → LLM 生成符號程式 $P = (o_1, o_2, \dots, o_T) \rightarrow$ Program Validator 文法校驗 / 自我修正
└ [Execution stage] → Interpreter 在影像 I 上逐步執行 operator，每步自我驗證；
 任何 operator 回傳 $\emptyset \rightarrow$ 立即 early-exit $\rightarrow$ 該圖判為 no-target
 全部通過 $\rightarrow$ RESULT 把最終候選映成答案框 B

關鍵設計：解耦 (decoupled)。程式只對 query 生成「一次」，可在 N 張影像上重複使用： $T_{total} = T_{pre} + N \times T_{exec}$ ；而 HYDRA / NAVER 把合成與執行糾纏，每張圖都重生程式： $T_{total} = N \times T_{pre} + N \times T_{exec}$ 。

3.2 Verification Reasoning Operators (VROs)

定義一組有限的原語 operator 集合 $\mathcal{O}$ 。每個 operator 既執行一個 **reasoning** 動作，也驗證自己的輸出；若驗證條件不滿足，回傳空集合 $\emptyset$ (觸發整條 pipeline early-exit)。四類：

- **Identification**：FIND (偵測候選)、PROPERTY (依屬性 refine 實體)
- **Absolute spatial**：LOCATE、SIZE、ORDER、ABSOLUTE_DEPTH (絕對位置/尺度/排序/深度)
- **Relative spatial**：FIND_DIRECTION、FIND_NEAR、FIND_INSIDE、RELATIVE_DEPTH (多實體間空間關係)
- **Termination**：RESULT (把選定物件映入答案空間，程式必須以此結尾)

所有 operator 都設計成回傳「一組已驗證的 bounding box」或在條件不滿足時回傳 $\emptyset$ 。

兩種驗證模組 (A) Uncertainty Verification (UV) — 在 FIND operator 裡

- FIND(object_name=l) 先叫 OVD D (GroundingDINO 或 GLIP) 在影像上以標籤 l 產生候選 $\{B_j\}$ 。
- 為了過濾 OVD 的高信心 FP，加一個輕量 **CLIP-based 二元驗證**：對每個候選 crop 出區域 I_j ，預先準備 K 個常見類別 $C = \{c_1 \dots c_K\}$ 當作 **負錨點 (negative anchors)**，驗證分數是「target l vs 每個 c_k 一對一比較」的平均勝率：

$$S(l | I_j) = (1/K) \sum_k \exp(\text{sim}(I_j, l)/\tau) / [\exp(\text{sim}(I_j, l)/\tau) + \exp(\text{sim}(I_j, c_k)/\tau)]$$

- 只有 $S(l | I_j) \geq \delta_l$ 才接受該候選為 1。 δ_l 可為固定門檻或 **per-label 自適應門檻**。
- **門檻的取舍**：太接近 0.5 $\rightarrow$ TP 被誤殺或 FP 漏網；又因 CLIP 對訓練常見類別 (person、car) 有偏，固定門檻對各類別不公平。

(B) Logical Verification (LV) — 在 FIND_DIRECTION operator 裡

- FIND_DIRECTION(object, reference_object, direction)：對所有輸入候選做**幾何測試**，驗證每個 object proposal 是否相對於至少一個 reference_object 滿足指定的空間關係 (左/右/上/下...)。不滿足者剔除；全空則回 $\emptyset$ 。
- 即「空間關係不是假設成立，而是逐一幾何檢查」。

3.3 自適應門檻校準 (Adaptive Threshold · Appendix A.1.3) —這是和 CRS 最易混淆、最需釐清的一段

- 用 **ImageNet** 當輔助校準資料：每類取 5 張、共 5,000 張，用 GroundingDINO crop 出該類物件 (記為 D_A)，降低背景偏差。
- 對每個 target label l ，在 D_A 上算出該類的驗證分數分布 $S(l \mid D_A)$ 。
- **Top-k%** 選擇策略：把分數排序，門檻 δ_l 取「最高分的 top-k%」對應的分數 (k 通常設 10)。直覺是「捕捉 CLIP 對該類別在高信心預測時穩定達到的水準」，給一個 data-driven 的 per-label 門檻。
- 對 k 不敏感 (Balanced Accuracy 穩定)。

重點：這是一個啟發式、**per-label** 的分位數門檻調參，目的是抵銷 CLIP 的類別偏差。它**不是** distribution-free 的 conformal calibration，沒有任何有限樣本的覆蓋保證或風險上界；ImageNet 也只是用來估「CLIP 對某類的典型信心範圍」，不是用來控制 no-target 的錯誤率到某個 α 。下面第五節會逐項對照。

3.4 Program Generation + Validation (Appendix A.2)

- 生成：用 LLM 做 few-shot (仿 VisProg)， $P = \text{LLM}(Q \mid m)$ 。主用 **Qwen2.5-72B-Instruct-AWQ** (強 code-gen，與 ViperGPT 公平比較)；也可用 GPT-4o/mini、Llama3.1。
- 驗證器 (**Validator**)：強制嚴格文法 $\text{VAR} = \text{OP}(\text{ARG}=\dots, \dots)$ ，結尾必為 $\text{FINAL_RESULT} = \text{RESULT}(\text{object}=\text{VAR})$ 。檢查 syntax、變數追蹤、引數型別、operator 約束、輸出格式。失敗 → 回診斷訊息給 LLM 重生 (最多 5 次)。這使 program failure rate 壓到 $\leq 0.3\%$ (相對 HYDRA/NAVER 動輒 20–35% 失敗率)。

3.5 是否 training-free / backbone

- 是 **training-free / zero-shot**：所有元件皆現成預訓練模型，無 REC fine-tune (自適應門檻只用 ImageNet 統計，不訓練)。
- **Backbone** 組合：OVD = GroundingDINO-T 或 GLIP-L；驗證/屬性 = CLIP (ViT-H/14，輕量替代 ViT-L/14)；深度 = DepthAnything v2；程式生成 = Qwen2.5-72B (或 GPT-4o/Llama3.1)。

四、實驗

4.1 資料集與指標

- **No-target**：gRefCOCO no-target split (只取「圖中無對應物件」的 query；負例被約束成「與圖語意相關」以避免 trivial negative)。
- 標準 REC：RefCOCO / RefCOCO+ / RefCOCOg (TestA=person、TestB=object)。
- 對抗語言：RefAdv (Ref-Hard 的結構依賴 OOD 子集)。
- 影片/第一人稱：RefEgo (Ego4D，含 target-present 與 no-target frame，天然對應 1-query–N-images)。
- 可擴展到 VQA：GQA (附錄)。

指標 (關鍵，與 CRS 對比重點)：

- **Balanced Accuracy = (TPR + TNR)/2**。
 - $\text{TPR} = \text{TP}/(\text{TP}+\text{FN})$ ，等同標準 REC 的 **Acc@0.5** (IoU>0.5)。
 - $\text{TNR} = \text{TN}/(\text{TN}+\text{FP})$ ，即 **no-target accuracy (N-acc)**。
- 混淆矩陣定義：TP= 有 target 且 IoU>0.5；TN= 無 target 且正確判 $\emptyset$ ；FP= 無 target 卻輸出框；FN= 有 target 卻判 no-target 或 IoU<0.5。
- RefEgo 另用 **mSTIoU** 與 **ACC@0.5+n** (frame 層級，target-present 看 IoU>0.5、no-target 看正確判 $\emptyset$)。

重要觀察 (對 CRS 切割直接相關)：VIRO 並未採用 GREC 官方的 $\text{Pr}@(F1=1) / \text{N-acc} / \text{T-acc}$ 這套三元 GREC metric。它把 gRefCOCO 重新框成一個二元分類問題 (target-present vs no-target)，只用 TPR/TNR/Balanced Accuracy，且 **no-target** 與 **target-present** 是用不同 split 各自評估後合併 (gRefCOCO no-target split 量 TNR、RefCOCO 量 TPR)。也就是說，VIRO 的「no-target 評估」本質是 點估計的分類正確率，沒有覆蓋/風險的統計保證描述。

4.2 主結果

Table 2 (gRefCOCO no-target + RefCOCO TestA/TestB) —Balanced Acc / TNR / TPR :

類別	方法	TestA Bal.Acc	TestA TNR	TestA TPR	TestB Bal.Acc	TestB TNR	TestB TPR
全監督	Qwen2.5-VL-72B-AWQ†	69.5	47.3	91.7	66.8	45.1	88.4
全監督	GREC-MDETR-R101	62.0	34.5	89.6	56.2	31.0	81.4
全監督	GREC-UNINEXT-R50	70.4	49.3	91.5	67.6	48.2	86.9
Proposal	ReCLIP	23.5	0.0	47.0	22.6	0.0	45.2
Proposal	SS-CLIP	33.3	0.0	66.5	27.5	0.0	54.9
Proposal	GroundVLP	30.7	0.0	61.3	21.8	0.0	43.5
Detector	GLIP-L	37.2	21.7	52.6	30.0	18.2	41.8
Detector	GroundingDINO-T	40.0	22.8	57.2	29.6	16.0	43.2
Compositiona	ViperGPT	33.4	0.2	66.7	27.4	0.1	54.6
Compositiona	HYDRA	35.2	7.5	62.8	34.7	7.0	62.4
Compositiona	NAVER	33.8	3.4	64.2	30.0	1.8	58.2
本文	VIRO	61.1	50.2	71.9	56.9	52.9	60.8

要點：proposal-based 因「必選一框」TNR≈0；compositional baseline 雖有 reasoning 但 TNR 仍只有個位數 (ViperGPT≈0.1–0.2、NAVER 1.8–3.4)。VIRO 把 TNR 拉到 50% 以上、且 zero-shot 下 Balanced Acc 逼近甚至超越部分全監督 GREC 模型 (如 GREC-MDETR)，但其 TPR (71.9/60.8) 明顯低於全監督 (88–91) ——即它用「敢棄答」換了 no-target robustness，代價是 target-present recall 下降。

Table 3 (標準 REC 效率)：VIRO program failure rate ≤0.3% (HYDRA/NAVER 為 28–36%)；execution runtime 最低 (Exec. 0.71s/query)，E2E 12.92s (多半是 72B LLM 的 pre-execution)。Acc@0.5 (TestA) RefCOCO 71.9 / RefCOCO+ 63.3 / RefCOCog 66.6，在 compositional baseline 中最高。

Table A2 (gRefCOCO no-target，純 TNR)：VIRO 在 GroundingDINO 下 Val/TestA/TestB = 56.5/50.2/52.9，遠勝 NAVER(3.0/3.4/1.8)、HYDRA(8.6/7.5/7.0)、ViperGPT(≈0.3)，甚至勝過全監督 GREC-UNINEXT(50.6/49.3/48.2)。

Ablation (Table 5)：Detector-only(Bal 40.0) → +Operators(56.8) → +LV(57.0) → +UV fixed(58.8) → +UV adaptive(**61.1**)。可見 no-target robustness 的主要增益來自 compositional operators 本身 + UV 的 adaptive 門檻 (TNR 從 22.8→50.2)；LV 貢獻較小。OVD 門檻取 0.2 (偏高 recall)。

RefEgo (Table 4)：VIRO mSTIoU 22.8、ACC@0.5+n 51.9，在 zero-shot 中最佳，ACC@0.5+n 甚至超過全監督 MDETR+BH(51.1)。

Forced prediction (Table A1)：把 abstention 關掉、強迫輸出時，VIRO 標準 REC TPR 也具競爭力 (如 RefCOCO TestA 75.0–75.7)，說明棄答不是靠犧牲 grounding 換來的。

五、與 CRS 的逐項 diff (最重要)

CRS = 我的碩論：Cross-Base Conformal Referring Set。OWL-ViT 當 gate (控 abstention/no-target) + GroundingDINO 出 box (控 compact set)，用 **LTT (Learn-then-Test)** 做 **distribution-free** 校準，在 $\alpha=\beta$ (含 R3 三風險 Bonferroni) 下對 **recall + abstention** 同時給有限樣本風險上界，輸出一個 **conformal referring SET** (多框集合，帶覆蓋保證)，錨 gRefCOCO/RefCOCO、用官方 GREC metric。

維度	VIRO	CRS (本論文)
核心機制	symbolic 程式 + operator 級「驗證」(CLIP 二元判別 + 幾何邏輯檢查) · 驗證不過就回 $\emptyset$	post-hoc conformal composition : 對 frozen base 的分數做分布無關校準, 輸出風險受控的集合
no-target 判定依據	operator 回傳空集合即 early-exit ; 本質是「CLIP 分數 < 自適應門檻」或「幾何關係不成立」	OWL-ViT gate 在 LTT 校準下, 當且僅當無候選通過風險受控門檻時 abstain ; abstention 是一個被風險上界約束的決策
是否有統計保證	無。Top-k% / ImageNet 門檻是啟發式調參, 沒有有限樣本覆蓋或風險上界 ; TNR 是事後點估計, 沒有「保證 $N\text{-acc} \geq 1-\alpha$ 」這類 claim	有。LTT 給 distribution-free, finite-sample 的風險上界 ; R1/R2 (含 R3) CI 上界皆 < 0.3 , 可寫成「 $P(\text{風險} > \alpha) \leq \delta$ 」
pipeline 結構	single pipeline (單一 OVD + 單一 CLIP 驗證 + DepthAnything) · 所有 operator 都掛在這條鏈上	cross-base composition : OWL-ViT 與 GroundingDINO 是兩個獨立 base, 分工 (gate vs box) · 2x2 ablation 證 factorization 非 ensemble
輸出型態	單一 box B 或 $\emptyset$ (point prediction , 二元)	referring SET (0..K 個框的集合) + 覆蓋保證 ; 本質是 set-valued prediction
是否有 referring set / 覆蓋保證	無 set、無覆蓋保證 ; 只輸出一個框或棄答	有 : set size 受控 ($\alpha=\beta=0.3$ 下 val/testA/testB $\approx 3.21/2.02/3.48$ 框) · 且 size CI 與純 OWL 分離
評估指標	Balanced Acc / TPR / TNR (自定二元混淆矩陣, 未用官方 GREC Pr@ (F1=1)) · no-target 與 present 分 split 各自量	官方 GREC metric (Pr@ (F1=1) / N-acc / T-acc) + 風險 CI + size CI ; no-target 在同一統計框架內
multi-target	不處理 (只 0/1 target 二元軸)	GREC 廣義設定, 可涵蓋 0/1/多 target (set 天然支援多框)
訓練/校準資料	ImageNet (5k 張) 估 per-label CLIP 門檻——用於去 CLIP 偏差, 非控錯誤率	gRefCOCO/RefCOCO 校準集——用於 LTT 風險控制 (calib-only grid、修 leakage)
是否 training-free	是 (zero-shot, 無 REC fine-tune)	是 (post-hoc、frozen base, 無 fine-tune) ——這點兩者相同, 更需在「保證」軸劃界
跨 base 轉移	無此 claim (換 OVD 是 robustness 比較, 非轉移保證)	C4 : raw consistency zero-shot 跨 base 轉移 $\approx$ native ; composition 跨 base 校準

一句話差異 : VIRO 和 CRS 都「post-hoc、training-free、針對 no-target/abstention、都用 CLIP/GroundingDINO」, 表面高度重疊 ; 但 **VIRO** 的 **abstention** 是一個沒有統計保證的啟發式門檻決策、輸出單框、用自定二元指標, 而 CRS 的 abstention 是分布無關、有限樣本風險上界約束下的集合值決策 (**conformal referring set**) · 用官方 **GREC metric** 評估。VIRO 是「更聰明地猜要不要棄答」, CRS 是「以可證明的風險上界保證棄答/召回」。

六、論文該怎麼引用 / 切割 (精準切割文字)

VIRO 直接踩在 CRS 的 no-target/abstention 軸上, 是 related work 與 motivation 都必須點名、且要明確劃清「保證 vs 啟發式」的一篇。建議 :

6.1 Related Work 段落 (中性引介 + 切割)

「近期 neuro-symbolic REC 已開始正視 no-target / forced-prediction 問題。VIRO [cite] 在 compositional pipeline 的每個 operator 內嵌輕量驗證 (CLIP-based uncertainty verification 與幾何 logical verification)，當驗證失敗即回傳空集合並提早終止，從而顯式偵測 no-target，並在 gRefCOCO no-target split 上大幅提升 no-target accuracy (TNR)。然而 VIRO 的棄答決策來自一個啟發式的 **per-label CLIP 門檻** (以 ImageNet top-k% 分位數校準以抵銷 CLIP 類別偏差)，其 no-target 正確率僅以事後點估計 (**Balanced Accuracy / TNR**) 報告，並未提供任何有限樣本的覆蓋或風險保證；其輸出亦為單一框或空集合的 point prediction，而非帶覆蓋保證的集合。」

6.2 與本文 (CRS) 的定位差異 (緊接著寫)

「相對地，本文不修改 base 模型、也不依賴啟發式門檻，而是在 frozen base 之上以 Learn-then-Test 做分布無關、有限樣本的校準，使 abstention (no-target) 與 recall 同時受可證明的風險上界約束，並輸出一個帶覆蓋保證的 **conformal referring set**。換言之，VIRO 與 True/False Verification [cite] 解決的是『如何更可靠地判定要不要棄答』，而本文解決的是『棄答與召回的錯誤率如何被統計上界所保證』；兩者在『verification 機制是否提供分布無關保證』、『輸出是 point prediction 還是 set with coverage』、『評估是否在官方 GREC 風險框架內』三點上交。」

6.3 防審稿人「你和 VIRO 差在哪」的一段 (rebuttal-ready)

三條硬切割，逐條釘死：1. 保證類型：VIRO 的 adaptive threshold 是去偏的啟發式，無 finite-sample 保證；CRS 用 LTT 給 $P(\text{risk} > \alpha) \leq \delta$ (R1/R2/R3 Bonferroni)。2. 輸出語意：VIRO 輸出單框/ $\emptyset$ ；CRS 輸出 size 受控、覆蓋受控的 referring set (size CI 與純 OWL 分離)。3. 架構：VIRO 是 single pipeline；CRS 是 cross-base composition (OWL gate $\times$ GD box)，2 $\times$ 2 ablation 證明是 factorization 而非 ensemble。另可補：VIRO 用自定二元 TPR/TNR (未用官方 GREC $\text{Pr}@(\text{F1}=1)/\text{T-acc}$)，且不處理 multi-target；CRS 全程在官方 GREC metric 與 multi-target set 下評估。

6.4 引用時務必避免的誤述

- 不要說 VIRO 「校準了 no-target 風險」——它只是調了一個去偏門檻。
- 不要說 VIRO 用 conformal / 覆蓋保證——它完全沒有。
- 不要把 VIRO 的 TNR 當成「保證值」——那是 split 上的點估計。
- 注意：VIRO 用的是 gRefCOCO 的 **no-target split + 自定 Balanced Acc**，不是官方 GREC 三元指標——比較數字時不可直接和 CRS 的 $\text{Pr}@(\text{F1}=1)$ 並列，需註明指標口徑不同。

七、個人評價

優點

- 把「forced prediction / cascading error」這個 compositional REC 的痛點講得很清楚，Figure 1 與 ablation (Detector-only 40.0 $\rightarrow$ +UV adaptive 61.1) 把 no-target 增益歸因得乾淨。
- operator-level 驗證 + program validator 的工程價值高：program failure rate $\leq 0.3\%$ vs HYDRA/NAVER 20–35%，是實打實的可靠性提升。
- decoupled 設計在 1-query–N-images / video (RefEgo) 上的擴展性論證紮實，這是對機器人視覺搜尋等落地場景真正有用的角度。
- training-free、backbone 都是現成模型，復現門檻相對低 (雖然要 72B LLM)。

局限 (也正是 CRS 的切入空間)

- **abstention 無統計保證**：整套 no-target 判定建立在一個啟發式 per-label 門檻上，沒有覆蓋/風險上界，TNR 是事後點估計。一旦分布偏移 (RefEgo 上 TNR 與 RefCOCO 不同)，它沒有任何形式保證能撐住——這正是 conformal 框架的價值所在。
- **單框輸出、不處理 multi-target**：在真正的 GREC (0/1/多 target) 設定下表達力受限；CRS 的 set-valued 輸出在這點上是結構性優勢。

- 指標自定：用 Balanced Acc / TNR 而非官方 GREC $\text{Pr}@(\text{F1}=1)$ ，雖然直觀，但與 GREC 主線文獻不完全可比，也讓「no-target 到底控到多嚴」缺乏統一口徑。
- TPR 明顯低於全監督 (71.9 vs 88–91)：敢棄答的代價是 recall 掉，但因為沒有風險框架，使用者無法在「我要 recall $\geq$ 某值」與「no-target 錯誤 $\leq$ 某值」之間做有保證的取舍——CRS 的 α/β 雙旋鈕正好補這個洞。

對 CRS 的威脅評估：VIRO 是「同軸最近競品」，會搶走「我們是第一個正視 compositional REC no-target」這種 novelty 措辭，但完全沒碰到 CRS 的核心 novelty (**distribution-free finite-sample 保證 + conformal referring set + cross-base composition + 官方 GREC 風險評估**)。只要在 related work 與 rebuttal 把「啟發式門檻 vs 可證明風險上界」「point prediction vs set with coverage」「single pipeline vs cross-base」三刀切清楚，VIRO 對 CRS 的 abstention novelty 不構成實質威脅，反而是極好的 motivation 對照組與 baseline 候選 (可在 GREC metric 下重評它，凸顯它沒有保證)。