

論文精讀：Enabling Calibration In The Zero-Shot Inference of Large Vision-Language Models

為 CRS (Conformal Referring Set) 碩論之「可靠性 / 校準」背景與基線對照所做的深度導讀。

一、書目資訊

- 標題：Enabling Calibration In The Zero-Shot Inference of Large Vision-Language Models
- 作者：Will LeVine、Benjamin Pikuš (兩人並列第一作者)、Pranav Raja、Fernando Amat Gil
- 單位：Scale AI
- 發表場合：ICLR 2023 Workshop paper (workshop 等級，非主會議長文)
- arXiv：2303.12748 (v1 提交於 2023-03-11，最終 v4 修訂於 2023-04-18)
- 領域：cs.CV / cs.LG
- 篇幅：正文約 5 頁 + 參考文獻 + 附錄 (屬短篇 workshop paper，方法輕量、實證為主)

一句話定位：這是一篇「zero-shot VLM (以 CLIP 為代表) 到底校不校準？」的系統性量測研究，並提出一個與 zero-shot 使用範式相容的溫度縮放變體 (Zero-Shot-Enabled Temperature Scaling, ZS-TS)。它是「VLM miscalibration」這個命題的代表性早期實證文獻之一。

二、問題定義與動機

2.1 為什麼要談校準 (calibration)

模型的可信度 (trustworthiness) 與安全使用的一大關卡，是它的信賴度估計是否反映真實正確率。直觀定義 (Guo et al. 2017 的經典例子)：若取 100 個信賴度都是 0.8 的預測，理想上應有 80 個是正確的。若成立，模型即為「已校準 (calibrated)」。

形式化定義 (論文式 (1))：令 $\hat{p}(x_i, \hat{f}) = \max_c \hat{f}_c(x_i)$ 為模型對 x_i 的信賴度 (取 softmax 後最大類別機率)。模型已校準的條件是

$$\text{acc}(\hat{f}, D_p^{\text{test}}) = p \quad \forall p \in [0, 1]$$

其中 D_p^{test} 是所有信賴度恰為 p 的測試樣本子集。注意：這是對一群樣本定義的 (單一樣本算不出 accuracy)，所以需要分箱 (binning) 的經驗近似。

2.2 為什麼是 zero-shot VLM 這個缺口

校準在「傳統監督分類」上已被大量研究 (Guo et al. 2017 ; Kull et al. 2019 等)：固定類別數、單模態、train/val/test 切分、在 val 上調校。

但 CLIP (Radford et al. 2021) 這種 zero-shot 推論範式打破了上述所有前提：

1. 資料是多模態 (影像 + 文字)。
2. 推論時的「類別」由自然語言 prompt 即時定義，訓練時並未把這些類別當作目標類別。
3. 因此沒有「per-inference-dataset 的校準集」可用——若要求每換一個下游任務就重新蒐集標註校準集，就違背了 zero-shot 的初衷。

論文明確指出：在本文之前，既沒有對 CLIP zero-shot 校準的系統性量測，也沒有把校準方法套用到 CLIP zero-shot 設定的研究 (Minderer et al. 2021 僅順帶提及 CLIP 校準，未跨 prompt/資料集/架構分層研究)。這就是本文要補的缺口。

2.3 兩大貢獻

1. 量測 (**analytical study**) : 把 CLIP 的校準按「架構 (architecture)、資料集 (pre-training + inference)、輸入 prompt」三軸分層做系統量測，發現 **CLIP zero-shot 推論普遍 miscalibrated**。
2. 方法 (**ZS-TS**) : 提出與 zero-shot 範式相容的溫度縮放——對每個 (架構 × 預訓練資料集) 配對只學一個純量溫度 T ，且此 T 可跨「inference 資料集 + prompt」泛化使用，推論時免再訓練、免調校、免校準集。

三、方法與技術細節

3.1 CLIP 的 logit 與信賴度

CLIP 把 logit 定義為影像嵌入 $E_{im}(x_i)$ 與各類別文字嵌入 $E_{lang}(y_c)$ 的餘弦相似度，乘上固定常數 100：

$$L_c^{\text{CLIP}}(x_i) = 100 \cdot \frac{E_{im}(x_i) \cdot E_{lang}(y_c)}{\|E_{im}(x_i)\| \|E_{lang}(y_c)\|}$$

(這個 100 本身就是 OpenAI 官方實作裡的標準純量溫度乘數。) 再經 softmax 轉成類別機率 $\hat{f}_c(x_i)$ ，取 $\max_c$ 得信賴度。

3.2 量測工具：Reliability Diagram + ECE

- **Reliability diagram (信賴度圖)** : 把樣本依信賴度分到 M 個等寬箱 B_m ，畫出每箱「真實正確率 vs 平均信賴度」的差距，偏離對角線 $f(x) = x$ 即為 miscalibration。粉紅 = 過度自信 (overconfidence)，紫色 = 信心不足 (underconfidence)。本文固定 $M = 10$ (業界標準)。同時畫信賴度直方圖 $|B_m|$ ——樣本多的箱若失準，比樣本少的箱失準更嚴重。
- **Expected Calibration Error (ECE · Naeini et al. 2015)** : 把 reliability diagram 的失準量總結成單一純量：

$$\text{ECE} = \sum_{m=1}^M \frac{|B_m|}{|D|} \left| \hat{p}(\hat{f}, B_m) - \text{acc}(\hat{f}, B_m) \right|$$

即各箱「平均信賴度與真實正確率之差」的絕對值，依箱內樣本占比加權求和。**越低越好**。

3.3 監督式溫度縮放 (傳統基線)

Temperature Scaling (Guo et al. 2017) 對凍結網路做事後校準：把 logit 整體除以一個純量溫度 T ：

$$L_c^{\text{calibrated}}(x_i; T) = L_c(x_i) / T$$

T 由一個與推論資料集同分布的校準集 $D^{\text{calibration}}$ 透過最小化交叉熵習得。論文也在附錄列了其他監督式方法 (Isotonic Regression、Histogram Binning) 與 Unsupervised TS 作對照——但這些方法都需要「逐 inference 資料集的校準集」或標籤，與 CLIP 的用法不符，故僅供 context，不適合廣泛採用。

3.4 本文方法：Zero-Shot-Enabled Temperature Scaling (ZS-TS)

核心洞見很簡單但定位很巧：

- 對某個固定的 (架構 × 預訓練資料集)，只在一個輔助資料集 (**auxiliary dataset**) 上用標準 TS 學一個溫度 T 。本文一律用 **ImageNet-1k** 當輔助集、prompt 用 "a photo of {}"。
- 學好之後，這個 T 套用到該模型的所有下游推論，不論換什麼 prompt、什麼 inference 資料集，都直接把 CLIP logits 除以 T 即可，無需再訓練 / 調校 / 另備校準集。

為何這仍算「zero-shot」？論文的論證：CLIP 本身就是先在 pre-training 集上訓參數，再對任意未見分布做 zero-shot——ZS-TS 完全平行：在輔助集上訓一個 T ，再對任意未見 inference 分布免訓練套用。且 T 的變動軸 (架構 + 預訓練集) 正好等同 CLIP 參數的變動軸，所以「per 架構 / 預訓練集配對每一個 T 」是與 CLIP 範式一致的。

四、實驗與數據

4.1 設定

- 模型來源：全部來自 OpenCLIP (Ilharco et al. 2021)。
- 架構：ViT-B-16、ViT-B-32、ViT-L-14、ViT-H-14、ResNet-50。
- 預訓練資料集：ViT 系列用 LAION-400M 或 LAION-2B；ResNet 用 YFCC15M (YFCC100M 子集) 或 Conceptual Captions 12M。
- **inference** 資料集：CIFAR10 (10 類)、CIFAR100 (100 類)、SUN397 (397 類)；輔助集 ImageNet-1k (1000 類)。
- **prompt**：多種模板 (如 "a photo of a {}"、"a blurry photo of a {}"、"a bad photo of a {}" 等，CIFAR 用了 18 種變體)。
- ECE 以 $M = 10$ 計算，每格數字為跨 3 個 inference 資料集 (各自帶 prompt) 的平均；全為百分比。

4.2 核心數據 (Table 1 · ECE % · 越低越好)

架構	預訓練集	CLIP (無校準)	CLIP + ZS-TS	CLIP + 監督式 TS
ViT-B-16	LAION-400M	6.34	2.22	0.91
ViT-B-16	LAION-2B	4.65	2.96	0.98
ViT-L-14	LAION-400M	6.68	1.36	0.72
ViT-L-14	LAION-2B	3.17	2.38	0.85
ViT-B-32	LAION-400M	4.69	3.06	1.66
ViT-B-32	LAION-2B	3.88	2.69	0.80
ViT-H-14	LAION-2B	3.67	2.47	0.88
ResNet-50	YFCC15M	26.69	7.60	2.61
ResNet-50	CC12M	26.56	6.18	3.31

4.3 三個關鍵發現

1. 未校準 CLIP 確實 **miscalibrated**：ViT 系列裸 ECE 約 3–7%，ResNet (弱資料集 YFCC15M / CC12M) 更高達 ~26–27%。校準病理的嚴重程度強烈受預訓練資料集與架構影響——資料越乾淨 / 架構越強，裸校準越好。
2. **ZS-TS** 一致改善、但不及監督式 **TS**：ZS-TS 在所有設定都優於裸 CLIP (例如 ResNet-50/YFCC15M 從 26.69% → 7.60%)，但仍明顯遜於監督式 TS (→ 2.61%)。作者誠實標註「仍有改進空間，留給未來 zero-shot 校準方法」。
3. 單一溫度跨 **prompt** / 資料集泛化 (最重要的實證結論)：Figure 2 顯示，對固定 (架構 × 預訓練集)，不同 inference 資料集、不同 prompt 的最佳溫度幾乎相同，且都很接近在大型輔助集上學到的那個 T ——儘管這些資料集的類別數天差地別 (10 / 100 / 397 / 1000)。但不同 (架構 × 預訓練集) 配對的最佳 T 確實略有差異 (左圖 ~1.55、右圖 ~1.35)，所以 T 必須 per 配對各學一個。

4.4 附錄補充

附錄用 Isotonic Regression、Histogram Binning、Unsupervised TS 對照，三者都能大幅降低 miscalibration，但都需要逐資料集校準集或標籤，與 CLIP 實務用法不符。

五、對 CRS 的意涵 (重點)

CRS = 在凍結 grounding base (CLIP-VG / OWL-ViT / GroundingDINO) 之上，用 conformal / LTT 風險控制做事後可靠性層，輸出帶覆蓋與棄答雙保證的 referring set。

5.1 Framing 引用：「VLM 本身就 miscalibrated → 需要可靠性層」

這篇是極佳的動機引用。它用乾淨的實證 (Table 1) 量化了「zero-shot VLM 的原生信賴度不可信」：

- 裸 CLIP ECE 在強模型上仍有 3–7%，在弱預訓練上飆到 26%。
- 換言之，直接拿 frozen VLM 的 softmax / score 當機率用是不安全的——這正是 CRS 立論的起點。

CRS 在 background 可這樣寫：「即使是最廣泛使用的 zero-shot VLM (CLIP)，其原生信賴度也系統性失準 (LeVine et al. 2023)，且失準程度隨架構與預訓練分布大幅波動；因此任何把 frozen base 用於高風險決策 (如 referring grounding) 的系統，都需要一個事後可靠性層來提供可被信任的不確定性語意。」這篇把「需要可靠性層」這件事從直覺變成可引用的數字。

5.2 Baseline 對照：point-calibration (TS/ECE) vs distribution-free guarantee (conformal)

這篇代表的是傳統校準典範，正好是 CRS 要對照、要超越的對象。對照可寫成：

面向	Temperature Scaling / ECE (本文)	CRS (conformal / LTT)
校準對象	softmax 機率的點估計 (讓信賴度逼近正確率)	預測集合的風險 (覆蓋率 / 召回 / 棄答率)
保證型態	無有限樣本保證；ECE 只是事後的聚合誤差度量，不保證任何下游事件的機率	distribution-free、有限樣本的高機率風險上界 (LTT)
是否依賴分布假設	隱含假設校準集與推論分布同分布；換分布即失效	僅需 exchangeability；對 base 與分布更穩健
輸出語意	「這個機率比較準」——仍是單點軟分數	「這個集合以 $\geq 1 - \alpha$ 機率含正解 / 棄答風險 $\leq \beta$ 」——可操作的保證
校準資源	監督式 TS 需逐資料集校準集；ZS-TS 用單一輔助集學一個 T	用一個 calibration split 校準 λ ，輸出對 test 的保證

關鍵論述句 (供論文用)：「Temperature scaling 改善的是平均意義下的信賴度品質 (ECE 下降)，但 ECE 是一個聚合統計量——它不對任何個別預測或特定下游事件 (例如『正解被涵蓋』) 提供機率保證。CRS 改用 conformal / LTT 風險控制，把可靠性從『讓分數更準的點校準』升級為『對覆蓋與棄答的 distribution-free、有限樣本保證』。」

5.3 Gap：分類校準 vs grounding set

兩者任務層級不同，這是 CRS 的差異化空間：

- 本文做的是封閉/開放詞表的影像分類校準：輸出是 single-label 的 top-1 機率，校準的是「最大類別機率 vs 正確率」。
- CRS 做的是 referring grounding 的集合預測：輸出是一組 box / region (可能含棄答、含 no-target)，要保證的是「正解框落在集合內」的召回與集合大小，跨兩個異質 base (gate + box) 做聯合校準。

Gap 的三層：1. 輸出空間：標量機率 → 結構化集合 (box 集合 + 棄答)。ECE 不適用於集合輸出；需要 conformal set 的 size / coverage 度量。2. 保證語意：分類校準求「機率準」；grounding 求「集合涵蓋 + 控棄答」，這是 TS 完全沒處理的維度。3. 多 base 組合：本文一個模型一個 T ；CRS 要在 OWL gate + GroundingDINO box 的 factorization 上做聯合 LTT，溫度縮放沒有對應機制。

因此 CRS 可定位為：「沿用本文揭示的『VLM 原生不可信』動機，但把可靠性工具從點校準 (TS/ECE，無保證) 換成集合層級的 distribution-free 風險控制，並從單模型分類推廣到多 base 的 referring grounding。」

六、ECE vs Conformal Guarantee：概念區分 (可直接放進論文 background)

校準 (calibration，以 ECE 量、以 temperature scaling 修) 與 conformal 風險控制 (CRS 採用) 解決的是兩個不同層級的可靠性問題，不應混為一談。

ECE / temperature scaling 是「點校準」：其目標是讓模型輸出的軟分數 (softmax 機率) 在統計平均上逼近真實正確率。ECE 把預測依信賴度分箱，量測各箱「平均信賴度與真實正確率」的加權絕對差。它是一個聚合的、事後的誤差度量——ECE 低只代表「整體而言信賴度數字比較可信」，但它不對任何單一預測、也不對任何特定下游事件提供機率上界；而且它沒有有限樣本的覆蓋保證，校準集一旦與推論分布不同就可能失效。temperature scaling 則是對應的修法：學一個純量 T 把 logits 壓縮/拉伸，使平均信賴度對齊正確率。它改變的是分數的「銳利度」，輸出仍是不帶任何保證的單點機率。

Conformal / LTT 是「集合層級的 distribution-free 保證」：它不試圖把某個分數修準，而是直接建構一個預測集合 (CRS 中是 referring box 集合，含棄答選項)，並透過校準集選一個閾值 λ ，使得在僅需 exchangeability、不需分布假設的前提下，給出有限樣本、高機率的風險上界——例如「正解以至少 $1 - \alpha$ 的機率落在輸出集合內」「棄答/錯誤風險不超過 β 」。這是一種可操作的、針對指定事件的保證，而非平均意義的分數品質。

一句總結：**ECE** 回答「我的機率數字平均而言準不準」；**conformal** 回答「我這個集合涵蓋正解的機率有沒有被嚴格保證在門檻之上」。前者是 point calibration (無保證)，後者是 set-level distribution-free guarantee (有保證)。CRS 屬於後者，本文 (temperature scaling / ECE) 是前者的代表，正是 CRS 要對照與超越的傳統基線。

七、個人評價

7.1 引用優先級

- **動機引用 (高優先)**：作為「zero-shot VLM 原生 miscalibrated」的實證錨點，Table 1 的數字 (尤其 ResNet 26% 對比 ViT 3–7%) 很適合一句話帶過引用。屬於 CRS background 該放的 framing 引用之一。
- **基線對照 (中高優先)**：作為「傳統校準典範 = temperature scaling / ECE」的代表，用來凸顯 conformal 的差異。它比直接引 Guo et al. (2017) 更貼題，因為它就是在 VLM 上做，與 CRS 同物件 (VLM) 但不同方法層 (point vs set)。建議與 Guo et al. (2017) 一起引 (後者是 TS 原典，本文是 VLM 版應用)。
- **方法借鑒 (低優先)**：ZS-TS 方法本身對 CRS 幫助有限 (CRS 不用 TS)，不需深入。

7.2 限制 (撰文時要誠實標註，也可作為 CRS 的對比優勢)

1. **Workshop paper、實證輕量**：方法是 TS 的一個小變體 (換輔助集 + per-配對單溫度)，新穎性有限；它的價值主要在量測與定位，不在方法深度。
2. **僅分類、僅 top-1 機率**：完全沒碰偵測 / grounding / 集合輸出，也沒碰 open-set / no-target，與 CRS 的任務有實質 gap——這恰好是 CRS 的差異化空間。
3. **ECE 本身的已知缺陷** (本文未深究)：ECE 受分箱數、分箱方式影響，且只反映平均失準、可能掩蓋局部嚴重失準；它不是保證、只是診斷。CRS 引用時可順帶點出「即使 ECE 低也不等於有覆蓋保證」。
4. **泛化結論的範圍**：「單一 T 跨資料集泛化」是在 CIFAR/SUN397/ImageNet 這類自然影像分類上觀察到的，未必能外推到偵測/grounding 或大幅分布偏移；CRS 不依賴此假設 (只需 exchangeability)，是更穩健的設計。
5. **未與 conformal 類方法比較**：本文完全在點校準框架內，沒有比較分布無關保證的方法——這不是它的缺點 (時代與範疇所限)，但正好是 CRS 可以接力的論述縫隙。

總評：一篇定位清晰、誠實、適合當「VLM miscalibration + 傳統校準基線」雙重引用的小品。對 CRS 的價值在 framing 與對照，而非方法移植。引用時要把「point calibration 無保證」對上「conformal distribution-free 有保證」這條軸線，才能把 CRS 的貢獻講清楚。

導讀依據 [arXiv:2303.12748v4](https://arxiv.org/abs/2303.12748v4) 全文 (ICLR 2023 Workshop) 整理。