

VL-SAM-v3 深讀摘要與 CRS 第四個 frozen base 可行性評估

本文件為 CRS (Conformal Referring Set) 碩論研究脈絡下，對 VL-SAM-v3 一篇的深度導讀與「能否作為第四個 frozen open-vocab base」的可行性評估。

0. arXiv ID 驗證結果 (重要)

- 指定 ID : **arXiv:2605.03456v3** (v3, 2026-05-09 · cs.CV)
- 抓取結果 : 已驗證 (**VERIFIED**)。Firecrawl scrape <https://arxiv.org/html/2605.03456> 回傳 status-Code 200、title = "VL-SAM-v3: Memory-Guided Visual Priors for Open-World Object Detection"。頁面內容與「retrieval-grounded visual memory + open-world / open-ended detection」的描述完全一致。ID 沒有指向別篇、也沒有 404。
- 注意一個與題目描述的小落差：題目寫「open-world / open-vocabulary + open-ended detection with retrieval-grounded visual memory」與本文方法相符；但本文並非 **referring expression / REC 論文**，而是**類別層級 (category-level)** 的物件偵測論文。這對後面「能否吃 referring expression」的評估非常關鍵 (見第 6 節)。

1. 書目資訊

- 標題 : VL-SAM-v3: Memory-Guided Visual Priors for Open-World Object Detection
- 作者 : Chih-Chung Liu、Zhiwei Lin、Yongtao Wang (通訊作者)
- 單位 : 北京大學 王選計算機研究所 (Wangxuan Institute of Computer Technology, Peking University)
- **arXiv** : 2605.03456v3 · 2026-05-09
- 系列脈絡 : 本文是 VL-SAM 系列第三代。
 - VL-SAM (NeurIPS 2024 · arXiv 2410-ish · [28]) : training-free · 用 attention-as-prompts 接 SAM 做 open-ended 偵測 + 分割。
 - VL-SAM-v2 (arXiv 2505.18986 · [29]) : general + specific query fusion。
 - VL-SAM-v3 (本文) : 核心換成 **retrieval-grounded external visual memory + Memory-Guided Prompt Refinement**，注意「SAM」這個名字在 v3 已經弱化成可選後處理模組 (見下)。

2. 問題定義與動機

2.1 Open-world detection 的兩個子類

論文把「超出固定封閉類別集 (closed-set) 的偵測」統稱 open-world detection，並明確分為兩類，差別只在**候選類別**怎麼來：

1. **Open-vocabulary detection (開放詞彙)** : 測試時給定一份預先定義好的類別清單 (如 LVIS 1203 類的類名)，偵測器只需在此清單上做定位 + 分類。代表作 GLIP、Grounding-DINO、OWL-ST、DetCLIP 系列、LLMDet。
2. **Open-ended detection (開放生成)** : 測試時沒有類別清單，候選類別要在推論當下由一個 **VLM** 線上生成 (例如用 InternVL/Qwen3-VL 看圖吐出「這張圖裡有哪些物件」的類名)，再交給偵測器定位。代表作 GenerateU、VL-SAM、Open-Det。這個設定更彈性，但表現高度受候選生成品質影響 (候選可能模糊、缺漏、有雜訊)。

兩者共同的底層假設：最後都得**靠語意描述 (文字)** 引導偵測。

2.2 動機：文字語意太粗

論文的 motivation 很單純清楚：只有文字不夠。語言能說「要找什麼 (what)」，但對「目標在影像裡長什麼樣 (how)」線索很少。例如 prompt「dog」把品種、姿態、視角、周遭脈絡全壓成一個概念，對長尾類別 (rare)、雜亂場景、類內變異大的物件特別吃虧。

受 RAG (retrieval-augmented generation) 啟發：非參數記憶 (**non-parametric memory**) 可以在推論時補回參數知識缺的細粒度視覺證據。但目前「如何為 open-world detection 檢索關鍵視覺證據」研究還很少。VL-SAM-v3 就是要補這塊。

3. 方法詳解

整體框架 (論文 Figure 2)：給一張影像 I 與候選類別集 C ，對每個類別從**場景感知視覺記憶庫**檢索相關視覺證據，轉成 **sparse + dense** 兩種視覺先驗，再透過 **Memory-Guided Prompt Refinement** 注入到一個 prompt-based 的開放詞彙偵測器裡。Open-vocab 與 open-ended 共用同一套流程，唯一差別是 C 怎麼取得。

3.1 場景感知視覺記憶 (Scene-aware visual memory · 離線建)

從 grounding-style 資料 (每筆有 image / GT box / phrase) 離線建一個記憶庫，每筆記憶存一組 (k_i, v_i) ：

- **retrieval key k_i** (用於檢索)： $k_i = \text{Norm}(w_p \cdot E_{\text{text}}(t_i) + w_s \cdot E_{\text{text}}(s) + w_g \cdot E_{\text{img}}(I))$ 其中 t_i 是該 box 的 phrase/類名， s 是用 VLM (Qwen3-VL-8B) 對整張圖生成的單一場景標籤 (如 "kitchen"、"forest")， $E_{\text{text}}/E_{\text{img}}$ 是多模態 embedding 模型 (Qwen3-VL-Embedding-2B)。權重 $w_p=1.0$ ， $w_s=0.3$ ， $w_g=0.01$ (phrase 為主、場景為輔、全圖視覺極輕)。
- **visual value v_i** (保存外觀)： $v_i = \text{Norm}(\text{Pool}(F(I), b_i))$ 。 F 是 **DINOv3** 特徵編碼器， Pool 是對 box b_i 內 patch 特徵做 mean pooling (消融顯示 patch-mean 比 CLS token 好 +1.3 AP / +2.2 AP_r)。

記憶值落在 **DINOv3** 特徵空間，保留 grounded region 的外觀。

3.2 類別條件檢索 (Category-conditioned retrieval · 線上)

對每個候選類別 c ，建一個與 key 同空間的 query： $q_c = \text{Norm}(w_p \cdot E_{\text{text}}(c) + w_s \cdot E_{\text{text}}(s) + w_g \cdot E_{\text{img}}(I))$ ，即「類別文字 + 當前影像的場景 + 全圖視覺脈絡」。算 q_c 與每個 k_i 相似度，取 top-K (預設 **K=12**)，用 softmax 權重 α_i (溫度 $\tau_p=0.07$) 把檢索到的 v_i 聚合成**類別專屬視覺原型 p_c** (仍在 DINOv3 空間)。

3.3 Retrieval-grounded 視覺先驗

把 p_c 投影回輸入影像，得兩種互補先驗：

- **Dense prior (密集先驗) H_c** ：對輸入影像 DINOv3 特徵與 p_c 做內積，經平滑 + MinMax 正規化得到 $[0,1]$ 的類別熱圖，提供「class-aware 的空間支撐」。
- **Sparse prior (稀疏先驗) A_c** ：在 H_c 的局部極大值取峰，按響應排序 + 距離抑制 (類 NMS) 挑出空間多樣的點，得到一組 **instance-level** 的空間錨點。

3.4 Memory-Guided Prompt Refinement (核心融合模組)

對偵測器的多尺度特徵，每個尺度獨立做精煉。設 M 為偵測器特徵、 e 為原始可學 prompt prior：- 對每個錨點 a_j 取 sparse 特徵 $f_j^s = \text{Sample}(M, a_j)$ (雙線性取樣)。- 在以 a_j 為中心的局部視窗 Ω_j 內，用 H_c 當權重對 M 加權求和得 dense 特徵 f_j^d 。- 融合： $z_j = \text{LN}(e + W_s \cdot f_j^s + W_d \cdot f_j^d)$ (W_s, W_d 為可學投影)。

每個精煉後的 prompt 同時帶「偵測器原始 query prior + sparse 實例線索 + dense 局部脈絡線索」。各尺度的精煉 prompt 與偵測器原始 prompt 串接，餵進同一個 **transformer decoder**。

3.5 Label-constrained decoding (標籤約束解碼)

每個 memory-guided prompt z_j 綁定其來源類別 t_j ，解碼時只允許對自己的來源類別投票 (其他類別 logit 設 $-\infty$)，避免跨類別漂移。偵測器原始 prompt 不受約束，仍負責全域 open-world 搜尋。消融：加此約束 AP/AP_r 從 46.9/42.7 $\rightarrow$ 47.7/44.9。

3.6 訓練與推論

- **訓練**：避免線上檢索，用 GT box 中心當錨點近似，離線預算 class-specific dense priors，沿用 base detector 同樣的監督與 loss。
- **推論**：對每個候選類別線上檢索建 p_c ， H_c ， A_c 與對應的 memory-guided prompts。

3.7 輸出格式、backbone、是否 frozen-friendly、checkpoint (CRS 最關心)

- **輸出格式**：核心輸出是 **bounding box + 類別分數** (標準偵測 AP)。**Mask** 是可選後處理：附錄 C.1 仿 Grounded-SAM，把 box 餵 SAM 轉 mask，SAM 不參與偵測器訓練。→ 本質是 **box detector**，不是只出 **mask** 的分割器。
- **Backbone / base detector**：主實作建在 **LLMDet** (Swin-T / Swin-L)，照 LLMDet 訓練策略，在 **GroundingCap-1M** 上 fine-tune 150k iters ($8 \times A100$)。另把同一套 retrieval-and-refinement 套到 **SAM3** (PE-L+ backbone) 做泛化驗證 (在 GroundingCap-1M fine-tune 2 epochs)。
- 是否 **frozen-friendly**：這是最大警訊。VL-SAM-v3 不是一個訓練後拿來即插即用的 **frozen** 偵測器——它需要對 **base detector** 做 **fine-tune** (無論是 LLMDet 還是 SAM3 都重新 fine-tune 過)，且推論時要線上檢索一個 **10.83M** 筆、約 **64 GiB** 的 **FAISS** 記憶庫並做 prompt 精煉。它是「在既有 base 上加一層需要訓練的精煉機制」，而非一個獨立的 frozen black-box。
- 公開 **checkpoint**：論文文本未提供任何程式碼 / **checkpoint** / 專案連結 (無 GitHub、無 HuggingFace、無 project page 出現在內文與附錄)。記憶庫建構依賴 Qwen3-VL-8B (場景描述)、Qwen3-VL-Embedding-2B (key)、DINOv3 (value)。這些是外部模型，但 VL-SAM-v3 本身的權重與記憶庫目前看不到釋出。

4. 實驗

4.1 設定

- **主資料集**：**LVIS** (zero-shot)，報 fixed AP 與 APr/APc/APf (rare/common/frequent)。同時跑 open-vocab 與 open-ended 兩種協議。
- **參考資料集**：**COCO** (非 zero-shot，因 GroundingCap-1M 含 COCO 影像，僅供參考)。
- **記憶庫**：離線從 GroundingCap-1M 的 grounding 標註建，排除與 LVIS eval split 重疊的影像避免污染。
- **效率**：記憶庫 10.83M 筆 / 63.97 GiB / 每筆 6.2 KiB；FAISS IndexIVFPQ，內積相似度，約 400 queries/s (僅 FAISS 搜尋階段)。推論成本主要來自 VLM 類別生成 (700 ms) 與場景描述 (500 ms)，retrieval+refinement 本身很輕 (sparse/dense prompt 80 ms、refinement head 5 ms)。

4.2 Open-vocabulary detection on LVIS (Table 1，關鍵數字)

Method	Backbone	minival AP	minival APr	val AP	val APr
Grounding-DINO	Swin-T	27.4	18.1	20.1	10.1
OWL-ST	CLIP B/16	34.4	38.3	28.6	30.3
LLMDet	Swin-T	44.7	37.3	34.9	26.0
VL-SAM-v2	Swin-T	45.7	41.2	35.5	29.3
VL-SAM-v3	Swin-T	47.7	44.9	38.1	35.2
LLMDet	Swin-L	51.1	45.1	42.0	31.6
VL-SAM-v2	Swin-L	51.7	47.2	42.5	33.2
VL-SAM-v3	Swin-L	53.4	50.9	43.5	39.7
SAM3	PE-L+	59.1	61.9	53.6	54.9
VL-SAM-v3 + SAM3	PE-L+	60.2	63.4	54.1	55.8

重點：相對 base (LLMDet) 一致提升，增益集中在 **rare/common** (APr Swin-T +7.6、val +9.2)，APf 幾乎不變 (與 v2 同推論協議)。套到 SAM3 也再升，說明機制不綁 LLMDet。**SAM3** 本身才是目前最強的 **base** (minival 59.1 / val

53.6 AP) · VL-SAM-v3 的貢獻是在其上 +1.x AP 的精煉。

4.3 Open-ended detection on LVIS (Table 2)

Method	Base / backbone	候選生成器	AP / APr
GenerateU	Swin-L	FlanT5-base	27.9 / 22.3
VL-SAM	ViT-H	CogVLM(17B)	25.3 / 23.4
VL-SAM-v2	LLMDet/Swin-T	InternVL-2.5(8B)	29.5 / 29.8
VL-SAM-v3	LLMDet/Swin-T	InternVL-2.5(8B)	40.6 / 37.9
VL-SAM-v3	LLMDet/Swin-T	Qwen3-VL(8B)	41.4 / 39.4
VL-SAM-v3	LLMDet/Swin-L	Qwen3-VL(8B)	44.8 / 41.9
SAM3	SAM3/PE-L+	Qwen3-VL(8B)	49.9 / 52.6
VL-SAM-v3+SAM3	SAM3/PE-L+	Qwen3-VL(8B)	51.7 / 54.0

open-ended 是本文增益最大的地方 (同候選生成器下 +11 AP 量級)。

4.4 消融 (LVIS minival, Swin-T)

- sparse / dense 先驗互補 : base 44.7 → +sparse 46.8 → +dense 46.7 → both 47.7 (APr 37.3→44.9)。
- scene descriptor : 47.1→47.7 ; label-constrained decoding : 46.9→47.7 。
- value : patch-mean > CLS (47.7 vs 46.4)。top-K=12 最佳。
- 對輔助 VLM 穩健 (GLM4.6V/InternVL-2.5/3.5/Qwen3-VL 都行，越強略好)。

4.5 Mask 遷移 (附錄 C.1)

接 SAM 做 open-ended instance segmentation · LVIS minival 39.9 mask AP / 36.4 mask APr 。

完全沒有 RefCOCO / gRefCOCO / referring expression / REC / phrase grounding 的單句指涉實驗——全部是 category-level LVIS/COCO。這點對 CRS 評估極其關鍵。

5. 作為 CRS 第 4 個 frozen base 的可行性評估

CRS 現況回顧 : post-hoc conformal composition · 組合凍結的 open-vocab grounding base (目前 OWL-ViT 當 gate + GroundingDINO 出 box) · 用 LTT 校準在 gRefCOCO/RefCOCO 上給「召回 + 棄答」雙保證。要納入新 base 必須滿足 : (1) 能出 box ; (2) 能吃 referring expression (自然語言指涉) ; (3) 能當 gate (棄答/no-target) 或 box source ; (4) 最好有公開 frozen checkpoint 。

逐項對照 :

評估維度	VL-SAM-v3	判定
能否輸出 box ?	能 · 核心就是 box detector (AP) · mask 可選。	通過

評估維度	VL-SAM-v3	判定
能否接受 referring expression ?	不能 (直接地)。它吃的是類別字串 (“dog” , “cup”)。open-ended 時由 VLM 生成類名清單。論文沒有任何 RefCOCO/REC 單句指涉實驗。referring expression (“the man in red on the left”) 與類名語意不同——key/query 是用 E_text(類別)+ 場景 + 全圖。記憶庫也以 phrase-region 類別對建。對指涉性、空間關係、屬性區辨 (CRS 主場 gRefCOCO 的核心) 未經設計也未經驗證。	不通過 (高風險)
適合當 gate (棄答/no-target)?	不適合。CRS 的 OWL-ViT gate 角色需要可校準的 per-object/no-target 分數分布來做 abstention。VL-SAM-v3 沒有 no-target / 不存在目標的處理機制。其分數是 LVIS detection logit (且經 label-constrained decoding 綁死來源類別)。不是為「該不該回答」設計。	不通過
適合當 box source ?	理論上可 (它出 box)。但前提是要能吃 CRS 的 query。而它吃類名不吃 referring expression。若硬把 RE 當「類別字串」塞進去。等於用錯介面。	條件不成立
是否 frozen-friendly / 有 checkpoint ?	否。需 fine-tune base detector；需線上維護 64 GiB / 10.83M 筆 FAISS 記憶庫 + Qwen3-VL/DINOv3 多模型管線；論文未釋出程式碼/權重。整合工程量巨大。	不通過
score 分布互補性 (cross-base 論證)	表面上「記憶檢索 + open-ended」確實帶來與 OWL-ViT/GroundingDINO 不同的分數來源 (DINOv3 原型相似度)。理論上分布更異質、對 cross-base transfer 是好題材。但這只有在它能接同一個 RE 介面、且能拿到 frozen 版本時才有意義；目前兩個前提都不成立。	潛力存在但無法兌現

整合難度與風險總結：1. 介面不符 (最致命)：CRS 是 referring expression comprehension 場景 (gRefCOCO/RefCOCO，單句指涉)，VL-SAM-v3 是 category-level open-vocab/open-ended detection。語意層級不同，記憶庫與 query 設計都不是為指涉句設計。把它塞進 CRS 等於改變它的使用方式，會破壞「凍結既有 base、post-hoc 組合」的乾淨敘事。2. 非 **frozen**：要 fine-tune，違背 CRS「frozen base」前提。3. 重型依賴：64 GiB 記憶庫 + 多個 VLM/embedding/DINOv3 模型線上協作，部署與重現成本極高，且無公開 checkpoint。4. 正面但無法兌現的點：rare-category 強、score 來源異質，本來會是 cross-base 多樣性的好賣點，可惜被前三點抵消。

6. 個人評價

推薦度：低（作為 CRS 第 4 個 frozen base 不推薦）

理由按重要性排序：1. 任務介面錯位：它不吃 referring expression，沒有任何 REC/gRefCOCO 證據。CRS 的核心是指涉理解與棄答/no-target，VL-SAM-v3 是類別偵測，兩者不在同一介面上。這是硬傷，不是調參能補的。2. 不是 frozen 模型：需要 fine-tune base detector，與 CRS「凍結現成 base、純 post-hoc」的賣點直接衝突。3. 無公開 checkpoint / 重型管線：64 GiB 記憶體 + Qwen3-VL + DINOv3 + LLMdet/SAM3，工程整合成本與 CRS「輕量、可重現、後處理」的定位不符。

唯一可考慮的「拐個彎」用法：若論文要強化 cross-base 論證，真正值得引用的是它的 base，而非 VL-SAM-v3 本身——也就是 SAM3（它驗證機制時所用的最強 open-vocab 偵測器，LVIS val 53.6 AP）。但 SAM3 是 concept-based 偵測器，仍非 RE 模型，要納入 CRS 也需確認其 RE/phrase 能力。

限制（即使撇開 CRS）

- 全評測停在 category-level（LVIS/COCO），缺指涉性與關係推理評測。
- 增益高度依賴外部 VLM 候選生成（open-ended 的 AP 大頭成本在 VLM 生成）。
- 記憶體需排除測試影像避免污染，遷移到新 domain 要重建記憶體。

7. 若不適合：改用什麼（誠實建議）

VL-SAM-v3 不適合當 CRS 第 4 個 frozen base（不吃 RE、非 frozen、無 checkpoint）。對 CRS「最新/最強 frozen base 上仍給保證」的 cross-base 論證，下列兩者遠更合適，因為它們是現成 frozen、可吃 referring expression / phrase、有公開權重：

1. **DINO-X (arXiv 2411.14347)**：unified open-world detection + grounding，吃文字 prompt（含 phrase/referring 風格），出 box（並可出 mask/pose 等），有 API/模型。與 GroundingDINO 同家族但更強，分數分布與現有 GroundingDINO 有家族相關性——若要「不同家族」可搭 OWL 系。屬性：能出 box、能吃語言 query、可當 box source 或 gate 候選。推薦度：中高。
2. **Grounding-DINO-1.5 (arXiv 2405.10300)**：GroundingDINO 的升級版（Pro/Edge），open-set detection，吃自然語言 prompt（句子/phrase/category），出 box，有釋出。作為「更強的 frozen GroundingDINO」最自然——直接支撐「CRS 換到更强同型 base 仍給保證」的敘事，整合成本最低（介面與現有 GroundingDINO 幾乎一致）。推薦度：高（最低風險、最對齊 CRS 敘事）。

選擇建議：- 想證明「換更强的同型 base 仍有保證」→ 用 **Grounding-DINO-1.5**（介面相容、風險最低）。- 想證明「換到分數分布更異質的新家族 base 仍有保證，強化 cross-base transfer」→ 用 **DINO-X**（能力更廣、分布更不同）。- 兩者都比 VL-SAM-v3 更符合「frozen open-vocab grounding base」的定義，且都有 referring/phrase 能力與可取得的權重/API。

8. 一句話結論

VL-SAM-v3 是篇紮實的 category-level open-world detection 論文（retrieval-grounded visual memory + prompt refinement，LVIS rare/open-ended 大幅提升），但它吃類別不吃 referring expression、需要 fine-tune（非 frozen）、無公開 checkpoint 且依賴 64 GiB 記憶體管線，不適合當 CRS 的第 4 個 frozen base。要強化 CRS 的 cross-base 論證，改用 **Grounding-DINO-1.5 (2405.10300)**，最對齊、最低風險，或 **DINO-X (2411.14347)**，分布更異質。